# הסתברות

## הרצאות

ד"ר רבייב דניאל

8 באפריל 2026

ייתכנו טעויות דפוס[1], אתם מוזמנים ליידע אותי בכל טעות אפשרית.

## תוכן עניינים


**I מבוא** **4**

1 מרחב הסתברות . . . . . 5

1.1 $\sigma$־אלגברה . . . . . 6

1.2 הגדרת מרחב הסתברות . . . . . 8

1.3 תכונות מרחב הסתברות . . . . . 13

2 הסתברות מותנית . . . . . 15

2.1 נוסחת ההסתברות השלמה ונוסחת בייס . . . . . 19

2.2 אי־תלות . . . . . 21

3 הלמה של בורל־קנטלי . . . . . 23

4 ניסויי ברנולי . . . . . 27

**II משתנה מקרי בדיד** **30**

5 הגדרות ותכונות בסיסיות . . . . . 30

6 פילוגים בדידים מרכזיים . . . . . 33

7 תכונת חוסר הזיכרון . . . . . 40

8 טרנספורמציה של משתנה מקרי . . . . . 41


[1] תודה למאור ליסקר על הערות, תיקונים והגהות.

9 וקטור אקראי . . . 43
9.1 פילוג שולי . . . 45
9.2 פילוג מולטינומי . . . 46
9.3 טרנספורמציה של וקטור אקראי . . . 47
10 פילוג מותנה של משתנים . . . 48
11 משתנים מקריים בדידים בלתי תלויים . . . 49
11.1 משפט הקונבולוציה למשתנים מקריים בדידים . . . 50
11.2 טרנספורמציה של משתנים מקריים בדידים בלתי־תלויים . . . 51
12 התוחלת . . . 51
12.1 תוחלת של פילוגים בדידים ידועים . . . 54
12.2 נוסחת הזנב . . . 56
12.3 תוחלת של טרנספורמציה . . . 58
12.4 לינאריות וכפליות של התוחלת . . . 59
12.5 אי־שוויון מרקוב . . . 60
12.6 תוחלת מותנית . . . 61
12.7 נוסחת ההחלקה . . . 63
12.8 מומנטים . . . 64
12.8.1 פונקציה יוצרת מומנטים . . . 65
12.8.2 אי־שוויון צ'רנוף . . . 67
12.8.3 מומנטים מסדר שני של פילוגים ידועים . . . 68
13 השונות . . . 71
13.1 השונות של הפילוגים הידועים . . . 72
13.2 תכונות בסיסיות . . . 73
13.3 אי־שוויון צ'בישב . . . 75
13.4 שונות משותפת . . . 76
13.5 שונות מותנית והחלקה לשונות . . . 81
13.6 מקדם המתאם . . . 83

**III משתנה מקרי כללי** **86**

14 משתנה מקרי רציף ורציף בהחלט . . . 86
15 פילוגים רציפים מרכזיים . . . 87

16 פונקציית ההתפלגות . . . . . 90
16.1 פונקציית ההתפלגות של פילוגים ידועים . . . . . 91
16.2 תכונות של פונקציית התפלגות . . . . . 101
16.3 דוגמה למשתנה מעורב . . . . . 103
16.4 אפיון משתנה רציף בהחלט . . . . . 104
16.5 דוגמה למשתנה רציף שאינו רציף בהחלט . . . . . 106
17 וקטור אקראי רציף בהחלט . . . . . 107
17.1 פונקציית ההתפלגות . . . . . 108
17.2 פילוג שולי . . . . . 110
18 פילוג מותנה במקרה הכללי . . . . . 113
19 אי־תלות במקרה הרציף . . . . . 115
19.1 משפט הקונבולוציה למשתנים מקריים רציפים בהחלט . . . . . 118
20 התוחלת והשונות במקרה הרציף בהחלט ובמקרה הכללי . . . . . 121
20.1 תוחלת ושונות של פילוגים רציפים ידועים . . . . . 122
20.2 נוסחת הזנב . . . . . 124
20.3 תוחלת מותנית ונוסחת ההחלקה במקרה הכללי . . . . . 125
21 וקטור אקראי גאוסי כללי . . . . . 127
22 משפטי הגבול . . . . . 129
22.1 סדרת משתנים מקריים ומושג ההתכנסות . . . . . 129
22.1.1 התכנסות בהתפלגות . . . . . 130
22.1.2 התכנסות בהסתברות . . . . . 130
22.1.3 התכנסות כמעט בטוח . . . . . 132
22.2 החוק החלש של המספרים הגדולים . . . . . 133
22.3 החוק החזק של המספרים הגדולים . . . . . 134
22.4 משפט הגבול המרכזי . . . . . 135

## חלק I

# מבוא

הסתברות מיוצגת בעזרת מספר ממשי בין 0 ל־1 המציין את מידת הסבירות שמאורע מסוים יתרחש. ראשית נתחיל במספר דוגמאות אינטואיטיביות.

**דוגמאות:**

1. בהטלת קוביה הוגנת ההסתברות שיצא 1 היא $\frac{1}{6}$.

2. בבחירת מספר אקראי מבין המספרים $\{1, 2, ..., 100\}$, ההסתברות שייבחר מספר זוגי היא $\frac{1}{2}$.

3. בבחירת מספר אקראי מבין כל המספרים הטבעיים $\mathbb{N} = \{0, 1, 2, ...\}$, ההסתברות שייבחר מספר זוגי היא לא בהכרח $\frac{1}{2}$, זה תלוי באיך מודדים את ההסתברות.

4. בבחירת מספר ממשי אקראי בקטע $[0, 1]$, ההסתברות שבחרנו את 1 היא 0. בהמשך נבין היטב מדוע, ואיך בדיוק מתבטאת האקראיות. עם זאת דוגמה זאת ממחישה שהסתברות 0 לא אומרת שאין סיכוי שמשהו יקרה, היא אומרת שהוא "כמעט בטוח" לא מתרחש (כנ"ל עבור הסתברות 1). המינוח "כמעט בטוח" הוא מושג פורמלי שנגדיר בהמשך.

5. נתונה המשוואה $x + y + z = 10$ כאשר $x, y, z \in \mathbb{N}$. מגרילים פתרון פתרון אקראי, מה ההסתברות לקבל פתרון בו $x \leq 1$? כידוע מספר הפתרונות למשוואה הוא:

$$D(3, 10) = \binom{12}{10} = 66$$

מספר הפתרונות בהם $x \leq 1$ הוא:

$$D(2, 10) + D(2, 9) = \binom{11}{10} + \binom{10}{9} = 21$$

לכן ההסתברות היא: $\frac{21}{66} \sim 0.32\%$.


danielr@technion.ac.il

6. מציעים לכם את המשחק הבא: אתם משלמים $n$ שקלים, כעת מטילים מטבע הוגן שוב ושוב עד שיוצא עץ, אתם מרוויחים $x(k)$ שקלים כאשר $k$ הוא מספר ההטלות הכולל (כלומר עד שיצא עץ). כמה $n$ צריך להיות שווה על מנת שיהיה כדאי לשחק במשחק? האם עבור ערכי $n$ מסויימים כדאי לשחק מספר רב יותר של פעמים? נבחין בין המקרים הבאים:

**1.** $x(k) = 4$: במקרה זה נראה שה"רווח הממוצע" הוא 4, לכן על מנת שיהיה משתלם לשחק נדרוש $n < 4$. אין ככל הנראה משמעות למספר המשחקים.

**2.** $x(k) = 4k$: במקרה זה נראה שה"רווח הממוצע" הוא 8, לכן על מנת שיהיה משתלם לשחק נדרוש $n < 8$. אין ככל הנראה משמעות למספר המשחקים.

**3.** $x(k) = 2^{k-1}$: במקרה זה נראה שה"רווח הממוצע" הוא אינסוף, לכן על פניו נראה שכל ערך של $n$ צפוי להשתלם. עם זאת, עבור ערכי $n$ גדולים, ככל הנראה נפסיד אם נשחק משחק אחד. אם כך מהי המשמעות שהרווח הממוצע הוא אינסוף? המשמעות היא שאם נשחק במשחק שוב ושוב הרווח הממוצע צפוי לגדול ככל שנשחק יותר. לכן עבור סכום מסויים, נאמר $n = 1000$, עבור מספיק משחקים (כלומר $k$ גדול מספיק) יהיה משתלם לשחק את המשחק.

בהמשך נטפל בבעיה הזאת בצורה יותר אנליטית. על מנת להתקדם ולהיות מסוגלים לבצע אנליזה מדוייקת ופורמלית יותר נתחיל בהגדרת מרחב ההסתברות והתכונות הבסיסיות שלו.

## 1 מרחב הסתברות

לפני ההגדרות הפורמליות, נתחיל עם דוגמאות כמוטיבציה להגדרה. נניח שנתונה בעיה, נסמן ב־$\Omega$ את האפשרויות השונות.

**דוגמאות:**

1. בהטלת קוביה הוגנת אפשר לבחור $\Omega = \{1, 2, 3, 4, 5, 6\}$.

2. בהטלת שתי קוביות הוגנות אחת אחרי השניה אפשר לבחור $\Omega = \{(i, j) \mid \ i, j \in [1, 2, 3, 4, 5, 6]\}$.

3. בבחירה של מספר אקראי בקטע $[0, 1]$ נבחר $\Omega = [0, 1]$.

נניח שרוצים לדעת הסתברות של תרחיש מסויים כאשר התרחיש הוא לא בהכרח איבר בודד מאוסף האפשרויות.

**דוגמאות:**

1. בהטלת קוביה הוגנת בחרנו $\Omega = \{1,2,3,4,5,6\}$. כעת:
   1. אם רוצים לדעת מהי ההסתברות שיצא לנו 3 אז נחשב: $\frac{|\{3\}|}{|\Omega|} = \frac{1}{6}$.
   2. אם רוצים לדעת מהי ההסתברות שיצא לנו מספר זוגי אז נחשב: $\frac{|\{2,4,6\}|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}$.

2. בהטלת שתי קוביות הוגנות אחת אחרי השניה בחרנו $\Omega = \{(i,j) \mid \ i,j \in [1,2,3,4,5,6]\}$. כעת אם רוצים לדעת מהי ההסתברות שסכום הערכים הוא 4 נחשב:

$$\frac{|\{(1,3),(2,2),(3,1)\}|}{|\Omega|} = \frac{3}{36} = \frac{1}{12}$$

### 1.1 $\sigma$־אלגברה

נתחיל עם מושג בסיסי וחשוב אשר נקרא **$\sigma$־אלגברה** ויעזור לנו לחשב באופן פורמלי הסתברויות.

**הגדרה 1.1** תהא $\Omega \neq \phi$, תת קבוצה $\mathcal{F} \subseteq \mathbb{P}(\Omega)$ נקראת **$\sigma$־אלגברה** על $\Omega$ אם מתקיים:

1. $\phi \in \mathcal{F}$.
2. לכל $\{A_n\}_{n=1}^{\infty} \subseteq \mathcal{F}$ מתקיים $\bigcup\limits_{n=1}^{\infty} A_n \in \mathcal{F}$.
3. לכל $A \in \mathcal{F}$ מתקיים $A^c \in \mathcal{F}$.

**הערה:** תזכורת להמשך, $\mathbb{P}(A)$ היא **קבוצת החזקה** של $A$, כלומר קבוצת כל תת הקבוצות שלה.

**דוגמאות:**

1. לכל קבוצה סופית $A$ או בת־מניה מתקיים שקבוצת החזקה $\mathbb{P}(A)$ היא $\sigma$־אלגברה.

2. תהא:

$$\mathcal{F} = \{A \subseteq \mathbb{R} \mid \text{בת מניה } A \text{ או } A^c \text{ בת מניה}\}$$

קל לוודא ש־ $\mathcal{F}$ היא אכן $\sigma$־אלגברה מעל $\mathbb{R}$.

נוכיח תכונות בסיסיות.

**משפט 2.1** תהא $\Omega \neq \phi$ ותהא $\mathcal{F}$ $\sigma$־אלגברה מעל $\Omega$, אז:

1. $\Omega \in \mathcal{F}$.
2. לכל מספר סופי $A_1, ..., A_n \in \mathcal{F}$ מתקיים $\bigcup_{k=1}^{n} A_k \in \mathcal{F}$.
3. לכל $\{A_n\}_{n=1}^{N} \subseteq \mathcal{F}$ כאשר $N \in \mathbb{N}$ או $N = \infty$ מתקיים $\bigcap_{k=1}^{N} A_k \in \mathcal{F}$.
4. לכל $A, B \in \mathcal{F}$ מתקיים $A - B \in \mathcal{F}$.

**הוכחה:**

1. מההגדרה $\phi \in \mathcal{F}$ וגם $\Omega = \phi^c \in \mathcal{F}$ וסיימנו.
2. נגדיר $A_k = \phi$ לכל $k > n$ ומהתכונה השניה בהגדרה נקבל $\bigcup_{k=1}^{n} A_k = \bigcup_{k=1}^{\infty} A_k \in \mathcal{F}$.
3. מההגדרה מתקיים $A_k^c \in \mathcal{F}$ לכן לפי דה־מורגן וסעיף קודם נקבל $\bigcap_{k=1}^{N} A_k = \left(\bigcup_{k=1}^{N} A_k^c\right)^c \in \mathcal{F}$.
4. מההגדרה גם $B^c \in \mathcal{F}$ לכן מסעיף קודם $A - B = A \cap B^c \in \mathcal{F}$.

■

כעת נעבור למשפט חשוב אשר עוזר לעבוד במקרים העיקריים בהם ה־$\sigma$־אלגברה היא לא בת מניה.

**משפט 3.1** תהא $\Omega \neq \phi$ ותהא $\phi \neq S \subseteq \mathbb{P}(\Omega)$, אז קיימת $\sigma$־אלגברה יחידה $\mathcal{F}_S$ המקיימת:

1. $S \subseteq \mathcal{F}_S$.
2. לכל $\sigma$־אלגברה $\mathcal{F}$ המכילה את $S$ מתקיים $\mathcal{F}_S \subseteq \mathcal{F}$.

**הערה:** $\mathcal{F}_S$ היא ה־$\sigma$־אלגברה **הנוצרת ע"י** $S$ והיא מינימלית במובן שהיא מכילה כל $\sigma$־אלגברה אחרת המכילה את $S$. לפעמים מסמנים גם $\mathcal{F}_S = \sigma(S)$.

**הוכחה:** תהא $\mathcal{A}$ אוסף כל ה־$\sigma$־אלגבראות המכילות את $S$ (ברור כי $\mathcal{A} \neq \phi$ הרי $\Omega \in \mathcal{A}$). נוכיח כי $\mathcal{F}_S$ המבוקשת היא $\bigcap_{\mathcal{F} \in \mathcal{A}} \mathcal{F}$. ראשית מראים (לפרט) כי $\bigcap_{\mathcal{F} \in \mathcal{A}} \mathcal{F}$ מקיימת את האקסיומות של $\sigma$־אלגברה ולכן היא $\sigma$־אלגברה. כעת נראה את שתי התכונות:

1. מההגדרה לכל $\mathcal{F} \in \mathcal{A}$ מתקיים $S \subseteq \mathcal{F}$ ולכן $S \subseteq \bigcap_{\mathcal{F} \in \mathcal{A}} \mathcal{F}$.
2. אם $\tilde{\mathcal{F}}$ היא $\sigma$־אלגברה המכילה את $S$ אז $\tilde{\mathcal{F}} \in \mathcal{A}$ ולכן $\bigcap_{\mathcal{F} \in \mathcal{A}} \mathcal{F} \subseteq \tilde{\mathcal{F}}$.

■

**דוגמה:** נגדיר $\sigma$־אלגברה מעל הקטע $[0,1]$. תהא $S=\{[a,b]\mid 0\le a<b\le 1\}$ אז לפי המשפט $\mathcal{F}_S$ היא $\sigma$־אלגברה. נראה ש־$\mathcal{F}_S$ מכילה את כל היחידונים $\{x\}$ כאשר $x\in[0,1]$:

עבור $x\in[0,1)$: נבחין כי $\{x\}=\bigcap_{n=n_0}^{\infty}\left[x,x+\frac{1}{n}\right]$ כאשר $n_0=\left\lceil\frac{1}{1-x}\right\rceil$ ולכן לפי המשפט החיתוך נמצא ב־$\mathcal{F}_S$.

עבור $x=1$: נבחין כי $\{1\}=\bigcap_{n=1}^{\infty}\left[1-\frac{1}{n},1\right]$ ושוב לפי המשפט החיתוך נמצא ב־$\mathcal{F}_S$.

באופן כללי מגדירים $\sigma$־אלגברה סטנדרטית על $\mathbb{R}^n$ והיא:

**הגדרה 4.1** **ה־$\sigma$־אלגברה של בורל** מוגדרת על־ידי:

$$\beta_n=\beta\left(\mathbb{R}^n\right)=\mathcal{F}_S,\quad S=\{(-\infty,a_1]\times\cdots\times(-\infty,a_n]\mid a_1,\dots,a_n\in\mathbb{R}\}$$

**הערות:**

1. $\beta_n$ מכילה את כל הקבוצות הפתוחות וכל הקבוצות הסגורות.
2. מגדירים $\sigma$־אלגברה גדולה ו"מדוייקת" יותר הנקראת **ה־$\sigma$־אלגברה של לבג**. לא דבר על זה בקורס.

**דוגמה:** כזכור עבור $S=\{[a,b]\mid 0\le a<b\le 1\}$ ראינו את ה־$\sigma$־אלגברה $\mathcal{F}_S$. ניתן להוכיח כי:

$$\mathcal{F}_S=\beta_1\cap\mathbb{P}\left([0,1]\right)$$

למעשה לכל תת־קבוצה כל $\mathbb{R}^n$ עם נפח[2] חיובי ניתן לקבל $\sigma$־אלגברה מושרית מבורל. באופן פורמלי:

**משפט 5.1** תהא $J\subseteq\mathbb{R}^n$ קבוצת ז'ורדן[3] בעלת נפח חיובי הקבוצה $\beta_J=\beta_n\cap\mathbb{P}\left(J\right)$ היא $\sigma$־אלגברה.

### 1.2 הגדרת מרחב הסתברות

ראינו כרגע את המושג שנקרא $\sigma$־אלגברה. כעת ניתן להגדיר פונקציה אשר "מודדת הסתברות".

[2] מדובר על נפח $n$־מימדי. עבור $n=1$ מדובר באורך, עבור $n=2$ מדובר בשטח ועבור $n=3$ זה נפח תלת מימדי.
[3] באופן אינטואיטיבי קבוצת ז'רודן היא קבוצה שיש לה שפה המחלקת את המרחב ל"פנים וחוץ".

**הגדרה 6.1** תהא $\mathcal{F}$ $\sigma$־אלגברה מעל $\Omega$. פונקציה $P:\mathcal{F}\to[0,1]$ נקראת **מידת הסתברות** אם:

1. $P(\phi)=0$.
2. $\sigma$־אדיטיביות: לכל סדרת מאורעות $\{A_n\}_{n=1}^{\infty}\subseteq\mathcal{F}$ זרים בזוגות מתקיים: $P\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}P(A_n)$.
3. לכל $A\in\mathcal{F}$ מתקיים: $P(A^c)=1-P(A)$.

**הערות:**

1. $\Omega$ נקרא **מרחב המדגם** וכן כל איבר ב־$\mathcal{F}$ נקרא **מאורע**. ברמה האינטואיטיבית היינו מצפים שאיחוד של מאורעות הוא מאורע, חיתוך של מאורעות הוא מאורע וכך גם המשלים. התכונות הללו אכן נובעות מההגדרה של $\sigma$־אלגברה.
2. מההגדרה נובע כי: $P(\Omega)=P(\phi^c)=1-P(\phi)=1$.
3. $\sigma$־אדיטיביות נכונה גם באוסף סופי של מאורעות, אפשר למשל לבחור את יתר המאורעות להיות קבוצה ריקה.
4. כזכור קבוצה **בת־מניה** היא קבוצה סופית או אינסופית השקולה לטבעיים (כלומר יש פונקציה חח"ע ועל מהקבוצה לטבעיים). כאשר $\Omega$ היא בת־מניה נהוג לקחת $\mathcal{F}=\mathbb{P}(\Omega)$.
5. במרחב בן־מניה מספיק לקבוע את ההסתברות של היחידונים (כלומר לקבוע את $P(\{\omega\})$ לכל $\omega\in\Omega$) ואז בעזרת ה־$\sigma$־אדיטיביות לקבל את ההסתברות של כל מאורע.
6. במרחב שהוא לא בן־מניה לא מספיק לקבוע את ההסתברות של היחידונים, מייד נראה דוגמה בעניין.
7. אומרים שמאורע $A$ מתקיים **כמעט בטוח** אם $P(A^c)=0$.

כעת ניתן להגדיר את מרחב ההסתברות:

**הגדרה 7.1** **מרחב הסתברות** הוא שלשה $(\Omega,\mathcal{F},P)$ כך שמתקיים:

1. $\Omega\neq\phi$ הוא מרחב המדגם.
2. $\mathcal{F}\subseteq\mathbb{P}(\Omega)$ היא $\sigma$־אלגברה.

3. $P:\mathcal{F}\to[0,1]$ היא מידת הסתברות.

**הערה**: מרחב **שווה הסתברות** הוא מרחב הסתברות בו $\Omega$ סופית וההסתברות של כל יחידון היא זהה. במרחב כזה מתקיים:

$$\forall A\in\mathcal{F},\ P(A)=\frac{|A|}{|\Omega|}$$

**דוגמאות:**

1. מטילים שתי קוביות (הוגנות) ברצף. מרחב הסתברות אפשרי הוא:

$$\begin{cases}\Omega=\{(i,j)\mid\ i,j\in\{1,2,3,4,5,6\}\}\\ \mathcal{F}=\mathbb{P}(\Omega)\\ \forall(i,j)\in\Omega,\ P(\{(i,j)\})=\frac{1}{36}\end{cases}$$

ראשית נבחין שזהו מרחב שווה הסתברות. כעת נניח שרוצים לחשב את ההסתברות שסכום הערכים הוא 4, נסמן $A=\{(1,3),(2,2),(3,1)\}$ ונחשב:

$$P(A)=\frac{|A|}{|\Omega|}=\frac{3}{36}=\frac{1}{12}$$

2. אם ניקח את אותה הבעיה מהדוגמה הקודמת, כלומר מטילים שתי קוביות (הוגנות) ברצף ורוצים לחשב את ההסתברות שסכום הערכים הוא 4, ניתן להגדיר מרחב הסתברות אחר:

$$\begin{cases} \Omega = \{2,3,4,...,12\} \\ \mathcal{F} = \mathbb{P}(\Omega) \\ \begin{cases} P(\{2\}) = \frac{1}{36},\ P(\{3\}) = \frac{2}{36},\ P(\{4\}) = \frac{3}{36},\ P(\{5\}) = \frac{4}{36},\ P(\{6\}) = \frac{5}{36},\ P(\{7\}) = \frac{6}{36} \\ P(\{8\}) = \frac{5}{36},\ P(\{9\}) = \frac{4}{36},\ P(\{10\}) = \frac{3}{36},\ P(\{11\}) = \frac{2}{36},\ P(\{12\}) = \frac{1}{36} \end{cases} \end{cases}$$

הפעם לא קיבלנו מרחב שווה הסתברות ועדיין זה פותר את אותה הבעיה: ההסתברות שסכום הערכים הוא 4 היא ההסתברות של המאורע $A = \{4\}$ שהיא:

$$P(A) = \frac{3}{36} = \frac{1}{12}$$

**הערה**: אפשר לחשוב על מרחב הסתברות כמודל אפשרי לבעיה. שתי הדוגמאות הנ"ל מראות שאפשר לבחור מודלים שונים לאותה הבעיה. טבעי לשאול האם יש מודלים יותר מוצלחים מאחרים, התשובה היא כן. למעשה, נראה בהמשך שאידיאלי יותר לפתור בעיות ללא בחירה של מודל אלא בצורה אריתמטית יותר.

3. רוצים לבחור מספר טבעי חיובי, לשם כך נבחר:

$$\begin{cases} \Omega = \mathbb{N}\setminus\{0\} \\ \mathcal{F} = \mathbb{P}(\Omega) \\ \forall n \in \Omega,\ P(\{n\}) = \left(\frac{1}{2}\right)^n \end{cases}$$

ראשית נוודא כי $P(\Omega) = 1$, אכן:

$$P(\Omega) = P\left(\bigcup_{n=1}^{\infty}\{n\}\right) = \sum_{n=1}^{\infty} P(\{n\}) = \sum_{n=1}^{\infty}\left(\frac{1}{2}\right)^n = \frac{1}{2}\cdot\sum_{n=0}^{\infty}\left(\frac{1}{2}\right)^n = \frac{1}{2}\cdot\frac{1}{1-\frac{1}{2}} = 1$$

כעת נבדוק מה ההסתברות שבחרנו מספר זוגי, כלומר נחשב את ההסתברות של המאורע:

$$A = \{2k \mid\ k = 1, 2, 3, ...\}$$

נחשב:

$$P(A) = P\left(\bigcup_{n=1}^{\infty}\{2n\}\right) = \sum_{n=1}^{\infty} P(\{2n\}) = \sum_{n=1}^{\infty}\left(\frac{1}{2}\right)^{2n} =$$
$$= \sum_{n=1}^{\infty}\left(\frac{1}{4}\right)^n = \frac{1}{4}\cdot\sum_{n=0}^{\infty}\left(\frac{1}{4}\right)^n = \frac{1}{4}\cdot\frac{1}{1-\frac{1}{4}} = \frac{1}{3}$$

האם זה מוזר שההסתברות היא לא חצי? לא! בבחירת מידת ההסתברות יש הטיה לטובת האי־זוגיים, למשל ההסתברות לבחור 1 היא כבר $\frac{1}{2}$.

**הערות**:

**1.** אפשר היה לבחור מידת הסתברות בה ההסתברות של $A$ היא חצי, למשל:

$$P(\{n\}) = \begin{cases} \left(\frac{1}{2}\right)^{\frac{n+1}{2}+1} & ,\quad n\ odd \\ \left(\frac{1}{2}\right)^{\frac{n}{2}+1} & ,\quad n\ even \end{cases}$$

עם זאת, מידת ההסתברות הזאת עדיין מוטה לטובת ערכים קטנים יותר, כלומר יש הסתברות גבוהה יותר לבחור מספרים טבעיים קטנים מאשר גדולים.

**2.** אינטואיטיבית אם היינו בוחרים מרחב שווה הסתברות ההסתברות הייתה אמורה להיות חצי, למה לא עשינו זאת? נבחין שאם לכל $n$ נגדיר $P(\{n\}) = c$ כאשר $c > 0$ אז מתכונת ה־$\sigma$־אדיטיביות:

$$P(\Omega) = P\left(\bigcup_{n=1}^{\infty}\{n\}\right) = \sum_{n=1}^{\infty} P(\{n\}) = \sum_{n=1}^{\infty} c = \infty$$

בסתירה להגדרת מידת ההסתברות. לפיכך לא ניתן לבחור מרחב שווה הסתברות במרחב בן־מניה לא סופי.

4. נניח שרוצים לבחור באופן אקראי (אחיד) מספר ממשי בקטע $[0,1]$. בדומה לחישוב בדוגמה קודמת, חייבים להגדיר $P(\{x\}) = 0$ לכל $x \in [0,1]$. נעיר שלמרות שניתן לרשום $[0,1] = \bigcup_{x\in[0,1]} \{x\}$ אין סתירה לתכונת ה־$\sigma$־אדיטיביות כיוון שמדובר באיחוד שהוא לא בן־מניה. למעשה ההסתברות של כל מאורע שהוא קבוצה סופית או לא סופית אך בת־מניה היא אפס. מכאן כבר רואים שההסתברות של היחידונים לא מספיקה על מנת לקבוע הסתברות של מאורעות שונים. אקראיות הבחירה מתבטאת בעובדה שההסתברות לבחור קטע תלוייה באורך שלו ולא במיקום. כלומר לכל $[a,b] \subseteq [0,1]$ מתקיים $P([a,b]) = \frac{b-a}{1-0} = b-a$.

**הערה**: באופן כללי עבור $\alpha < \beta$ מתקיים שלכל קטע $[a,b] \subset [\alpha,\beta]$ ההסתברות היא $P([a,b]) = \frac{b-a}{\beta-\alpha}$.

### 1.3 תכונות מרחב הסתברות

ננסח ונוכיח תכונות בסיסיות של מידת הסתברות.

**טענה 8.1** יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות.

1. מונוטוניות: אם $A, B \in \mathcal{F}$ מקיימים $A \subseteq B$ אז $P(A) \leq P(B)$.
2. הכלה/הפרדה: אם $A, B \in \mathcal{F}$ אז $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
3. תת־אדיטיביות: לכל $\{A_n\}_{n=1}^k \subseteq \mathcal{F}$ מתקיים $P\left(\bigcup_{n=1}^k A_n\right) \leq \sum_{n=1}^k P(A_n)$.

**הערות:**

1. מכלילים את נוסחת ההכלה/הפרדה למספר סופי של קבוצות (זהה לנוסחה שרואים בקומבינטוריקה).

2. בהוכחת המונוטוניות נסיק את הזהות $P(B \backslash A) = P(B) - P(A \cap B)$. ניעזר בה בהוכחת תכונת ההכלה/הפרדה וכן בהמשך.

**הוכחה:**

1. נבחין כי $B = (B \backslash A) \cup (A \cap B)$ הוא איחוד זר ומההנחה $A \cap B = A$, לכן:

$$P(B) = P(B \backslash A) + P(A \cap B) \geq 0 + P(A)$$

כנדרש.

2. נבחין כי $A\cup B=A\cup(B\backslash A)$ הוא איחוד זר ולכן:

$$P(A\cup B)=P(A)+P(B\backslash A)=P(A)+P(B)-P(A\cap B)$$

כנדרש.

3. נוכיח עבור $k=2$, את המקרה הכללי מראים באינדוקציה. אכן, עבור $k=2$, מנוסחת ההכלה/הפרדה נקבל:

$$P\left(\bigcup_{n=1}^{2}A_n\right)=P(A_1\cup A_2)=P(A_1)+P(A_2)-P(A_1\cap A_2)\leq P(A_1)+P(A_2)=\sum_{n=1}^{2}P(A_n)$$

כנדרש.

■

**דוגמאות:**

1. ליטל מטיילת בחבל אלזס בצרפת והיא סימנה על המפה 4 יקבים שהיא רוצה לבקר בהם (ורק בהם). כל יום היא בוחרת באופן אקראי ובלתי תלוי יקב לבקר בו. ליטל תעזוב את האזור מייד לאחר שתבקר בכל ארבעת היקבים. נחשב את ההסתברות שליטל תעזוב את האזור תוך 15 ימים לכל היותר. נסמן את המאורע הנדרש ב־$B$. המאורע המשלים הוא שליטל עוזבת לאחר 15 ימים והוא מתקיים אם ורק אם במהלך 15 הימים היא לא ביקרה בכל ארבעת היקבים. נסמן ב־$A_n$ את המאורע בו ליטל ביקרה ביקב $n$ במהלך 15 הימים, לכן $B=A_1\cap A_2\cap A_3\cap A_4$. ניתן לחשב בקלות יחסית את המשלים בעזרת הכלה/הפרדה וטעמי סימטריה. ראשית נחשב:

$$\begin{aligned}
\forall n \quad &, \quad P(A_n^c)=\tfrac{3^{15}}{4^{15}}\\
\forall n\neq k \quad &, \quad P(A_n^c\cap A_k^c)=\tfrac{2^{15}}{4^{15}}\\
\forall n\neq k\neq m \quad &, \quad P(A_n^c\cap A_k^c\cap A_m^c)=\tfrac{1^{15}}{4^{15}}\\
&\quad P(A_1^c\cap A_2^c\cap A_3^c\cap A_4^c)=0
\end{aligned}$$

כעת נציב בנוסחה:

$$\begin{aligned}
P(B)&=1-P(A_1^c\cup A_2^c\cup A_3^c\cup A_4^c)=\\
&=1-\binom{4}{1}P(A_1^c)+\binom{4}{2}P(A_1^c\cap A_2^c)-\binom{4}{3}P(A_1^c\cap A_2^c\cap A_3^c)+\binom{4}{4}P(A_1^c\cap A_2^c\cap A_3^c\cap A_4^c)=\\
&\simeq 1-0.053=0.947
\end{aligned}$$

2. בקבוצה יש 200 אנשים, מתוכם 10% עם שיער אדום, 5% עם עיניים ירוקות ו־4% עם שיער אדום ועיניים ירוקות. בוחרים מישהו באופן אקראי, נחשב את ההסתברות שאין לו שיער אדום וגם עיניים ירוקות. נסמן:

$$\begin{array}{ll} A = \{\text{נבחר אדם עם שיער אדום}\} & P(A) = 0.1 \\ & \Rightarrow \\ B = \{\text{נבחר אדם עם עיניים ירוקות}\} & P(B) = 0.05 \end{array}$$

רוצים לחשב את $P(A^c \cap B^c)$, לכן:

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B) =$$
$$= 1 - P(A) - P(B) + P(A \cap B) = 1 - 0.1 - 0.05 + 0.04 = 0.89$$

**הערה**: נבחין כי בשתי הדוגמאות ביצענו חישובים ללא בניה מפורשת של מרחב ההסתברות אלא בעזרת התכונות האריתמטיות של מידת ההסתברות.

## 2 הסתברות מותנית

רוצים לחשב הסתברות של מאורע אחד כתלות באחר.

**דוגמאות:**

1. בהטלת קוביה הוגנת, מה הסיכוי לקבל 2 אם ידוע שהתוצאה היא זוגית? אינטואיטיבית ברור שההסתברות היא $\frac{1}{3}$.

2. בהטלת קוביה הוגנת פעמיים ברצף, מה הסיכוי לקבל 2 בהטלה השניה אם ידוע שבהטלה הראשונה יצא 1? אינטואיטיבית אין תלות בין ההטלות ולכן נצפה שההסתברות תהיה $\frac{1}{6}$.

3. נתון סל עם $b$ כדורים שחורים ו־$w$ לבנים. מוציאים שני כדורים ללא החזרה. מהי ההסתברות שהכדור השני הוא שחור אם ידוע שהכדור הראשון היה שחור? גם כאן אינטואיטיבית ננחש שההסתברות היא $\frac{b-1}{w+b-1}$.

**הגדרה 1.2** יהא $B$ מאורע בעל הסתברות חיובית, אז לכל $A \in \mathcal{F}$ **ההסתברות המותנית** של $A$ בהינתן $B$ היא:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

**הערות:**

1. הפירוש הגיאומטרי של ההגדרה הוא היחס בין ה"שטח" של $A \cap B$ ל"שטח" של $B$, כלומר החלק היחסי של $A$ בתוך $B$.

2. נסיק כי $P(A \cap B) = P(A \mid B)\, P(B)$, זהות זו שימושית במקרה בו ההסתברות המותנית ידועה "באופן טבעי".

**דוגמאות:**

1. בהטלת קוביה הוגנת, מה הסיכוי לקבל 2 אם ידוע שהתוצאה היא זוגית? נסמן ב־$A$ את המאורע שיצא 2 וב־$B$ את המאורע שהתוצאה זוגית. נזכור שמדובר במרחב שווה הסתברות ונחשב לפי ההגדרה:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{|A \cap B|}{|B|} = \frac{|\{2\} \cap \{2,4,6\}|}{|\{2,4,6\}|} = \frac{|\{2\}|}{|\{2,4,6\}|} = \frac{1}{3}$$

2. בהטלת קוביה הוגנת פעמיים ברצף, מה הסיכוי לקבל 2 בהטלה השניה אם ידוע שבהטלה הראשונה יצא 1? נסמן ב־$A$ את המאורע שיצא 2 בהטלה השניה וב־$B$ את המאורע שיצא 1 בהטלה הראשונה. ראשית נבחין כי:

$$\begin{cases} A = \{(n,2) \mid n = 1,...,6\} \\ B = \{(1,n) \mid n = 1,...,6\} \end{cases} \Rightarrow A \cap B = \{(1,2)\}$$

נזכור שמדובר במרחב שווה הסתברות ונחשב לפי ההגדרה:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{|A \cap B|}{|B|} = \frac{1}{6}$$

3. נתון סל עם $b$ כדורים שחורים ו־$w$ לבנים. מוציאים שני כדורים ללא החזרה. נחשב את ההסתברות ששני הכדורים הם שחורים. נסמן ב־$A$ את המאורע שיצא כדור שחור בפעם הראשונה וב־$B$ את המאורע שיצא כדור שחור בפעם השניה. לא נטרח להגדיר את מרחב המדגם, נחשב ישירות:

$$P(A \cap B) = P(A) \cdot P(B \mid A) = \frac{b}{w+b} \cdot \frac{b-1}{w+b-1} = \frac{b^2 - b}{(w+b)(w+b-1)}$$

נעבור כעת לתכונות של הסתברות מותנית. ראשית נוכיח כי הסתברות מותנית היא מידת הסתברות, כלומר:

**משפט 2.2** יהא $B$ מאורע עם הסתברות חיובית, אז $\begin{cases} P_B : \mathcal{F} \to [0,1] \\ P_B(A) = P(A \mid B) \end{cases}$ היא מידת הסתברות.

**הוכחה:** נוכיח את שלושת התכונות:

1. עבור הקבוצה הריקה נקבל:

$$P_B(\phi) = \frac{P(\phi \cap B)}{P(B)} = \frac{0}{P(B)} = 0$$

2. לכל סדרת מאורעות $\{A_n\}_{n=1}^{\infty} \subseteq \mathcal{F}$ זרים בזוגות ברור שגם $\{A_n \cap B\}_{n=1}^{\infty}$ זרים בזוגות, לפיכך:

$$P_B\left(\bigcup_{n=1}^{\infty} A_n\right) = \frac{P\left(\left(\bigcup_{n=1}^{\infty} A_n\right) \cap B\right)}{P(B)} = \frac{P\left(\bigcup_{n=1}^{\infty} (A_n \cap B)\right)}{P(B)} =$$
$$= \frac{\sum_{n=1}^{\infty} P(A_n \cap B)}{P(B)} = \sum_{n=1}^{\infty} \frac{P(A_n \cap B)}{P(B)} = \sum_{n=1}^{\infty} P_B(A_n)$$

3. לכל $A \in \mathcal{F}$ נקבל:

$$P_B(A^c) = \frac{P(A^c \cap B)}{P(B)} = \frac{P(B \backslash A)}{P(B)} = \frac{P(B) - P(A \cap B)}{P(B)} = 1 - P_B(A)$$

■

מהמשפט האחרון נסיק:

**מסקנה 3.2** ההסתברות המותנית $P_B$ מקיימת את אותן התכונות הבסיסיות של $P$.

נרכז בטענה הבאה מספר תכונות נוספות של הסתברות מותנית.

**טענה 4.2** יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות ותהא $B \in \mathcal{F}$ עבורה $P(B) > 0$, אז:

1. לכל $A \in \mathcal{F}$ מתקיים $P_B(A) = 0 \iff P(A \cap B) = 0$.
2. לכל $A \in \mathcal{F}$ מתקיים $P_B(A) = P_B(A \cap B)$.

3. לכל $A \in \mathcal{F}$, אם $P(A \cap B) \neq 0$ אז לכל $C \in \mathcal{F}$ מתקיים $P_B(C \mid A) = P_{A\cap B}(C)$.

4. אם $P$ שוות הסתברות ($\Omega$ סופי) אז $P_B$ שוות הסתברות כמידת הסתברות מעל $B$.

5. (תכונת הכפל) לכל $\{A_k\}_{k=1}^n \in \mathcal{F}$ עבורן $P\left(\bigcap_{k=1}^n A_k\right) \neq 0$ מתקיים:

$$P\left(\bigcap_{k=1}^n A_k\right) = P(A_1) \cdot P(A_2 \mid A_1) \cdot P(A_3 \mid A_1, A_2) \cdots P(A_n \mid A_1, A_2, ..., A_{n-1})$$

**הערה:** נהוג לסמן $P_{A\cap B} = P_{A,B}$ ובאותו האופן $P(C \mid A \cap B) = P(C \mid A, B)$.

**הוכחה:**

1. ישירות מההגדרה $P_B(A) = \frac{P(A\cap B)}{P(B)}$ ולכן $P_B(A) = 0 \iff P(A \cap B) = 0$.

2. לפי ההגדרה:

$$P_B(A) = \frac{P(A \cap B)}{P(B)} = \frac{P((A \cap B) \cap B)}{P(B)} = P_B(A \cap B)$$

3. שוב לפי ההגדרה:

$$P_B(C \mid A) = \frac{P_B(A \cap C)}{P_B(A)} = \frac{\frac{P(A\cap C\cap B)}{P(B)}}{\frac{P(A\cap B)}{P(B)}} = \frac{P(C \cap A \cap B)}{P(A \cap B)} = P_{A\cap B}(C)$$

4. כפי שכבר ראינו, מספיק להוכיח שההסתברות של כל יחידון זהה, ואומנם לכל $\omega \in B$ נקבל:

$$P_B(\{\omega\}) = \frac{P(\{\omega\} \cap B)}{P(B)} = \frac{P(\{\omega\})}{P(B)} = \frac{\frac{|\{\omega\}|}{|\Omega|}}{\frac{|B|}{|\Omega|}} = \frac{1}{|B|}$$

5. מוכיחים באינדוקציה.

■

**דוגמאות:**

1. מסדרים 6 אנשים ממוספרים בשורה. נחשב את ההסתברות שאדם מספר 3 נמצא במקום השלישי אם ידוע שאנשים $1,2$ נמצאים "במקום שלהם". נסמן ב־$A_n$ את המאורע בו אדם $n$ נמצא במקום שלו ונחשב:

$$P_{A_1\cap A_2}\left(A_3\right)=\frac{P\left(A_1\cap A_2\cap A_3\right)}{P\left(A_1\cap A_2\right)}=\frac{\frac{3!}{6!}}{\frac{4!}{6!}}=\frac{1}{4}$$

2. נתונות שתי חפיסות קלפים זהות עם 10 קלפים (שונים). מערבבים את החפיסה השניה באופן אחיד (כלומר כל קלף מתקבל בהסתברות שווה) ומניחים ליד הראשונה. נחשב את ההסתברות ששלושת הקלפים התחתונים בחפיסה השניה זהים לראשונה. נסמן ב־$A_n$ את המאורע בו הקלף ה־$n$ (מלמטה) בחפיסה השניה זהה לקלף ה־$n$ בראשונה. כעת נחשב:

$$P\left(A_1\cap A_2\cap A_3\right)=P\left(A_1\right)\cdot P\left(A_2\mid A_1\right)\cdot P\left(A_3\mid A_1,A_2\right)=\frac{9!}{10!}\cdot\frac{8!}{9!}\cdot\frac{7!}{8!}=\frac{1}{720}\simeq 0.0013$$

### 2.1 נוסחת ההסתברות השלמה ונוסחת בייס

לפעמים יהיה נוח יותר לחשב הסתברות של מאורע בעזרת ממוצע משוקלל של הסתברויות מותנות אשר "מכסות" את כל האפשרויות. באופן מדוייק יותר:

**משפט 5.2** (**נוסחת ההסתברות השלמה**) תהא $\{B_n\}_{n=1}^N$ סדרה של מאורעות זרים בזוגות עם הסתברות חיובית כך שמתקיים $\bigcup_{n=1}^N B_n=\Omega$. אז לכל $A\in\mathcal{F}$ מתקיים:

$$P\left(A\right)=\sum_{n=1}^N P\left(A\mid B_n\right)\cdot P\left(B_n\right)$$

**הערות:**

1. המשפט נכון גם כאשר $N=\infty$.

2. באופן אינטואיטיבי, מחלקים את $\Omega$ למאורעות $\{B_n\}_{n=1}^N$ ואז מחשבים את ההסתברות המותנית היחסית של $A$ בתוך כל חלק.

3. אפשר להחליש את התנאים: במקום זרים בזוגות אפשר לדרוש $P(B_j \cap B_i) = 0$ לכל $i \neq j$ וכן $P\left(\bigcup_{n=1}^{N} B_n\right) = 1$.

**הוכחה:** נחשב:

$$P(A) = P(A \cap \Omega) = P\left(A \cap \left(\bigcup_{n=1}^{N} B_n\right)\right) = P\left(\bigcup_{n=1}^{N} (A \cap B_n)\right) \underset{(*)}{=}$$
$$= \sum_{n=1}^{N} P(A \cap B_n) = \sum_{n=1}^{N} P(A \mid B_n) \cdot P(B_n)$$

$(*)$ נתון כי $\{B_n\}_{n=1}^{N}$ זרים בזוגות ולכן גם $\{A \cap B_n\}_{n=1}^{N}$ זרים בזוגות.

■

**דוגמאות:**

1. נופר משתתפת בהגרלה שוות הסתברות עם $0 \leq k \in \mathbb{N}$ משתתפים נוספים. נסמן ב־$A_n$ את המאורע בו יש $n$ משתתפים נוספים, נתון כי $P(A_n) = \frac{1}{2^{n+1}}$. נחשב את ההסתברות שנופר זוכה. נסמן את המאורע הנ"ל ב־$B$, נבחין שמתקיימים תנאי משפט ההסתברות השלמה ולכן:

$$P(B) = \sum_{n=0}^{\infty} P(B \mid A_n) \cdot P(A_n) = \sum_{n=0}^{\infty} \frac{1}{n+1} \cdot \frac{1}{2^{n+1}} \underset{(*)}{=} \ln 2 \simeq 0.69$$

$(*)$ כזכור מאינפי/חדו"א:

$$\sum_{n=0}^{\infty} \frac{1}{n+1} x^{n+1} = \sum_{n=0}^{\infty} \int_0^x t^n dt = \int_0^x \left(\sum_{n=0}^{\infty} t^n\right) dt = \int_0^x \frac{1}{1-t} dt = \ln \frac{1}{1-t}\Big|_{t=0}^{t=x} = \ln \frac{1}{1-x}$$

נציב $x = \frac{1}{2}$ ונקבל $\sum_{n=1}^{\infty} \frac{1}{n+1} \left(\frac{1}{2}\right)^{n+1} = \ln 2$.

2. נתון כד עם $b > 1$ כדורים שחורים ו־$w$ כדורים לבנים. מוציאים שני כדורים ללא החזרה. נסמן ב־$B_k$ את המאורע שהכדור ה־$k$־י שחור וכנ"ל $W_k$. נחשב את $P(B_2)$:

$$P(B_2) = \mathrm{P}(B_2 \mid B_1) \cdot P(B_1) + \mathrm{P}(B_2 \mid W_1) \cdot P(W_1) = \frac{b-1}{b+w-1} \cdot \frac{b}{b+w} + \frac{b}{b+w-1} \cdot \frac{w}{b+w} = \frac{b}{b+w}$$

נבחין שקיבלנו $P(B_2) = P(B_1)$, כלומר ההסתברות שהכדור השני שחור זהה להסתברות שהכדור הראשון שחור.

**משפט 6.2** (**נוסחת בייס**) יהיו $A, B \in \mathcal{F}$ בעלי הסתברות חיובית, אז $P(B \mid A) = \frac{P(A|B) \cdot P(B)}{P(A)}$.

**הערה:** בשילוב על נוסחת ההסתברות השלמה נקבל את **נוסחת בייס השלמה:** תהא $\{B_n\}_{n=1}^{N}$ סדרה של מאורעות זרים בזוגות עם הסתברות חיובית כך שמתקיים $\bigcup_{n=1}^{N} B_n = \Omega$ (ייתכן $N = \infty$). אז לכל $A \in \mathcal{F}$ מתקיים:

$$\forall n \geq 1, \quad P(B_n \mid A) = \frac{P(A \mid B_n) \cdot P(B_n)}{\sum_{n=1}^{N} P(A \mid B_n) \cdot P(B_n)}$$

**הוכחה:** ישירות מההגדרה:

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)} = \frac{\frac{P(A \cap B)}{P(B)} \cdot P(B)}{P(A)} = \frac{P(A \mid B) \cdot P(B)}{P(A)}$$

■

**דוגמה:** נחזור לדוגמה עם נופר. נניח שידוע שנופר זכתה, נחשב את ההסתברות שהיו 3 משתתפים נוספים. לפי בייס:

$$P(A_3 \mid B) = \frac{P(B \mid A_3) \cdot P(A_3)}{P(B)} = \frac{\frac{1}{4} \cdot \frac{1}{16}}{\ln 2} \simeq 0.022$$

### 2.2 אי־תלות

באופן אינטואיטיבי, נצפה ששני מאורעות יהיו בלתי־תלויים אם הידיעה שאחד התרחש לא משפיעה על ההסתברות שהשני התרחש. באופן פורמלי:

**הגדרה 7.2** נאמר שמאורעות $A, B \in \mathcal{F}$ הם **בלתי־תלויים** אם מתקיים $P(A \cap B) = P(A) \cdot P(B)$.

**הכללה:** תהא $\Gamma \subseteq \mathcal{F}$ משפחה[4] של מאורעות. נאמר ש**המשפחה $\Gamma$ היא בלתי־תלויה** אם לכל $\{A_1, ..., A_n\} \subseteq \Gamma$ שונים מתקיים:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdots P(A_n)$$

**הערות:**

[4] סופית או אינסופית.

1. המשמעות הגיאומטרית (כדאי לצייר דיאגרמת ון) היא שהיחס בין $A$ ל־$\Omega$ זהה ליחס בין $A \cap B$ ל־$B$ (ולהיפך).

2. התלות או אי־תלות של מאורעות היא לא תמיד אינטואיטיבית. נדגיש שאי־תלות לא אומרת שאין כלל קשר בין המאורעות אלא שההסתברות שאחד התרחש לא משפיעה על האחר. נדגים:

**דוגמה**: מטילים פעמיים קוביה הוגנת. יהא $A$ המאורע בו בהטלה הראשונה יצא $4$ ו־$B$ הוא שסכום ההטלות יצא $6$. נבדוק תלות:

$$\begin{cases} P(A) = \frac{1}{6} \\ P(B) = \frac{5}{36} \\ P(A \cap B) = \frac{1}{36} \end{cases} \Rightarrow P(A \cap B) = \frac{1}{36} \neq \frac{1}{6} \cdot \frac{5}{36} = P(A) \cdot P(B)$$

לכן המאורעות תלויים. אם נגדיר את $C$ להיות המאורע בו סכום ההטלות הוא $7$ אז נקבל:

$$\begin{cases} P(A) = \frac{1}{6} \\ P(C) = \frac{6}{36} \\ P(A \cap C) = \frac{1}{36} \end{cases} \Rightarrow P(A \cap C) = \frac{1}{36} = \frac{1}{6} \cdot \frac{6}{36} = P(A) \cdot P(C)$$

כלומר $A, C$ בלתי־תלויים.

3. נבחין שבהכללה לא דרשנו אי־תלות בזוגות, הסיבה היא שאי־תלות בזוגות לא תשקף את מה שרוצים מקבוצה גדולה של מאורעות בלתי־תלויים. נדגים:

**דוגמה**: יהא $\Omega = \{a, b, c, d\}$ מרחב שווה הסתברות ותהא $\Gamma = \{\{a, b\}, \{a, c\}, \{c, b\}\}$. נבחין כי:

$$P(\{a, b\} \cap \{a, c\}) = P\{a\} = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = P(\{a, b\}) \cdot P(\{a, c\})$$

החישוב נכון לכל זוג מאורעות ב־$\Gamma$ ולכן אברי $\Gamma$ בלתי־תלויים בזוגות. עם זאת:

$$P(\{\{a, b\} \cup \{c, b\}\} \cap \{a, c\}) = P\{a, c\} = \frac{1}{2} \neq \frac{3}{4} \cdot \frac{1}{2} = P(\{a, b\} \cup \{c, b\}) \cdot P(\{a, c\})$$

כלומר איחוד שני מאורעות תלוי במאורע אחר, זהו מצב לא רצוי.

תכונה בסיסית היא שהמשלים משמר אי־תלות:

**טענה 8.2** אם $A, B \in \mathcal{F}$ בלתי־תלויים אז גם הזוגות $\{A^c, B^c\}, \{A, B^c\}, \{A^c, B\}$ בלתי תלויים.

**הוכחה:** נוכיח למשל עבור $\{A, B^c\}$. מניחים כי $A, B$ בלתי תלויים ולכן $P(A \cap B) = P(A) \cdot P(B)$, כעת נחשב:

$$P(A \cap B^c) = P(A \backslash B) = P(A) - P(A \cap B) = P(A) - P(A) \cdot P(B) =$$
$$= P(A)(1 - P(B)) = P(A) \cdot P(B^c)$$

■

**דוגמה:** עברי משתתף בשתי הגרלות בלתי תלויות כאשר הסיכוי לזכות בראשונה הוא $0.01$ והסיכוי לזכות בשניה הוא $0.04$. נחשב את ההסתברות שעברי זכה לפחות באחת מההגרלות. נסמן ב־$A$ את המאורע שעברי זכה בהגרלה הראשונה וב־$B$ בשניה. רוצים לחשב את $P(A \cup B)$ או באופן שקול את:

$$P(A \cup B) = 1 - P((A \cup B)^c) = 1 - P(A^c \cap B^c)$$

נתון כי $A, B$ בלתי־תלויים ולכן גם $A^c, B^c$ בלתי־תלויים, מכאן:

$$1 - P(A^c \cap B^c) = 1 - P(A^c) \cdot P(B^c) = 1 - (1 - 0.01) \cdot (1 - 0.04) = 0.0496$$

## 3 הלמה של בורל־קנטלי

נראה כעת שני משפטים חשובים אשר עוסקים בסדרת מאורעות וקובעים תנאים על ההסתברות של מאורעות מתוך סדרה אינסופית.

נתחיל עם טענה על תכונות בסיסיות של סדרת מאורעות ב־$\sigma$־אלגברה.

**טענה 1.3** (**למת הרציפות**) יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות, ותהא $\{A_n\}_{n=1}^{\infty} \subseteq \mathcal{F}$.

1. אם הסדרה עולה, כלומר $A_1 \subseteq A_2 \subseteq \cdots$, אז מתקיים $P\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$.
2. אם הסדרה יורדת, כלומר $A_1 \supseteq A_2 \supseteq \cdots$, אז מתקיים $P\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$.
3. (**$\sigma$־תת־אדיטיביות**) מתקיים $P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n)$, זה נכון גם כאשר הסדרה סופית.

**הערה:** הטענה מכונה למת הרציפות כיוון שהיא עוזרת בהמשך להוכיח תכונות של משתנים מקריים רציפים.

**הוכחה:**

1. נגדיר $A_0=\phi$ ואז לכל $1\leq n$ נגדיר $B_n=A_n\backslash A_{n-1}$. הסדרה $\{B_n\}_{n=1}^{\infty}\subseteq\mathcal{F}$ מקיימת (לפרט):

א. המאורעות זרים בזוגות.

ב. $\bigcup\limits_{n=1}^{\infty}A_n=\bigcup\limits_{n=1}^{\infty}B_n$.

לכן לפי $\sigma$־אדיטיביות נקבל:

$$\begin{aligned}P\left(\bigcup_{n=1}^{\infty}A_n\right)&=P\left(\bigcup_{n=1}^{\infty}B_n\right)=\sum_{n=1}^{\infty}P\left(B_n\right)=\sum_{n=1}^{\infty}\left(P\left(A_n\right)-P\left(A_{n-1}\right)\right)=\\&=\lim_{k\to\infty}\sum_{n=1}^{k}\left(P\left(A_n\right)-P\left(A_{n-1}\right)\right)=\lim_{k\to\infty}\left(P\left(A_k\right)-P\left(A_0\right)\right)=\\&=\lim_{k\to\infty}\left(P\left(A_k\right)-0\right)=\lim_{k\to\infty}P\left(A_k\right)\end{aligned}$$

$(*)$ סכום טלסקופי.

2. נגדיר $\tilde{C}_n=A_n^c$ ונקבל סדרה עולה של מאורעות. לפי דה־מורגן $\left(\bigcup\limits_{n=1}^{\infty}C_n\right)^c=\bigcap\limits_{n=1}^{\infty}A_n$ וסעיף קודם:

$$P\left(\bigcap_{n=1}^{\infty}A_n\right)=1-P\left(\bigcup_{n=1}^{\infty}C_n\right)=1-\lim_{n\to\infty}C_n=1-\left(1-\lim_{n\to\infty}A_n\right)=\lim_{n\to\infty}P\left(A_n\right)$$

3. נגדיר $D_n=\bigcup\limits_{k=1}^{n}A_k$, זוהי סדרה עולה אשר מקיימת $\bigcup\limits_{n=1}^{\infty}A_n=\bigcup\limits_{n=1}^{\infty}D_n$ לכן:

$$P\left(\bigcup_{n=1}^{\infty}A_n\right)=P\left(\bigcup_{n=1}^{\infty}D_n\right)=\lim_{n\to\infty}P\left(D_n\right)$$

מצד שני, לפי תת־אדיטיביות נקבל שלכל $n$ מתקיים:

$$P\left(D_n\right)=P\left(\bigcup_{k=1}^{n}A_k\right)\leq\sum_{k=1}^{n}P\left(A_k\right)\underset{n\to\infty}{\longrightarrow}\sum_{k=1}^{\infty}P\left(A_k\right)$$

ולכן:

$$P\left(\bigcup_{n=1}^{\infty}A_n\right)=\lim_{n\to\infty}P\left(D_n\right)\leq\sum_{n=1}^{\infty}P\left(A_n\right)$$

■

נעבור כעת להגדרת "גבול עליון" של סדרת מאורעות.

**הגדרה 2.3** תהא $\{A_n\}_{n=1}^{\infty}$ סדרת קבוצות אז הקבוצה $\bigcap\limits_{n=1}^{\infty}\left(\bigcup\limits_{j=n}^{\infty}A_j\right)$ הוא קבוצת כל האיברים המופיעים באינסוף קבוצות, כלומר:

$$x \in \bigcap_{n=1}^{\infty}\left(\bigcup_{j=n}^{\infty} A_j\right) \iff x \in A_n \text{ יש אינסוף } n\text{־ים עבורם}$$

נהוג לסמן את הקבוצה הזאת ע"י $\limsup A_i = \bigcap_{n=1}^{\infty}\left(\bigcup_{j=n}^{\infty} A_j\right)$.

**הערות:**

1. אפשר להוכיח פורמלית אך באופן אינטואיטיבי האיחוד $\bigcup_{j=n}^{\infty} A_j$ אומר ש־$x$ נמצא באחת הקבוצות. כאשר מבצעים חיתוך של כל אלה נקבל שלא משנה "כמה רחוק נלך" תמיד נמצא את $x$ באחת הקבוצות.

2. באופן דומה מגדירים $\liminf A_i = \bigcup_{n=1}^{\infty}\left(\bigcap_{j=n}^{\infty} A_j\right)$ המשמעות כאן היא קבוצת כל האיברים המופיעים כמעט בכל הקבוצות, כלומר:

$$x \in \bigcup_{n=1}^{\infty}\left(\bigcap_{j=n}^{\infty} A_j\right) \iff x \in A_n \text{ מתקיים } n > n_0 \text{ כך שלכל } n_0 \text{ קיים}$$

למעשה מחוקי דה־מורגן נקבל:

$$(\limsup A_i)^c = \left(\bigcap_{n=1}^{\infty}\left(\bigcup_{j=n}^{\infty} A_j\right)\right)^c = \bigcup_{n=1}^{\infty}\left(\bigcap_{j=n}^{\infty} A_j^c\right) = \liminf A_i^c$$

**משפט 3.3** (**הלמה הראשונה של בורל־קנטלי**) יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות ותהא $\{A_n\}_{n=1}^{\infty}$ סדרת מאורעות. אם הטור $\sum_{n=1}^{\infty} P(A_n)$ מתכנס אז $P(\limsup A_i) = 0$.

**הוכחה:** נגדיר $B_n = \bigcup_{j=n}^{\infty} A_j$, זוהי סדרה יורדת של מאורעות ולכן:

$$P(\limsup A_n) = P\left(\bigcap_{n=1}^{\infty} B_n\right) = \lim_{n\to\infty} P(B_n)$$

מה־$\sigma$־תת־אדיטיביות נקבל $0 \le P(B_n) = P\left(\bigcup_{j=n}^{\infty} A_j\right) \le \sum_{j=n}^{\infty} A_j$. נתון שהטור $\sum_{n=1}^{\infty} P(A_n)$ מתכנס ולכן זנב הטור $\sum_{j=n}^{\infty} A_j$ שואף לאפס. לפי כלל הסנדוויץ נקבל $\lim_{n\to\infty} P(B_n) = 0$, לפיכך:

$$P(\limsup A_n) = \lim_{n\to\infty} P(B_n) = 0$$

■

**הערה:** אם נחשוב על $\{A_n\}_{n=1}^{\infty}$ כתוצאות של סדרת ניסויים אז המשפט אומר שההסתברות של תוצאות הניסוי המכילות אינסוף מהמאורעות $\{A_n\}_{n=1}^{\infty}$ היא אפס.

**דוגמאות:**

1. מטילים מטבע (הוגן) אחד לאחר מכן מטילים שני מטבעות (הוגנים), לאחר מכן מטילים שלושה מטבעות (הוגנים) וכן הלאה. נגדיר $A_n = \{$ יצא $n$ פעמים פלי בשלב ה־$n$־י $\}$. נבחין כי:

$$\sum_{n=1}^{\infty} P(A_n) = \sum_{n=1}^{\infty} \left(\frac{1}{2}\right)^n = 1$$

אז לפי בורל־קנטלי ההסתברות שהיו אינסוף שלבים בהם כל ההטלות היו פלי היא אפס.

2. נתון כד ריק. בשלב הראשון מכניסים כדור לבן, מוציאים כדור אקראי ומחזירים אותו. בשלב השני מוסיפים $2^2-1$ כדורים שחורים, מוציאים כדור אקראי ומחזירים אותו. ממשיכים באופן זה כך שבשלב ה־$n$־י מוסיפים $n^2-1$ כדורים שחורים, מוציאים כדור אקראי ומחזירים אותו וכן הלאה. מהי ההסתברות שהכדור הלבן הוצא אינסוף פעמים? לשם כך נגדיר $A_n = \{$ יצא כדור לבן בשלב ה־$n$־י $\}$ ונבחין כי שבשלב ה־$n$־י יש $\sum_{k=1}^{\infty} k^2 = \frac{n(n+1)(2n+1)}{6}$ כדורים שאחד מהם לבן והיתר שחורים. לפיכך:

$$P(A_n) = \frac{1}{\frac{n(n+1)(2n+1)}{6}} = \frac{6}{n(n+1)(2n+1)} \leq \frac{6}{n(n+0)(2n+0)} \leq \frac{3}{n^3}$$

מכאן הטור $\sum_{n=1}^{\infty} P(A_n)$ מתכנס (לפי מבחן השוואה). מתקיימים תנאי בורל־קנטלי ולכן ההסתברות שהיו אינסוף שלבים בהם יצא כדור לבן היא אפס.

**משפט 4.3** (**הלמה השניה של בורל־קנטלי**) יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות ותהא $\{A_n\}_{n=1}^{\infty}$ סדרת מאורעות ב"ת. אם הטור $\sum_{n=1}^{\infty} P(A_n)$ מתבדר אז $P(\limsup A_i) = 1$.

**הוכחה:** נגדיר $B_n = \bigcup_{j=n}^{\infty} A_j$, זוהי סדרה יורדת של מאורעות. מאי־תלות ותכונות קודמות, לכל $n < m$ נקבל:

$$P(B_n^c) = P\left(\bigcap_{k=n}^{\infty} A_k^c\right) \leq P\left(\bigcap_{k=n}^{m} A_k^c\right) = (1-P(A_n)) \cdot (1-P(A_{n+1})) \cdots (1-P(A_m))$$

כזכור לכל $x > 0$ מתקיים $1 - x \leq \mathrm{e}^{-x}$, נחסום את המכפלה:

$$(1-P(A_n))\cdot(1-P(A_{n+1}))\cdots(1-P(A_m)) \leq \mathrm{e}^{-P(A_n)}\cdot\mathrm{e}^{-P(A_{n+1})}\cdots\mathrm{e}^{-P(A_m)} = \mathrm{e}^{-\sum_{k=n}^{m} P(A_k)} \xrightarrow[m\to\infty]{} \mathrm{e}^{-\infty} = 0$$

מכאן $0 \leq P(B_n^c) \leq \mathrm{e}^{-\sum_{k=n}^{m} P(A_k)} \xrightarrow[m\to\infty]{} \mathrm{e}^{-\infty} = 0$ לכל $n$, לכן מכלל הסנדוויץ $P(B_n^c) = 0$ ואז $P(B_n) = 1$.
סה"כ נקבל:

$$P(\limsup A_n) = \lim_{n\to\infty} P(B_n) = \lim_{n\to\infty} 1 = 1$$

■

**דוגמאות:**

1. מטילים מטבע (הוגן) ונגדיר $A_n = \{$ יצא פלי בהטלה ה־$n$־ית $\}$. המאורעות בבירור ב"ת, נבחין כי:

$$\sum_{n=1}^{\infty} P(A_n) = \sum_{n=1}^{\infty} \frac{1}{2} = \infty$$

אז לפי הלמה השניה של בורל־קנטלי ההסתברות שהיו אינסוף הטלות בהן יצא פלי היא 1.

2. נחזור לדוגמה עם הכד אך הפעם נוסיף רק כדור שחור אחד בכל פעם. במקרה זה נקבל כי $P(A_n) = \frac{1}{n}$ ולכן הטור $\sum_{n=1}^{\infty} P(A_n)$ מתבדר. גם כאן קל לראות שהמאורעות ב"ת ולכן לפי הלמה השניה של בורל־קנטלי, ההסתברות שהיו אינסוף שלבים בהם יצא כדור לבן היא 1.

**הערה:** מעניין לדעת שאין מספר כדורים שחורים שנוסיף אשר יכול לגרום להסתברות להיות ערך השונה מ־0 או 1. לא נוכל להיכנס לזה בקורס אך זה נובע ממשפט המכונה **חוק $0-1$ של קולמוגורוב**.

3. קוף חרוץ מקליד על מקלדת באופן אקראי וללא הגבלת זמן, מהי ההסתברות שהוא יקליד בשלב כלשהו את הספר Civilization and Its Discontents של ז. פרויד? באופן מפתיע מתברר שהתשובה היא בהסתברות 1. יתרה מזאת, נראה שלא רק שאין סיכוי שהוא לא יקליד את הספר בשלב כלשהו, הוא למעשה מקליד אותו אינסוף פעמים. אכן נסמן ב־$N$ את מספר התווים הכולל בספר ונגדיר סדרת המאורעות:

$$A_n = \{ \text{הקוף מקליד את הספר החל מהתו ה־}n\text{־י ועד לתו ה־}n+N-1\text{־י} \}$$

נבחין שהסדרה הזאת לא מקיימת את תנאי המשפט כיוון שיש תלות (בדקו!). לכן נביט בתת־סדרה $\{A_{1+n\cdot N}\}_{n=0}^{\infty}$ של מאורעות (זהו טריק נפוץ במצבים כאלה, זוהי סדרת מאורעות "מדלגת"). תת הסדרה היא אכן סדרת מאורעות ב"ת. במקלדת סטנדרטית באנגלית יש כ־75 תווים שונים שאפשר לקבל ע"י הקלדה של תו אחד בכל שלב ולכן $P(A_{1+n\cdot N}) = \frac{1}{75^N}$. מכאן $\sum_{n=1}^{\infty} P(A_{1+n\cdot N}) = \sum_{n=1}^{\infty} \frac{1}{75^N} = \infty$. ברור כי $\infty = \sum_{n=1}^{\infty} P(A_{1+n\cdot N}) \leq \sum_{n=1}^{\infty} P(A_n)$ לכן מתקיימים התנאים של הלמה השניה של בורל־קנטלי. לפיכך לא רק שהקוף מקליד בהסתברות 1 את הספר בשלב כלשהו, הוא למעשה מקליד אותו אינסוף פעמים.

## 4 ניסויי ברנולי

דוגמה חשובה בה יש אי־תלות "סדרתית" היא ניסויי ברנולי, נגדיר את המושג באופן פורמלי.

**הגדרה 1.4** סדרת **ניסויי ברנולי** היא סדרה סופית או אינסופית של ניסויים בה מתקיימים התנאים הבאים:

1. בכל ניסוי יש שתי תוצאות אפשריות: הצלחה וכישלון. ההסתברות להצלחה היא <u>תמיד</u> $p \in [0,1]$ וההסתברות לכישלון היא $q = 1 - p$.
2. הניסויים בלתי־תלויים, כלומר אוסף המאורעות[5] $\{A_n\}_{n=1}^{N}$ הוא בלתי־תלוי, כאשר $A_n$ הוא המאורע המתאר הצלחה בניסוי ה־$n$.

**הערות:**

1. ניתן "לעטוף" אפשרויות שונות כהצלחה או כישלון.

   **דוגמה**: אם מטילים קוביה הוגנת $N$ פעמים, אפשר להגדיר הצלחה כהטלה זוגית וכשלון כאי־זוגית.

2. המשמעות של הצלחה יכולה להשתנות מניסוי לניסוי, כל עוד $p$ זהה.

   **דוגמה**: אם מטילים קוביה הוגנת $N$ פעמים, אפשר להגדיר הצלחה בהטלה הראשונה אם יצא $1$ וביתר ההטלות אם יצא $5$.

3. הניסויים לא חייבים להיות זהים, כל עוד $p$ זהה.

   **דוגמה**: מטילים קוביה הוגנת $3$ פעמים ואז מטילים מטבע הוגן פעם אחת. אפשר להגדיר הצלחה בהטלת הקוביה אם יצא מספר זוגי והצלחה בהטלת המטבע אם יצא פלי.

נדגים שתי שאלות חשובות בהקשר של ניסויי ברנולי:

**דוגמאות:**

1. יהא $1 \leq n \in \mathbb{N}$, נחשב את ההסתברות שיהיו בדיוק $k \leq n$ הצלחות בסדרה של $n$ ניסויי ברנולי. נסמן את המאורע המבוקש ב־$A_k$. יש $\binom{n}{k}$ אפשרויות לבחור את הניסויים בהם הייתה הצלחה, לפיכך:

$$P(A_k) = \binom{n}{k} p^k q^{n-k}$$

קיבלנו מידת הסתברות מעל המספרים הטבעיים החיוביים, זוהי **מידת הסתברות בינומית**.

[5] כרגיל, ייתכן ו־$N = \infty$.

2. נחשב את ההסתברות שבסדרה עם $N$ ניסויי ברנולי, ההצלחה הראשונה התרחשה בניסוי ה־$k$־י. נסמן את המאורע המבוקש ב־$B_k$, בבירור:

$$P\left(B_k\right) = pq^{k-1}$$

קיבלנו מידת הסתברות מעל המספרים הטבעיים החיוביים, זוהי **מידת הסתברות גיאומטרית**.

יש מגוון של מידות הסתברות סטנדרטיות אשר עוזרות לפתור בעיות. אפשר להגדיר אותן בצורה דומה לשתי הדוגמאות האחרונות, עם זאת דרך אינטואיטיבית ושימושית יותר היא בעזרת המושג הבא שנלמד שהוא משתנים מקריים.

חלק II

# משתנה מקרי בדיד

רוצים להגדיר פונקציה אשר תתאר תרחישים הסתברותיים רלוונטיים, תגדיר מידת הסתברות מתאימה ותעזור לנו בחישוב הסתברויות.

## 5 הגדרות ותכונות בסיסיות

**הגדרה 1.5** **משתנה מקרי** $X$ הוא פונקציה $X:\Omega\to\mathbb{R}$ כך שלכל $x\in\mathbb{R}$ מתקיים $\{\omega\in\Omega\mid X(\omega)\le x\}\in\mathcal{F}$.

**דוגמה**: נניח כי $\Omega=\{1,2,3,4,5,6\}$ ונגדיר משתנה $X$ המקיים $X(3)=1$ ו־$X(k)=0$ לכל $3\neq k\in\Omega$. אפשר לחשוב על $X$ כאינדיקטור אשר מחזיר $1$ אם בהטלת קוביה יצא $3$ ואפס בכל ערך אחר. בפועל לא נטרח להגדיר את מרחב המדגם.

**הערות:**

1. הדרישה שהקבוצה $\{\omega\in\Omega\mid X(\omega)\le x\}$ היא מאורע היא דרישה "טכנית" ולא נבדוק אותה בקורס.

2. את המאורע $\{\omega\in\Omega\mid X(\omega)\le x\}$ נהוג לסמן בקיצון על־ידי $\{X\le x\}$.

3. לכל $B\subset\mathbb{R}$ מגדירים:

$$P_X(B)=P(X\in B)=P(\{\omega\mid X(\omega)\in B\})$$

זוהי למעשה מידת הסתברות מעל $\mathbb{R}$ והיא מגדירה את **הפילוג** של $X$ (אם לדייק, זוהי מידת הסתברות מעל תת־קבוצה של $\mathbb{R}$). **פונקציית ההסתברות** של $X$ היא $p_X(x)=P_X(X=x)$. פונקציית ההסתברות מכילה את כל המידע ההסתברותי של המשתנה המקרי $X$, הגרף שלה מתאר את **ההתפלגות** של $X$.

4. היתרון הגדול של משתנה מקרי ופונקציית הסתברות הוא שאין (כמעט) צורך לעבוד עם מרחב ההסתברות.

5. נאמר שמשתנה מקרי $X$ **נתמך** בקבוצה $B \subseteq \mathbb{R}$ אם $P_X(B) = 1$, מחוץ לקבוצה הערך הוא תמיד אפס, עם זאת ייתכנו נקודות ב־$B$ בהן $X$ שווה לאפס.. **התומך** של משתנה מקרי $X$ הוא:

$$\cap \{B \mid B \subseteq R,\ P_X(B) = 1\}$$

בפועל התומך של משתנה מקרי הוא תת־הקבוצה "הקטנה ביותר" $B$ עבורה מתקיים $P_X(B) = 1$.

6. נאמר שמשתנה מקרי $X$ הוא **בדיד** אם הוא נתמך על־ידי קבוצה סופית או אינסופית בת־מניה.

7. אם התומך של $X$ הוא נקודה אחת, נניח $\{c\}$ (כלומר $p_X(c) = 1$ ולכל $x \neq c$ מתקיים $p_X(x) = 0$), אז נאמר ש־$X$ הוא משתנה מקרי קבוע או **דטרמיניסטי**.

**דוגמה:** נחזור לדוגמה קודמת. נרשום מפורשות את המאורעות הרלוונטיים:

$$\begin{cases} \{X = 1\} = \{\omega \in \Omega \mid X(\omega) = 1\} = \{3\} \\ \{X = 0\} = \{\omega \in \Omega \mid X(\omega) = 0\} = \{1, 2, 4, 5, 6\} \end{cases}$$

בהנחה שמדובר בקוביה הוגנת, פונקציית ההסתברות של $X$ היא:

$$p_X(x) = P_X(X = x) \begin{cases} \frac{1}{6} & , \quad x = 1 \\ \frac{5}{6} & , \quad x = 0 \\ 0 & , \quad otherwise \end{cases}$$

במקרה זה $X$ נתמך בקבוצה $\{0, 1\}$, הקבוצה סופית ולכן המשתנה בדיד.

נראה כעת תכונות של משתנה מקרי.

**טענה 2.5** יהא $X$ משתנה מקרי.

1. פרט למספר סופי או אינסופי בן־מניה של $x$־ים מתקיים $p_X(x) = 0$.
2. $X$ בדיד $\iff \sum_{x \in \mathbb{R}} p_X(x) = 1$.
3. אם $X$ בדיד אז לכל $B \subseteq \mathbb{R}$ מתקיים $P(X \in B) = \sum_{x \in B} p_X(x)$,

**הערה:** מהסעיף הראשון בטענה נובע שהביטוי $\sum_{x\in\mathbb{R}} p_X(x)$ מוגדר היטב. מדוע? ובכן יש כאן שתי "בעיות". הראשונה היא שלא למדנו מה זה סכום אינסופי של מספרים כאשר מספר הגורמים הוא לא בן־מניה. השנייה היא שאולי יש תלות בסדר הסכימה. ובכן לפי הטענה יש מספר בן־מניה לכל היותר. זה פותר את הבעיה הראשונה. לגבי השניה, כל הגורמים בסכום הם אי־שליליים. לכן אם הטור מתכנס אז לפי משפט באינפי/חדו"א אין חשיבות לסדר הסכימה (בניגוד למקרה בו טור מתכנס בתנאי ואז אין חילופיות).

**הוכחה:**

1. נסמן $A_n = \left\{x\in\mathbb{R} \mid p_X(x) > \frac{1}{n}\right\}$ לכל $1 \le n \in \mathbb{N}$ ונבחין שקבוצת כל ה־$x$־ים עבורם $p_X(x) \neq 0$ שווה לקבוצה $\bigcup_{n=1}^{\infty} A_n$. לכן מספיק להוכיח כי $\bigcup_{n=1}^{\infty} A_n$ היא סופית או אינסופית בת־מניה. נוכיח כי כל $A_n$ היא סופית ומכאן ינבע שהאיחוד הוא סופי או אינסופי בן־מניה. ניקח $A_n$ ונניח בשלילה שהיא לא סופית, אז יש בה $n+1$ איברים שונים $\{x_1, ..., x_{n+1}\}$. נבחין כי:

$$1 \ge P(X \in \{x_1, ..., x_{n+1}\}) = \sum_{k=1}^{n+1} P(X = x_k) \ge \sum_{k=1}^{n+1} \frac{1}{n} = \frac{n+1}{n} > 1$$

וזאת סתירה.

2. $\Leftarrow$: נניח כי $X$ בדיד, לכן התומך של $X$ הוא סופי או בן־מניה. נסמן את התומך על־ידי[6] $\{x_k\}_{k=1}^{N}$ ונחשב:

$$\sum_{x\in\mathbb{R}} p_X(x) = \sum_{k=1}^{N} p_X(x_k) = 1$$

$\Rightarrow$: תהא $A = \{x \mid p_X(x) \neq 0\}$. לפי סעיף קודם $A$ סופית או בת־מניה, לכן:

$$\sum_{x\in A} p_X(x) = \sum_{x\in\mathbb{R}} p_X(x) = 1$$

כלומר התומך של $X$ הוא $A$ שהיא בת־מניה, בפרט $X$ בדיד.

3. יהא $A$ התומך של $X$. מניחים כי $X$ בדיד ולכן $A$ בת־מניה. כעת לכל $B \subseteq \mathbb{R}$ נסמן[7] $B \cap A = \{b_k\}_{k=1}^{N}$ ונחשב:

$$P(X \in B) \underset{(*)}{=} P(X \in B \cap A) = \sum_{k=1}^{N} p_X(x_k) \underset{(\triangle)}{=} \sum_{x\in B} p_X(x)$$

$(*)$ הרי לכל $x \in A^c$ מתקיים $p_X(x) = 0$. באופן מדוייק יותר לכל $D \subseteq A^C$ מתקיים $P(X \in D) \le P(X \in A^c) = 0$.

$(\triangle)$ לכל $x \in B \backslash A$ מתקיים $p_X(x) = 0$.

■

[6] ייתכן כי $N = \infty$.

[7] שוב, ייתכן כי $N = \infty$, כמו כן מספור האיברים הוא אקראי.

# 6 פילוגים בדידים מרכזיים

### פילוג אחיד

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **אחיד** אם $X$ מקבל מספר סופי של ערכים בהסתברות שווה. באופן מפורש, אם $X$ מקבל $n$ ערכים $\{x_1, ..., x_n\}$ אז $p_X(x_k) = \frac{1}{n}$ לכל $k = 1, ..., n$. במקרה זה התומך של $X$ הוא $\{x_1, ..., x_n\}$. ומסמנים $X \sim \mathbf{U}\{x_1, ..., x_n\}$. הגרף של $p_X$ הוא:

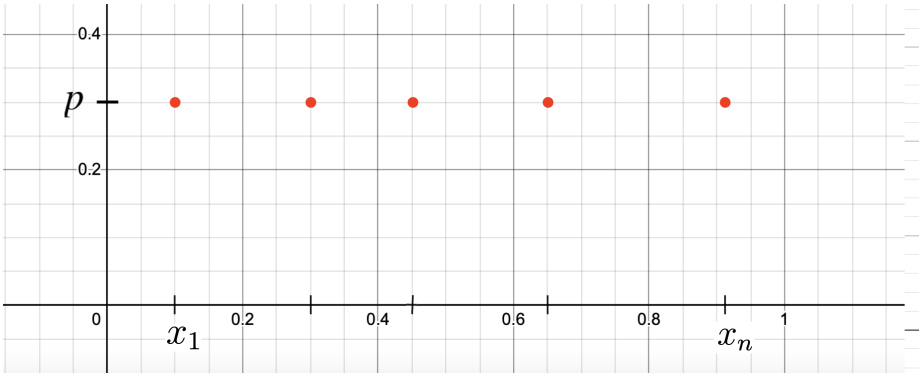


**הערה:** לא נהוג לצייר את הנקודות של $p_X$ אשר לא נמצאות בתומך.

**דוגמה:** אם $X$ מייצג ערך בהטלה של קוביה הוגנת אז $X \sim \mathrm{U}\{1, ..., 6\}$.

### פילוג ברנולי

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **ברנולי** אם $X$ מייצג הצלחה בניסוי ברנולי. באופן מפורש, נניח שנתון ניסוי אחד עם פרמטר הצלחה $p$. נגדיר משתנה $X$ המקיים $X = 1$ במקרה של הצלחה ו־$X = 0$ במקרה של כשלון, כלומר $p_X(1) = p$, $p_X(0) = q = 1 - p$ (נהוג לומר ש־$X$ הוא אינדיקטור המציין הצלחה). במקרה זה התומך של $X$ הוא $\{0, 1\}$. ומסמנים $X \sim \mathbf{Bern}(p)$. הגרף של $p_X$ הוא:

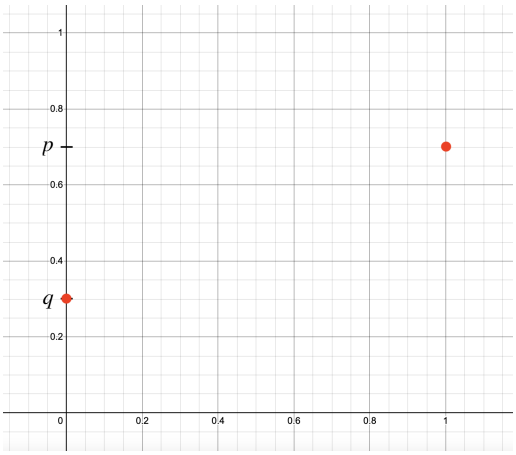

**פילוג בינומי**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **בינומי** אם $X$ מייצג את מספר ההצלחות מתוך סדרה סופית של ניסויי ברנולי. באופן מפורש, נניח שנתונים $n$ ניסויי ברנולי עם פרמטר הצלחה $p$, נסמן ב־$X$ את מספר ההצלחות. ראינו שלכל $0 \le k \le n$ שלם מתקיים $p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}$. במקרה זה התומך של $X$ הוא $\{0,1,2,3,...,n\}$, מסמנים $X \sim \mathbf{Bin}(n,p)$. הגרף של $p_X$ עבור $n=10,\ p=\frac{1}{2}$ הוא:

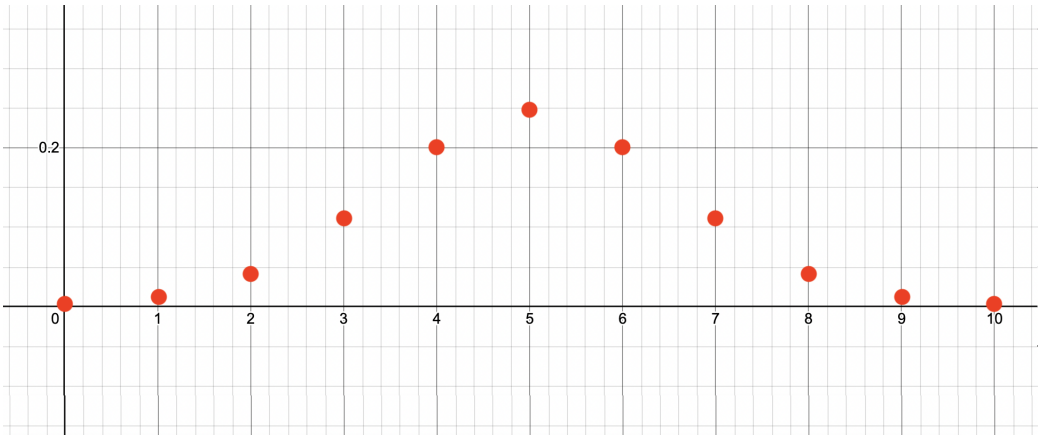


**דוגמאות:**

1. מטילים קוביה הוגנת 10 פעמים. נחשב את ההסתברות שיצא 1 לפחות 8 פעמים. נסמן ב־$X$ את מספר הפעמים שיצא 1, רוצים לחשב את $P(X \ge 8)$:

$$P(X \ge 8) = P(X=8) + P(X=9) + P(X=10) =$$
$$= \binom{10}{8} \cdot \left(\frac{1}{6}\right)^8 \cdot \left(\frac{5}{6}\right)^2 + \binom{10}{9} \cdot \left(\frac{1}{6}\right)^9 \cdot \left(\frac{5}{6}\right)^1 + \binom{10}{10} \cdot \left(\frac{1}{6}\right)^{10} \cdot \left(\frac{5}{6}\right)^0 =$$
$$= 45 \cdot \frac{5^2}{6^{10}} + 10 \cdot \frac{5}{6^{10}} + 1 \cdot \frac{1}{6^{10}} \simeq 0.00002$$

2. ידוע שמנוע של מטוס מתקלקל בהסתברות של $1-p=q \in (0,1)$, כמו כן מטוס מסוגל לנחות בבטחה אם לפחות חצי ממנועיו תקינים. נמצא טווח ערכים של $p$ אשר ביחס אליהם עדיף לנו מטוס עם 4 מנועים ולא 2 מנועים. נגדיר משתנה מקרי $X_2$ להיות מספר המנועים התקינים במטוס עם שני מנועים וב־$X_4$ את מספר המנועים התקינים במטוס עם 4 מנועים. מהנתון סביר להניח $X_2 \sim \mathrm{Bin}(2,p)\,,\ X_4 \sim \mathrm{Bin}(4,p)$. יהא $A_2$ המאורע בו מטוס עם שני מנועים נוחת בבטחה ויהא $A_4$ המאורע בו מטוס עם ארבעה מנועים נוחת בבטחה.

נחשב:

$$P(A_2) = P_{X_2}(X_2 \in \{1,2\}) = \binom{2}{1} p(1-p) + \binom{2}{2} p^2 (1-p)^0 = p(2-p)$$

$$P(A_4) = P_{X_4}(X_4 \in \{2,3,4\}) = \sum_{k=2}^{4} \binom{4}{k} p^k (1-p)^{4-k} = p^2(3p^2 - 9p + 6)$$

רוצים למצוא את ערכי $p$ עבורם $P(A_2) < P(A_4)$, נחשב:

$$P(A_2) < P(A_4) \iff p(2-p) < p^2(3p^2 - 9p + 6) \iff 0 < p(p-1)^2(3p-2)$$

נסיק שעדיף מטוס עם 4 מנועים כאשר $\frac{2}{3} < p$. בין היתר ניתן להסיק שאם יש סיכוי גבוה לתקלות (באופן מדוייק יותר $\frac{1}{3} \leq q$) אז עדיף פחות מנועים.

**פילוג בינומי שלילי**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **בינומי שלילי** אם $X$ מייצג את מספר הכשלונות לפני הצלחה מספר $1 \leq r$ בסדרה אינסופית של ניסויי ברנולי עם פרמטר הצלחה $p$. במקרה זה התומך של $X$ הוא $\{0,1,2,3,...\}$, לכל $0 \leq k \in \mathbb{N}$ מתקיים:

$$p_X(k) = P(X = k) = \binom{k+r-1}{r-1} p^r \cdot (1-p)^k$$

מסמנים $X \sim \mathbf{NB}(r,p)$. הגרף של $p_X$ עבור $r = 5$, $p = \frac{3}{4}$ הוא:

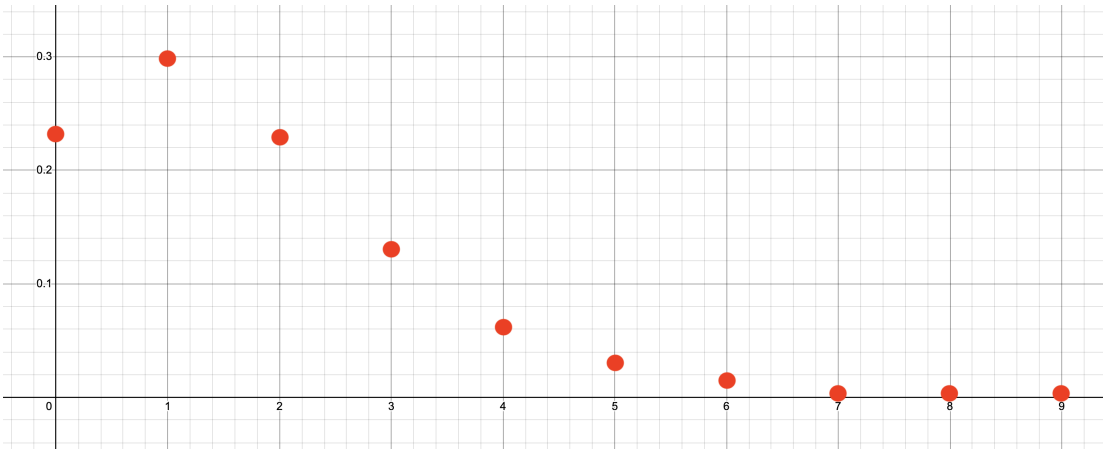


**הערות:**

1. מזהויות הבינום מתקיים $\binom{k+r-1}{k} = \binom{k+r-1}{k+r-1-(r-1)} = \binom{k+r-1}{r-1}$ לכן לפעמים רושמים גם $p_X(k) = \binom{k+r-1}{k} p^r \cdot (1-p)^k$.

2. הסיבה לשם בינומי שלילי נעוצה בחישוב הבא:

$$\binom{k+r-1}{k} = \frac{(r+k-1)!}{k! \cdot (r-1)!} = \frac{r \cdot (r+1) \cdots (r+k-1)}{k!} =$$
$$= \frac{(-r) \cdot (-r-1) \cdots (-r-k+1)}{k!} (-1)^k = (-1)^k \binom{-r}{k}$$

3. לפעמים מגדירים פילוג בינומי שלילי על־ידי ספירת ההצלחה ה־$r$־ית, כלומר מגדירים משתנה $Y$ מתאר את מספר הניסוי בו התרחשה הצלחה מספר $0 \leq r \in \mathbb{N}$. נבחין כי ערכי $Y$ האפשריים הם $\{r, r+1, r+2, ...\}$. עבור $Y$ כזה המשתנה $X = Y - r$ מתאר את מספר הכישלונות לפני הצלחה מספר $r$.

**פילוג גיאומטרי**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **גיאומטרי** אם $X$ מייצג את מספר הניסוי בו התרחשה ההצלחה הראשונה מתוך סדרה אינסופית של ניסויי ברנולי. באופן מפורש, בהינתן שיש סדרה אינסופית של ניסויי ברנולי עם פרמטר הצלחה $p$, נסמן ב־$X$ את מספר הניסוי בו התרחשה ההצלחה הראשונה. ראינו לכל $1 \leq k$ מתקיים $p_X(k) = p \cdot (1-p)^{k-1}$. במקרה זה התומך של $X$ הוא $\{1, 2, 3, ...\}$, מסמנים $X \sim \mathbf{Geom}(p)$. הגרף של $p_X$ עבור $p = \frac{1}{2}$ הוא:

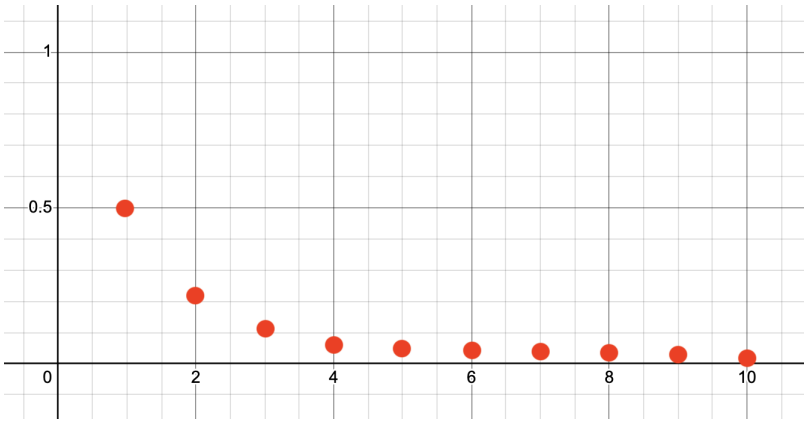

**הערה**: יהא $X$ משתנה המקבל רק ערכים טבעיים חיוביים. ישירות מההגדרה מראים כי:

$$g(n) = (g(1))^n \text{ מקיימת } g(n) = P(X > n) \text{ הפונקציה } \iff X \sim \mathbf{Geom}(p)$$

**דוגמה**: נתונה סדרה אינסופית של ניסויי ברנולי עם פרמטר הצלחה $p$. נחשב את ההסתברות שההצלחה הראשונה מתרחשת בניסוי זוגי. נסמן ב־$X$ את ההצלחה הראשונה, אז $X \sim \mathrm{Geom}(p)$. כעת נחשב:

$$p_X(\{2,4,6,...\}) = \sum_{k=1}^{\infty} p_X(2k) = \sum_{k=1}^{\infty} p \cdot (1-p)^{2k-1} = p \cdot (1-p) \sum_{k=1}^{\infty} \left((1-p)^2\right)^{k-1} =$$
$$= p \cdot (1-p) \sum_{k=0}^{\infty} \left((1-p)^2\right)^{k} = p \cdot (1-p) \frac{1}{1-(1-p)^2} = \frac{1-p}{2-p}$$

**פילוג היפרגיאומטרי**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **היפרגיאומטרי** עם פרמטרים $n, N, D$ אם $X$ סופר את מספר ההצלחות ב־$n$ הניסויים הראשונים מתוך $N$ כאשר בכל סדרת הניסויים היו $D$ הצלחות פוטנציאליות. לדוגמה נניח שנתון כד עם $D$ כדורים שחורים ו־$N-D$ כדורים לבנים. מוציאים $n$ כדורים ללא החזרה ונסמן ב־$X$ את מספר הכדורים השחורים שהוצאנו. נבחין שאם $N-D < n$ אז יהיו לפחות $n-(N-D)$ כדורים שחורים. מצד שני אם $D < n$ אז יהיו לכל היותר $D$ כדורים שחורים. נסיק שערכי $X$ האפשריים הם $k \in \mathbb{Z}$ עבורם $\max\{0, n-(N-D)\} \le k \le \min\{n, D\}$. מכאן:

$$p_X(k) = \frac{\binom{D}{k} \cdot \binom{N-D}{n-k}}{\binom{N}{n}}$$

במקרה זה התומך של $X$ הוא $\{\max\{0, n-(N-D)\}, ..., \min\{n, D\}\}$, מסמנים $X \sim \mathbf{HG}(n, N, D)$. הגרף של $p_X$ עבור $n = 10,\ N = 30,\ D = 20$ הוא:

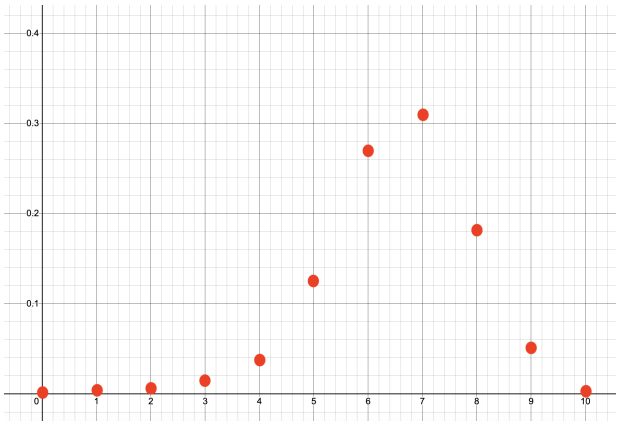

**הערה:** לכל $0 \le m \in \mathbb{N}$ נהוג לסמן $\begin{pmatrix} m \\ x \end{pmatrix} = 0$ לכל $x \notin \{0, 1, ..., m\}$ ואז לכל $x \in \mathbb{R}$ רושמים:

$$p_X(x) = \frac{\begin{pmatrix} D \\ x \end{pmatrix} \cdot \begin{pmatrix} N-D \\ n-x \end{pmatrix}}{\begin{pmatrix} N \\ n \end{pmatrix}}$$

**פילוג פואסון**

הפילוגים שראינו עד כה היו אינטואיטיבים. מייד נראה פילוג שאולי לא ברור מאיפה הוא הגיע אך הוא יעזור לנו ברמה החישובית ולמעשה יהווה "גבול" של הפילוג הבינומי. נתחיל עם דוגמה לשם המוטיבציה.

**דוגמה:** לחברה יש $10^6$ לקוחות. ההסתברות שלקוח יתקשר ביום נתון היא $p = 10^{-6}$, אין תלות בין הלקוחות. נסמן ב־$X$ את מספר הלקוחות שהתקשרו ביום נתון, אז $X \sim \text{Bin}(10^6, 10^{-6})$. נניח שרוצים לחשב את ההסתברות שביום מסויים התקשרו בדיוק 5 לקוחות. נחשב:

$$p_X(5) = \begin{pmatrix} 10^6 \\ 5 \end{pmatrix} \cdot (10^{-6})^5 \cdot (1-10^{-6})^{10^6-5} = \frac{1000000!}{5! \cdot 999995!} \cdot \frac{1}{10^{30}} \cdot \left(\frac{999999}{1000000}\right)^{999995}$$

גם עם שימוש במחשב, לא סביר לחשב את הערך הזה... הפתרון יבוא מהכיוון של מושג הגבול שראינו באינפי/חדו"א.

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **פואסון** עם פרמטר $\lambda > 0$ אם $X$ מתאר את ההסתברות שיתרחשו $k$ אירועים בלתי־תלויים בזמן הפרופורציוני לפרמטר $\lambda$. פונקציית ההסתברות היא $p_X(k) = e^{-\lambda}\frac{\lambda^k}{k!}$ כאשר $0 \le k \in \mathbb{N}$. התומך של $X$ הוא $\{0, 1, 2, 3, ...\}$, מסמנים $X \sim \textbf{Pois}(\lambda)$. הגרף של $p_X$ עבור $\lambda = 2$ הוא:

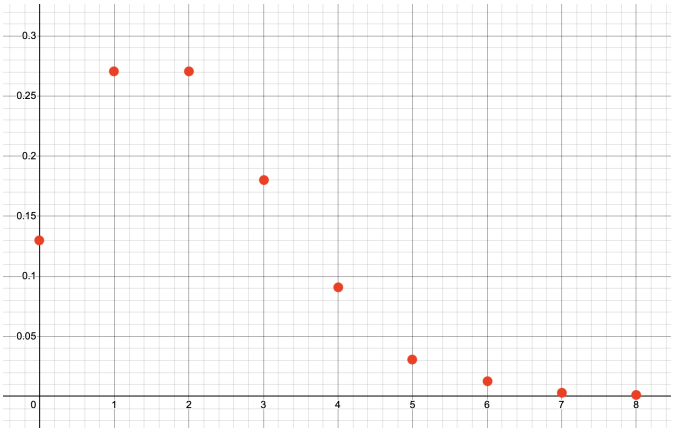

**הערה:** ההגדרה ופונקציית ההסתברות לא "הגיעו" בצורה טבעית כמו הפילוגים הקודמים ולכן לשם השקט הנפשי נוודא את אחד התנאים המרכזיים של פונקציית הסתברות, כלומר נוודא כי $\sum_{x\in\mathbb{R}} p_X(x) = 1$. אכן:

$$\sum_{x\in\mathbb{R}} p_X(x) = \sum_{k=0}^{\infty} p_X(k) = \sum_{k=0}^{\infty} \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!} = \mathrm{e}^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = \mathrm{e}^{-\lambda}\cdot\mathrm{e}^{\lambda} = 1$$

כעת נראה את הקשר לפילוג בינומי.

**משפט 1.6** תהא $\{p_n\}$ סדרה המקיימת $\lim_{n\to\infty} n\cdot p_n = \lambda > 0$, אז לכל $0 \le k \in \mathbb{N}$ מתקיים:

$$\lim_{n\to\infty}\binom{n}{k}\cdot p_n^k\cdot(1-p_n)^{n-k} = \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}$$

**הוכחה:** ראשית מאריתמטיקה נסיק:

$$\lim_{n\to\infty} p_n = \lim_{n\to\infty}\frac{n\cdot p_n}{n} = 0$$

בשילוב עם אריתמטיקה וגבולות ידועים נקבל:

$$\begin{aligned}
\binom{n}{k}\cdot p_n^k\cdot(1-p_n)^{n-k} &= \frac{n!}{k!\cdot(n-k)!}\cdot p_n^k\cdot\frac{(1-p_n)^n}{(1-p_n)^k} = \\
&= \frac{n\cdot(n-1)\cdots(n-k+1)}{k!}\cdot\frac{n^k\cdot p_n^k}{n^k}\cdot\frac{(1-p_n)^n}{(1-p_n)^k} = \\
&= \frac{1}{k!}\cdot\frac{n\cdot(n-1)\cdots(n-k+1)}{n^k}\cdot\frac{(n\cdot p_n)^k}{(1-p_n)^k}\cdot(1-p_n)^n = \\
&= \frac{(n\cdot p_n)^k}{(1-p_n)^k\cdot k!}\cdot\frac{n\cdot(n-1)\cdots(n-k+1)}{n^k}\cdot\left[(1-p_n)^{\frac{1}{p_n}}\right]^{n\cdot p_n} \xrightarrow[n\to\infty]{} \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}
\end{aligned}$$

■

**מסקנה 2.6** עבור $n$ גדול מספיק ו־$p$ קטן מספיק נקבל $\mathrm{Bin}(n,p) \approx \mathrm{Pois}(np)$.

**הערה:** הרעיון הוא שככל ש־$n$ גדול יותר, הקירוב יהיה טוב יותר. עם זאת אין לנו דרך לכמת זאת כרגע.

**הוכחה:** יהא $\varepsilon > 0$, מהגדרת הגבול עבור $n$ "גדול מספיק" מתקיים:

$$\left| \binom{n}{k} \cdot p_n^k \cdot (1-p_n)^{n-k} - \mathrm{e}^{-\lambda} \frac{\lambda^k}{k!} \right| < \varepsilon$$

לכן עבור $p \simeq p_n$ ו־$np \simeq \lambda$ אם ניקח $X \sim \mathrm{Bin}(n,p)$ ו־$Y \sim \mathrm{Pois}(\lambda)$ אז:

$$|p_X(k) - p_Y(k)| < \varepsilon$$

כלומר $X(k) \simeq Y(k)$ כנדרש.

■

**דוגמה:** נחזור לדוגמה הקודמת. ראינו כי:

$$p_X(5) = \frac{1000000!}{5! \cdot 999995!} \cdot \frac{1}{10^{30}} \cdot \left( \frac{999999}{1000000} \right)^{999995}$$

ניעזר במשפט על מנת לקבל קירוב. מתקיים $X \sim \mathrm{Bin}(10^6, 10^{-6}) \approx \mathrm{Pois}(10^6 \cdot 10^{-6}) = \mathrm{Pois}(1)$, לפיכך:

$$p_X(5) \simeq \mathrm{e}^{-1} \frac{1^5}{5!} = \frac{1}{120 \cdot \mathrm{e}} \simeq 0.003$$

## 7 תכונת חוסר הזיכרון

למשתנה גיאומטרי יש תכונה מעניינת אשר נקראת חוסר זיכרון המאפיינת אותו. המשמעות היא שאם ממתינים להצלחה הראשונה וכבר היו "הרבה" ניסויים, זה לא מגביר או מפחית את ההסתברות להצלחה בניסוי הבא.

**דוגמה:** נניח כי $X$ מתאר את הפעם הראשונה שקיבלנו מוצר פגום בפס ייצור. נגדיר $Y$ להיות הפעם הראשונה שיצא מוצר פגום אחרי $1 \leq m \in \mathbb{N}$ מוצרים תקינים, אז $X, Y$ מפולגים זהה.

באופן פורמלי:

**הגדרה 1.7** יהא $X$ משתנה מקרי המקבל ערכים טבעיים. נאמר כי ל־$X$ יש את תכונת **חוסר הזיכרון** אם:

$$\forall k, n \in \mathbb{N},\ P(X > n+k \mid X > n) = P(X > k)$$

**הערה:** ניסוח שקול הוא $P(X = n+k \mid X > n) = P(X = k)$ לכל $k, n \in \mathbb{N}$.

**משפט 2.7** יהא $X$ משתנה מקרי המקבל ערכים טבעיים, אז:

$$X \sim \mathrm{Geom}\left(p\right),\ p \in (0,1) \iff \text{יש ל־}X\text{ את תכונת חוסר הזיכרון}$$

**הוכחה:**

$\Leftarrow$: יהיו $k,n \in \mathbb{N}$, נבחין כי $P\left(X>n\right)=\left(1-p\right)^n$ ולכן:

$$P\left(X>n+k \mid X>n\right)=\frac{P\left(\{X>n+k\}\cap\{X>n\}\right)}{P\left(X>n\right)}=$$
$$=\frac{P\left(X>n+k\right)}{P\left(X>n\right)}=\frac{\left(1-p\right)^{n+k}}{\left(1-p\right)^n}=\left(1-p\right)^k=P\left(X>k\right)$$

$\Rightarrow$: אם $X$ מקיים את תכונת חוסר הזיכרון אז:

$$\frac{P(X>n+k)}{P(X>n)}=\frac{P(\{X>n+k\}\cap\{X>n\})}{P(X>n)}=P\left(X>n+k \mid X>n\right)=P\left(X>k\right)$$
$$\Downarrow$$
$$P\left(X>n+k\right)=P\left(X>n\right)\cdot P\left(X>k\right)$$

נסמן $g\left(n\right)=P\left(X>n\right)$ ונקבל $g\left(n+k\right)=g\left(n\right)\cdot g\left(k\right)$. לפיכך:

$$\forall n\in\mathbb{N},\ g\left(n\right)=g\left(1+\cdots+1\right)=\left(g\left(1\right)\right)^n$$

כלומר $X\sim\mathrm{Geom}\left(1-g\left(1\right)\right)$.

■

**דוגמה:** אמה מחכה לאוטובוס. ההסתברות שיהיה מקום פנוי באוטובוס היא $p=\frac{1}{6}$ וידוע שהאוטובוסים לא תלויים אחד בשני. נחשב את ההסתברות שאמה עולה על האוטובוס החמישי שהגיע אם ידוע שהיא לא עלתה על השניים הראשונים. נסמן ב־$X$ את מספר האוטובוסים שהגיעו עד שאמה עלתה על אוטובוס (כולל האחרון). ברור כי $X\sim\mathrm{Geom}\left(\frac{1}{6}\right)$, מתכונת חוסר הזיכרון:

$$P\left(X=5 \mid X>2\right)=P\left(X=3\right)=\frac{1}{6}\cdot\left(\frac{5}{6}\right)^2=\frac{25}{6^3}\simeq 0.115$$

## 8 טרנספורמציה של משתנה מקרי

ישירות מההגדרה נובע שאם $X$ משתנה מקרי אז לכל פונקציה ממשית $h$ גם $Y=h\left(X\right)$ הוא משתנה מקרי.

**דוגמאות:**

1. נתונה סדרה אינסופית של ניסויי ברנולי עם פרמטר הצלחה $p$ ונסמן ב־$X$ את מספר הכישלונות לפני הצלחה מספר $r$. כעת עבור $h(t) = t + r$ מתקיים $Y = h(X) = X + r$. נבחין שכבר ראינו את הדוגמה הנ"ל, $Y$ למעשה מסמן את מספר הניסוי בו התרחשה ההצלחה מספר $1 \leq r \in \mathbb{N}$.

2. נניח כי $X$ מתאר גובה של אנשים במילימטרים. ניקח $h(t) = \frac{t}{10}$ ואז $Y = h(X)$ הוא משתנה המתאר את הגובה בסנטימטרים. אפשר בנוסף להגדיר $g(t) = \lfloor t \rfloor$ ואז $Z = g(Y)$ מתאר את הגובה בסנטימטרים שלמים אשר מעוגלים כלפי מטה.

במקרים בהם $h$ היא חח"ע קל לחשב את פונקציית ההסתברות של המשתנה המתקבל מהטרנספורמציה.

**טענה 1.8** יהא $X$ משתנה מקרי בדיד ותהא $h : \mathbb{R} \to \mathbb{R}$ חח"ע, אז $Y = h(X)$ הוא משתנה מקרי בדיד ופונקציית ההסתברות שלו היא $p_Y(y) = p_X(h^{-1}(y))$.

**הערות:**

1. לכל $y \notin \operatorname{Im} h$ מתקיים $p_Y(y) = 0$.

2. במקרה בו $h$ לא חח"ע מתקיים $p_Y(y) = \sum_{x \in h^{-1}(y)} p_X(x)$.

**הוכחה:** ראשית $X$ בדיד ולכן עם תומך בן־מניה[8] $\{x_k\}_{k=1}^N$. לכן לפי הגדרת $Y$ התומך של $Y$ הוא $\{h(x_k)\}_{k=1}^N$, כלומר התומך סופי או אינסופי בן־מניה ולכן $Y$ בדיד. ניקח $y \in \mathbb{R}$ ונבחין בין שני מקרים:

1. $y \notin \{h(x_k)\}_{k=1}^N$: במקרה זה מהחח"ע של $h$ נקבל $\{Y = y\} \subseteq \{X \neq x_n \mid n = 1, ..., N\}$, כלומר הכלה בין המאורעות, לכן ממונוטוניות:

$$0 \leq p_Y(y) = P(Y = y) \leq P(\{X \neq x_n \mid n = 1, ..., N\}) = 0$$

כלומר $p_Y(y) = 0$.

[8] כרגיל $N \in \mathbb{N}$ או $N = \infty$.

2. $y \in \{h(x_k)\}_{k=1}^{N}$: נניח $y = h(x_n)$ אז $Y = y$ אם ורק אם $h(X) = h(x_n)$. מניחים כי $h$ חח"ע ולכן זה שקול ל־$X = x_n$, מכאן:

$$p_Y(y) = P(Y = y) = P(X = x_n) = p_X(x_n) = p_X\left(h^{-1}(y)\right)$$

■

**דוגמאות:**

1. נניח כי $X$ מתאר גובה של אנשים במילימטרים. ניקח $h(t) = \frac{t}{10}$ ואז $Y = h(X)$ הוא משתנה המתאר את הגובה בסנטימטרים. ברור כי $h^{-1}(t) = 10t$ ולכן:

$$p_Y(y) = p_X\left(h^{-1}(y)\right) = p_X(10y)$$

2. נסמן ב־$X$ את מספר הכישלונות לפני הצלחה מספר $r$ בסדרה אינסופית של ניסויי ברנולי עם פרמטר הצלחה $p$, כלומר $X \sim \mathrm{NB}(r,p)$. משתנה $Y$ המוגדר על־ידי $Y = X + r$ (כלומר $h(t) = t + r$) מתאר את מספר הניסוי בו התרחשה ההצלחה מספר $0 \le r \in \mathbb{N}$. נבחין כי ערכי $Y$ האפשריים הם $\{r, r+1, r+2, ...\}$. לכל $r \le k$ מתקיים:

$$p_Y(k) = p_X\left(h^{-1}(k)\right) = p_X(k-r) = \binom{k-1}{r-1} p^r \cdot (1-p)^{k-r}$$

## 9 וקטור אקראי

עד כה חקרנו משתנה מקרי בודד. נשאלת השאלה מה ניתן לומר על הקשר בין שני משתנים מקריים שונים (או יותר). באופן כללי אם אין שום מידע נוסף התשובה היא שלא ניתן לומר דבר.

**דוגמאות:**

1. אם $X \sim \mathrm{Bin}(n,p)$ ונגדיר $Y = X,\ Z = X + 1$ אז בבירור $Y, Z \sim \mathrm{Bin}(n,p)$ אבל $P(X = Y) = 1$ בעוד ש־$P(X = Z) = 0$.

2. יהא $X$ משתנה המקבל את הערכים $1,3$ בהסתברות $\frac{1}{2}$ כל אחד ויהא $Y$ משתנה המקבל את הערכים $2,4$ בהסתברות $\frac{1}{2}$ כל אחד. מהי $P(X>Y)$? מפתה לומר שהיא $\frac{1}{4}$ כיוון שהאפשרויות הן $\{(1,2),(1,4),(3,2),(3,4)\}$ ורק $\{(3,2)\}$ מקיימת את הנדרש. עם זאת, המאורעות לא בהכרח מתקבלים באותה ההסתברות! שני מודלים אפשריים הם למשל:

| | $X=1$ | $X=3$ |
|---|---|---|
| $Y=2$ | 0.2 | 0.3 |
| $Y=4$ | 0.3 | 0.2 |

| | $X=1$ | $X=3$ |
|---|---|---|
| $Y=2$ | 0.25 | 0.25 |
| $Y=4$ | 0.25 | 0.25 |

**הגדרה 1.9** יהא $(\Omega,\mathcal{F},P)$ מרחב הסתברות ויהיו $\{X_k\}_{k=1}^n$ משתנים מקריים. אם לכל $\overline{x}\in\mathbb{R}^n$ מתקיים כי $\{X_1\le x_1,...,X_n\le x_n\}$ הוא מאורע אז $\overline{X}=(X_1,...,X_n)$ נקרא **וקטור אקראי**.

**הערות:**

1. גם כאן, הדרישה שהקבוצה $\{X_1\le x_1,...,X_n\le x_n\}$ היא מאורע היא דרישה "טכנית" ולא נבדוק אותה בקורס.

2. המשתנים המקריים הם מעל אותו מרחב ההסתברות.

3. נאמר שוקטור אקראי $\overline{X}$ **נתמך** בקבוצה $B\subseteq\mathbb{R}^n$ אם $P\left(\overline{X}\in B\right)=1$.

4. נאמר כי $\overline{X}$ **בדיד** אם יש קבוצה $A\subseteq\mathbb{R}^n$ בת־מניה עבורה מתקיים $P\left(\overline{X}\in A\right)=1$. במקרה זה הקבוצה $A$ היא **התומך** של $\overline{X}$.

5. לכל $B\subset\mathbb{R}^n$ מגדירים:

$$P_{\overline{X}}(B)=P\left(\overline{X}\in B\right)=P\left(\left\{\omega\mid\overline{X}(\omega)\in B\right\}\right)$$

זוהי למעשה מידת הסתברות על $\mathbb{R}^n$ והיא מגדירה את **הפילוג** של $\overline{X}$. **פונקציית ההסתברות** של $\overline{X}$ היא $p_{\overline{X}}(\overline{x})=P\left(\overline{X}=\overline{x}\right)$. נציין שנהוג לרשום גם $p_{X_1,...,X_n}$ במקום $p_{(X_1,...,X_n)}$.

**דוגמה:** מטילית קוביה הוגנת פעמיים ברצף. נסמן ב־$X$ את התוצאה של ההטלה הראשונה וב־$Y$ את התוצאה של ההטלה השניה. אז פונקציית ההסתברות של $(X,Y)$ היא $p_{X,Y}(x,y)=\frac{1}{36}$ לכל $x,y\in\{1,...,6\}$.

**טענה 2.9** יהא $\overline{X}=(X_1,...,X_n)$ אז: $\overline{X}$ בדיד $\iff$ $\{X_k\}_{k=1}^n$ בדידים.

**הוכחה:**

$\Leftarrow$: תהא $A\subseteq\mathbb{R}^n$ בת־מניה עבורה $P\left(\overline{X}\in A\right)=1$ ונסמן ב־$A_k$ את ההיטל על הרכיב ה־$k$־י. ברור כי כל $A_k$ היא בת־מניה וכן $P\left(X_k\in A_k\right)=1$ ולכן כל $X_k$ בדיד לפי ההגדרה.

$\Rightarrow$: נתון שכל $X_k$ הוא בדיד ולכן יש $\{A_k\}_{k=1}^n$ בנות־מניה עבורן $P\left(X_k\in A_k\right)=1$. אם נגדיר $A=A_1\times\cdots\times A_n$ נקבל קבוצה בת־מניה עבורה $P\left(\overline{X}\in A\right)=1$, לכן $\overline{X}$ בן־מניה.

■

## 9.1 פילוג שולי

**הגדרה 3.9** יהא $\overline{X}$ וקטור אקראי ויהא $\overline{Y}$ תת־וקטור של $\overline{X}$. הפילוג של $\overline{Y}$ נקרא **פילוג שולי** של $\overline{X}$.

**הערה:** עבור $\overline{X}=(X_1,...,X_n)$, הפילוג של כל $X_k$ נקרא פילוג שולי חד־מימדי. נדגיש שהפילוגים השוליים החד־מימדיים לא קובעים את הפילוג של $\overline{X}$.

נראה דוגמה של פילוג מולטינומי עוד מעט. ראשית נוכיח תכונה בסיסית בקשר לפונקציית ההסתברות.

**טענה 4.9** יהא $(X,Y)$ וקטור אקראי בדיד ותהא $p_{X,Y}$ פונקציית ההסתברות, אז:

$$p_X(x)=\sum_{y\in\mathbb{R}}p_{X,Y}(x,y),\quad p_Y(y)=\sum_{x\in\mathbb{R}}p_{X,Y}(x,y)$$

**הערה:** מכלילים את המשפט לוקטור אקראי בדיד מכל אורך סופי. כמו כן, ניתן לקבל באופן דומה את פונקציית ההסתברות השולית של תת־וקטור מכל אורך.

**הוכחה:** נוכיח למשל עבור $X$. נקבע $x_0$ ונחשב:

$$p_X(x_0)=P(X=x_0)=P((X,Y)\in\{x_0\}\times\mathbb{R})=\sum_{(x,y)\in\{x_0\}\times\mathbb{R}}p_{X,Y}(x,y)=\sum_{y\in\mathbb{R}}p_{X,Y}(x_0,y)$$

■

### 9.2 פילוג מולטינומי

נראה כעת הכללה של הפילוג הבינומי. נניח שנתונים $n$ ניסויים בלתי תלויים בהם יש $1 \leq r$ סוגי הצלחה וסוג אחד של כישלון (זוהי הכללה של ניסויי ברנולי). נניח שההסתברות להצלחה מסוג $k \in \{1, ..., r\}$ היא $p_k \in [0, 1]$. דורשים $0 \leq p_1 + \cdots + p_r \leq 1$ וההסתברות לכישלון היא $p_0 = 1 - (p_1 + \cdots + p_r)$. נסמן ב־$X_k$ את מספר הניסויים בהם התרחשה הצלחה מסוג $k$. נקבל וקטור אקראי $\overline{X} = (X_1, ..., X_r)$ שהתומך שלו הוא:

$$A = \{\overline{x} \in \mathbb{R}^r \mid 0 \leq x_1, ..., x_r \in \mathbb{N},\ x_1 + \cdots + x_r \leq n\}$$

נסמן ב־$x_0 = n - (x_1 + \cdots + x_r)$ את מספר הכישלונות ונקבל שפונקציית ההסתברות של $\overline{X}$ היא:

$$p_{\overline{X}}(\overline{x}) = \begin{cases} \begin{pmatrix} n \\ x_0, x_1, ..., x_r \end{pmatrix} \cdot p_0^{x_0} \cdot p_1^{x_1} \cdot p_2^{x_2} \cdots p_r^{x_r} & , \quad \overline{x} \in A \\ 0 & , \quad \overline{x} \notin A \end{cases}$$

נאמר שהוקטור $\overline{X}$ הוא בעל פילוג **מולטינומי**, מסמנים $X \sim \mathbf{Multi}(n; p_1, ..., p_r)$.

**הערות:**

1. הביטוי $\begin{pmatrix} n \\ x_0, x_1, ..., x_r \end{pmatrix}$ מחשב תמורות עם חזרות. מספר האפשרויות נתון על־ידי:

$$\begin{pmatrix} n \\ x_0, x_1, ..., x_r \end{pmatrix} = \frac{n!}{x_0! \cdot x_1! \cdots x_r!}$$

דוגמה קלאסית היא מספר הסידורים השונים של אגרטלים ב־$r$ צבעים שונים על מדף כאשר יש $x_1, ..., x_r$ אגרטלים מכל סוג.

2. לא חייבים להתייחס במיוחד לכישלון, אפשר למספר הכל כסוגים שונים של תוצאות.

**דוגמה**: בשק יש $4$ כדורים כחולים, $7$ אדומים ו־$9$ ירוקים. מוציאים $n$ כדורים עם החזרה. נסמן ב־$(X_b, X_r, X_g)$ את מספר הכדורים שהוצאנו מכל צבע. נחשב את $p_{X_b}(k)$ לפי הטענה הקודמת:

$$p_{X_b}(k) = \sum_{l,m \in \mathbb{N}} p_{X_b, X_r, X_g}(k, l, m) = \sum_{j=0}^{n-k} p_{X_b, X_r, X_g}(k, j, n-k-j) =$$
$$= \sum_{j=0}^{n-k} \frac{n!}{k! \cdot j! \cdot (n-k-j)!} \cdot \left(\frac{4}{20}\right)^k \cdot \left(\frac{7}{20}\right)^j \cdot \left(\frac{9}{20}\right)^{n-k-j} =$$

$$= \frac{n!}{k!} \cdot \left(\frac{4}{20}\right)^k \cdot \sum_{j=0}^{n-k} \frac{1}{j! \cdot (n-k-j)!} \cdot \left(\frac{7}{20}\right)^j \cdot \left(\frac{9}{20}\right)^{n-k-j} =$$

$$= \frac{n!}{k! \cdot (n-k)!} \cdot \left(\frac{4}{20}\right)^k \cdot \sum_{j=0}^{n-k} \frac{(n-k)!}{j! \cdot (n-k-j)!} \cdot \left(\frac{7}{20}\right)^j \cdot \left(\frac{9}{20}\right)^{n-k-j} =$$

$$= \binom{n}{k} \cdot \left(\frac{4}{20}\right)^k \cdot \sum_{j=0}^{n-k} \binom{n-k}{j} \cdot \left(\frac{7}{20}\right)^j \cdot \left(\frac{9}{20}\right)^{n-k-j} =$$

$$= \binom{n}{k} \cdot \left(\frac{4}{20}\right)^k \cdot \left(\frac{7}{20} + \frac{9}{20}\right)^{n-k} = \binom{n}{k} \cdot \left(\frac{4}{20}\right)^k \cdot \left(\frac{16}{20}\right)^{n-k}$$

נסיק כי $X_b \sim \mathrm{Bin}\left(n, \frac{4}{20}\right)$, כלומר הפילוג השולי החד מימדי של הפילוג המולטינומי הוא פילוג בינומי. זה נכון לכל רכיב.

### 9.3 טרנספורמציה של וקטור אקראי

באופן אנלוגי למשתנה מקרי, השימוש בטרנספורמציה עוזר לעבוד עם וקטורים ולחשב הסתברויות. ההוכחה אנלוגית ולכן נסתפק בניסוח המשפט.

**משפט 5.9** יהא $\overline{X} = (X_1, ..., X_n)$ וקטור אקראי בדיד ותהא $h : \mathbb{R}^n \to \mathbb{R}^k$ פונקציה, אז $\overline{Y} = h\left(\overline{X}\right)$ הוא וקטור אקראי בדיד. אם $h$ היא חח"ע ביחס לתומך של $\overline{X}$ אז פונקציית ההסתברות נתונה על־ידי:

$$p_{\overline{Y}}(\overline{y}) = p_{\overline{X}}\left(h^{-1}(\overline{y})\right)$$

גם כאן, במקרה בו $h$ לא חח"ע נקבל:

$$p_{\overline{Y}}(\overline{y}) = \sum_{\overline{x} \in h^{-1}(\overline{y})} p_{\overline{X}}(\overline{x})$$

**דוגמה**: נניח כי $(X, Y) \sim \mathrm{Uni}\{1,2,3\} \times \{1,2,3\}$ ונסמן $Z = X + Y$, כלומר $h(x,y) = x + y$. ברור שהערכים של $Z$ הם בין 2 ל־6. מהמשפט אפשר לחשב באופן מלא את פונקציית ההתפלגות של $Z$, נחשב למשל את $p_Z(3)$. התומך של $X, Y$ הוא $\{1,2,3\}$ ולכן המקורות של $h(x,y) = 3$ הם $\{(1,2), (2,1)\}$, נחשב:

$$p_Z(3) = p_{(X,Y)}(1,2) + p_{(X,Y)}(2,1) = \tfrac{1}{9} + \tfrac{1}{9} = \tfrac{2}{9}$$

## 10 פילוג מותנה של משתנים

בדומה להסתברות מותנית, נרצה להבין את ההשפעה של משתנה מקרי אחד על אחד. נתחיל עם דוגמה.

**דוגמה**: נתונה סדרה אינסופית של ניסויי ברנולי. נסמן ב־$X_i$ את מספר הניסוי בו התרחשה הצלחה מספר $i$.
ראינו כי $X_1 \sim \mathrm{Geom}(p)$, עבור $X_2$ נקבל:

$$\forall k \geq 2,\ p_{X_2}(k) = \binom{k-1}{1} \cdot p^2 \cdot (1-p)^{k-2}$$

נקבע $m \in \mathbb{N}$ ונחשב את $P(X_2 = k \mid X_1 = m)$ לכל $k \geq 2$:

$$P(X_2 = k \mid X_1 = m) = \frac{P(X_2 = k, X_1 = m)}{P(X_1 = m)} = \frac{p^2 \cdot (1-p)^{k-2}}{p(1-p)^{m-1}} = p(1-p)^{k-m-1}$$

כלומר עד כדי כפל בקבוע, $X_2$ מפולג גיאומטרית בהינתן ש־$X_1 = m$.

**הגדרה 1.10** יהיו $X, Y$ משתנים מקריים בדידים. **פונקציית ההסתברות המותנית** של $Y$ בהינתן $X = x$ היא $p_{Y|X}(y \mid x) = \frac{p_{X,Y}(x,y)}{p_X(x)}$ לכל $x$ עבורו $p_X(x) > 0$.

**הערות:**

1. אם רוצים את הפילוג של $Y$ ביחס ל־$B \subseteq \mathbb{R}$ נחשב את $P(Y \in B \mid X = x) = \sum_{y \in B} p_{Y|X}(y \mid x)$.

2. מכלילים את ההגדרה לוקטור אקראי.

3. נוסחת בייס היא $p_{X|Y}(x \mid y) = \frac{p_{Y|X}(y|x) \cdot p_X(x)}{p_Y(y)}$ ונוסחת ההסתברות השלמה היא:

$$p_Y(y) = \sum_{x \in \mathbb{R}} p_{Y|X}(y \mid x) \cdot p_X(x)$$

**דוגמאות:**

1. ביחס לדוגמה קודמת נקבל $p_{X_2|X_1}(x_2 \mid x_1) = p(1-p)^{x_2 - x_1 - 1}$.

2. ביחס לדוגמה נחשב את הפילוג של $X_1$ בהינתן $X_2 = j$:

$$\forall k \in \{1, 2, ..., j-1\}, \quad p_{X_1|X_2}(k \mid j) = \frac{P(X_1 = k, X_2 = j)}{P(X_2 = j)} = \frac{p^2 \cdot (1-p)^{j-2}}{\binom{j-1}{1} \cdot p^2 \cdot (1-p)^{j-2}} = \frac{1}{j-1}$$

כלומר $X_1$ מתפלג באחידות בקבוצה $\{1, 2, ..., j-1\}$ בהינתן $X_2 = j$.

## 11 משתנים מקריים בדידים בלתי תלויים

בדומה למאורעות בלתי תלויים, רוצים לדעת האם יש תלות בין ערכים של משתנים מקריים שונים.

**דוגמה**: נתונה סדרה אינסופית של ניסויי ברנולי. נסמן ב־$X$ את מספר הניסויים עד להצלחה הראשונה וב־$Y$ את מספר הניסויים אחרי ההצלחה הראשונה ועד להצלחה השניה. באופן אינטואיטיבי לא נראה שיש תלות בין $X$ ל־$Y$. כמו כן ראינו כבר כי $X \sim \text{Geom}(p)$ ומתכונת חוסר הזיכרון דיי ברור גם כי $Y \sim \text{Geom}(p)$. בנוסף עבור הוקטור $(X, Y)$ חישוב ישיר מראה כי $p_{X,Y}(n, k) = p^2 \cdot (1-p)^{n+k-2}$.

**הגדרה 1.11** יהיו $X_1, ..., X_n$ משתנים מקריים בדידים. נאמר שהם **בלתי־תלויים** אם מתקיים:

$$\forall (x_1, ..., x_n) \in \mathbb{R}^n, \quad p_{X_1,...,X_n}(x_1, ..., x_n) = p_{X_1}(x_1) \cdots p_{X_n}(x_n)$$

**הערות**:

1. אוסף של משתנים מקריים בלתי תלויים אשר מפולגים באופן זהה מסומן על־ידי $i.i.d$, כלומר independent and identically distributed.

2. באופן כללי נאמר שמשתנים $X, Y$ (לא בהכרח בדידים) הם **בלתי־תלויים** אם לכל $x, y \in \mathbb{R}$ המאורעות $\{X \leq x\}, \{Y \leq y\}$ בלתי תלויים.

3. מסקנה מיידית מההגדרה היא שכאשר נתון וקטור אקראי בו המשתנים בלתי־תלויים, פונקציית ההסתברות מתפרקת למכפלה של פונקציות הסתברות לפי כל רכיב. באופן מפורש אם $X, Y$ בלתי־תלויים אז:

$$p_{X,Y}(x, y) = P(X = x, Y = y) = P(X = x) \cdot P(Y = y) = p_X(x) \cdot p_Y(y)$$

מכלילים למספר רב יותר של רכיבים.

**דוגמה:** בהמשך לדוגמה קודמת, לכל $n,k$ בתומך של $p_{X,Y}$ מתקיים:

$$p_{X,Y}(n,k) = p^2 \cdot (1-p)^{n+k-2} = p \cdot (1-p)^{n-1} \cdot p \cdot (1-p)^{k-1} = p_X(n) \cdot p_y(k)$$

לכן $X,Y$ בלתי תלויים.

## 11.1 משפט הקונבולוציה למשתנים מקריים בדידים

נראה כעת משפט אשר עוזר לנו לחשב את פונקציית ההסתברות של סכום של משתנים בדידים בלתי־תלויים.

**משפט 2.11** (**משפט הקונבולוציה**) נניח כי $X,Y$ משתנים מקריים בדידים בלתי תלויים, אז:

$$p_{X+Y}(t) = \sum_{x\in\mathbb{R}} p_X(x) \cdot p_Y(t-x)$$

**הערות:**

1. הפעולה אשר מתוארת במשפט בין הפונקציות נקראת קונבולוציה. זוהי הגרסה הבדידה שלה. באופן כללי נהוג לסמן $(p_X * p_Y)(t) = p_{X+Y}(t)$. מההגדרה נובע ישירות שהקונבולוציה היא קיבוצית וחילופית, כלומר:
   **א.** $p_X * p_Y = p_Y * p_X$.
   **ב.** $(p_X * p_Y) * p_Z = p_X * (p_Y * p_Z)$.

2. המשפט אומר שאם המשתנים בלתי־תלויים אז הפילוג של הטרנספורמציה נקבע בעזרת הפילוגים של המשתנים עצמם.

**הוכחה:** מההנחה במשפט והעובדה ש־$X,Y$ בלתי־תלויים נקבל:

$$\begin{aligned} p_{X+Y}(t) &= P(X+Y=t) = P\left(\bigcup_{x\in\mathbb{R}} \{X=x, Y=t-x\}\right) = \\ &= \sum_{x\in\mathbb{R}} P(X=x, Y=t-x) = \sum_{x\in\mathbb{R}} P(X=x) \cdot P(Y=t-x) = \\ &= \sum_{x\in\mathbb{R}} p_X(x) \cdot p_Y(t-x) \end{aligned}$$

■

**דוגמה:** נניח כי $X \sim \text{Pois}(\lambda)\,,\ Y \sim \text{Pois}(\mu)$ בלתי־תלויים. נוכיח כי $X+Y \sim \text{Pois}(\lambda+\mu)$, אכן:

$$p_{X+Y}(t) = \sum_{x\in\mathbb{R}} p_X(x)\cdot p_Y(t-x) \underset{(*)}{=} \sum_{x=0}^{t} \mathrm{e}^{-\lambda}\frac{\lambda^x}{x!}\cdot \mathrm{e}^{-\mu}\frac{\mu^{t-x}}{(t-x)!} =$$

$$= \mathrm{e}^{-(\lambda+\mu)}\sum_{x=0}^{t}\frac{\lambda^x}{x!}\cdot\frac{\mu^{t-x}}{(t-x)!} = \mathrm{e}^{-(\lambda+\mu)}\cdot\frac{1}{t!}\sum_{x=0}^{t}\frac{t!}{(t-x)!\cdot x!}\lambda^x\cdot\mu^{t-x} =$$

$$= \mathrm{e}^{-(\lambda+\mu)}\cdot\frac{1}{t!}\sum_{x=0}^{t}\binom{t}{x}\lambda^x\cdot\mu^{t-x} = \mathrm{e}^{-(\lambda+\mu)}\cdot\frac{(\lambda+\mu)^t}{t!}$$

$(*)$ נציין כי $0 \le x, t \in \mathbb{N}$ וכן $x \le t$.

תהליך זה נקרא **איחוד פואסון**, מכלילים למספר רב יותר של מחוברים.

### 11.2 טרנספורמציה של משתנים מקריים בדידים בלתי־תלויים

זה לא מובן מאליו אך טרנספורמציה של משתנים בלתי תלויים מניבה משתנים חדשים בלתי־תלויים. באופן מפורש:

**משפט 3.11** נניח כי $X, Y, Z$ בלתי תלויים, אז לכל שתי פונקציות $g:\mathbb{R}\to\mathbb{R},\ h:\mathbb{R}^2\to\mathbb{R}$ גם המשתנים המקריים $g(X), h(Y,Z)$ הם בלתי תלויים.

**הערה:** מכלילים למספר רב יותר של משתנים וכן לוקטורים אקראיים.

## 12 התוחלת

בהינתן משתנה מקרי טבעי לשאול מהו הערך "הממוצע" שמתקבל.

**דוגמאות:**

1. בהטלה של קוביה הוגנת הערך הממוצע שנקבל הוא $\frac{1+2+3+4+5+6}{6} = 3.5$.

2. נתונות 3 קבוצות של אנשים בגדלים $10, 20, 90$. בוחרים באופן אקראי מישהו. נסמן ב־$X$ את מספר האנשים מהקבוצה שאליה שייך האדם הנבחר. אינטואיטיבית, ממוצע הערכים של $X$ צריך להיות קרוב יותר ל־90 מאשר 20 או 10.

**הגדרה 1.12** יהא $X$ משתנה מקרי בדיד. **התוחלת** של $X$ (אם היא מוגדרת) היא:

$$E(X)=\sum_{x\in\mathbb{R}}x\cdot p_X(x)$$

**הערות:**

1. נהוג גם לסמן $\mu=\mu_X=E(X)$.

2. התוחלת יכולה להיות שווה לאינסוף. נציין שכל הטענות בהמשך תקפות בהנחה שהתוחלת קיימת ובד"כ סופית.

3. נהוג להתייחס לתוחלת לפי הפיצול הבא:

$$E^+(X)=\sum_{x>0}x\cdot p_X(x)$$
$$E^-(X)=\sum_{x<0}x\cdot p_X(x)$$

ואז התוחלת מוגדרת בהנחה שלפחות אחד משני הביטויים הנ"ל הוא סופי. למעשה בקרוב נראה ממשפט על טרנספורמציה כי $E(|X|)=\sum_{x\in\mathbb{R}}|x|\cdot p_X(x)$ ולכן התוחלת של $X$ מוגדרת וסופית אם ורק אם $E(|X|)$ מוגדר וסופי.

4. מרחב המשתנים המקריים עבורם $E(|X|)$ קיים וסופי מסומן על־ידי $L^1(P)$.

5. התוחלת מחשבת ממוצע ערכים בדומה לחישוב מרכז מסה, כלומר ממוצע משוקלל. סוג נוסף של ממוצע הוא ממוצע "לאורך זמן". בהמשך נתייחס גם לסוג הזה של הממוצע.

**דוגמאות:**

1. יהא $X$ הערך המתקבל בהטלה של קוביה הוגנת, התוחלת של $X$ היא:

$$E(X)=\sum_{x\in\mathbb{R}}x\cdot p_X(x)=\sum_{k=1}^{6}k\cdot\frac{1}{6}=\frac{1+2+3+4+5+6}{6}=3.5$$

2. נתונות 3 קבוצות של אנשים בגדלים $10.20,90$. בוחרים באופן אקראי מישהו. נסמן ב־$X$ את מספר האנשים מהקבוצה שאליה שייך האדם הנבחר. התוחלת של $X$ היא:

$$E\left(X\right)=\sum_{x\in\mathbb{R}}x\cdot p_X\left(x\right)=10\cdot\frac{10}{120}+20\cdot\frac{20}{120}+90\cdot\frac{90}{120}\simeq 71.6$$

3. מטילים מטבע הוגן אינסוף פעמים. נסמן ב־$X$ את מספר ההטלות עד שמקבלים בפעם הראשונה עץ ואז מייד פלי. ראשית נחשב את פונקציית ההסתברות:

$$p_X\left(1\right)=0,\ p_X\left(2\right)=\frac{1}{4},\ p_X\left(3\right)=\frac{1}{4},...,\ p_X\left(n\right)=\frac{n-1}{2^n}$$

מכאן התוחלת של $X$ היא:

$$E\left(X\right)=\sum_{x\in\mathbb{R}}x\cdot p_X\left(x\right)=\sum_{n=1}^{\infty}n\cdot p_X\left(n\right)=\sum_{n=2}^{\infty}n\cdot\frac{n-1}{2^n}\underset{(*)}{=}\frac{2\cdot\frac{1}{4}}{\left(1-\frac{1}{2}\right)^3}=4$$

$(*)$ נבחין כי:

$$\frac{2}{\left(1-x\right)^3}=\left(\frac{1}{1-x}\right)''=\left(\sum_{n=0}^{\infty}x^n\right)''=\left(\sum_{n=1}^{\infty}nx^{n-1}\right)'=\sum_{n=2}^{\infty}n\left(n-1\right)x^{n-2}$$

נכפול את שני הצדדים ב־$x^2$ ונקבל $\frac{2x^2}{\left(1-x\right)^3}=\sum_{n=2}^{\infty}n\left(n-1\right)x^n$. כעת נציב $x=\frac{1}{2}$ נקבל את סכום הטור.

## 12.1 תוחלת של פילוגים בדידים ידועים

נחשב לפי ההגדרה את התוחלות של הפילוגים שראינו:

**פילוג אחיד:**

אם $X \sim \mathrm{U}\{x_1, ..., x_n\}$ אז:

$$E(X) = \sum_{x\in\mathbb{R}} x \cdot p_X(x) = \sum_{k=1}^{n} x_k \cdot \frac{1}{n} = \frac{x_1 + \cdots + x_n}{n}$$

במקרה המיוחד בו $X \sim \mathrm{U}\{1, ..., n\}$ נקבל:

$$E(X) = \frac{1 + \cdots + n}{n} = \frac{n+1}{2}$$

**פילוג ברנולי:**

אם $X \sim \mathrm{Bern}(p)$ אז:

$$E(X) = \sum_{x\in\mathbb{R}} x \cdot p_X(x) = 0 \cdot (1-p) + 1 \cdot p = p$$

**פילוג בינומי**

אם $X \sim \mathrm{Bin}(n, p)$ אז:

$$\begin{aligned}
E(X) &= \sum_{k=0}^{n} k \cdot p_X(k) = \sum_{k=0}^{n} k \cdot \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k} = \\
&= \sum_{k=0}^{n} k \cdot \binom{n}{k} \cdot \left(\frac{p}{1-p}\right)^k \cdot (1-p)^n = p \cdot (1-p)^{n-1} \cdot \sum_{k=1}^{n} k \cdot \binom{n}{k} \cdot \left(\frac{p}{1-p}\right)^{k-1} \underset{(*)}{=} \\
&= p \cdot (1-p)^{n-1} \cdot n \cdot \left(1 + \frac{p}{1-p}\right)^{n-1} = np
\end{aligned}$$

$(*)$ נבחין כי $\sum_{k=0}^{n} k \cdot \binom{n}{k} \cdot t^{k-1} = \left(\sum_{k=0}^{n} \binom{n}{k} \cdot t^k\right)' = ((1+t)^n)' = n(1+t)^{n-1}$ ולכן נציב $t = \frac{p}{1-p}$.

**פילוג בינומי שלילי**

אם $X \sim \mathrm{NB}(r,p)$ אז:

$$
\begin{aligned}
E(X) &= \sum_{k=1}^{\infty} k \cdot p_X(k) = \sum_{k=0}^{\infty} k \cdot \binom{k+r-1}{r-1} p^r \cdot (1-p)^k = \sum_{k=1}^{\infty} k \cdot \frac{(k+r-1)!}{(r-1)! \cdot k!} p^r \cdot (1-p)^k = \\
&= \sum_{k=1}^{\infty} \frac{(k+r-1)!}{(r-1)! \cdot (k-1)!} \cdot p^r \cdot (1-p)^k = \sum_{k=1}^{\infty} r \cdot \frac{(k+r-1)!}{r! \cdot (k-1)!} \cdot p^r \cdot (1-p)^k = \\
&= r \cdot (1-p) \cdot p^r \cdot \sum_{k=1}^{\infty} \binom{k+r-1}{k-1} \cdot (1-p)^{k-1} = \\
&= r \cdot (1-p) \cdot p^r \cdot \sum_{k=0}^{\infty} \binom{k+r+1-1}{k} \cdot (1-p)^k \underset{(*)}{=} \\
&= r \cdot (1-p) \cdot p^r \cdot \left(\frac{1}{1-(1-p)}\right)^{r+1} = r \cdot \frac{(1-p)}{p}
\end{aligned}
$$

$(*)$ כידוע: $\sum_{l=0}^{\infty} \binom{m+l-1}{l} x^l = \sum_{l=0}^{\infty} D(m,l)\, x^l = \left(\frac{1}{1-x}\right)^m$.

**פילוג גיאומטרי**

אם $X \sim \mathrm{Geom}(p)$ אז:

$$
\begin{aligned}
E(X) &= \sum_{k=1}^{\infty} k \cdot p_X(k) = \sum_{k=1}^{\infty} k \cdot p \cdot (1-p)^{k-1} = \\
&= p \cdot \sum_{k=1}^{\infty} k \cdot (1-p)^{k-1} \underset{(*)}{=} p \cdot \frac{1}{(1-(1-p))^2} = \frac{1}{p}
\end{aligned}
$$

$(*)$ נבחין כי $\sum_{k=1}^{\infty} k t^{k-1} = \left(\sum_{k=1}^{\infty} t^k\right)' = \left(\frac{t}{1-t}\right)' = \frac{1}{(1-t)^2}$ ולכן נציב $t = 1-p$.

**פילוג היפר־גיאומטרי**

אם $X \sim \mathrm{HG}(n, N, D)$ אז:

$$E(X) = \sum_{k=1}^{n} k \cdot p_X(k) = \sum_{k=1}^{n} k \cdot \frac{\binom{D}{k} \cdot \binom{N-D}{n-k}}{\binom{N}{n}} =$$

$$= \frac{nD}{N} \sum_{k=0}^{n-1} \frac{\binom{D-1}{k} \cdot \binom{N-1-(D-1)}{n-1-k}}{\binom{N-1}{n-1}} =$$

$$= \frac{nD}{N\binom{N-1}{n-1}} \sum_{k=0}^{n-1} \binom{D-1}{k} \cdot \binom{N-1-(D-1)}{n-1-k} = n \cdot \frac{D}{N}$$

**פילוג פואסון**

אם $X \sim \mathrm{Pois}(\lambda)$ אז:

$$E(X) = \sum_{k=1}^{\infty} k \cdot p_X(k) = \sum_{k=1}^{\infty} k \cdot \mathrm{e}^{-\lambda} \cdot \frac{\lambda^k}{k!} =$$

$$= \lambda \cdot \mathrm{e}^{-\lambda} \cdot \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda \cdot \mathrm{e}^{-\lambda} \cdot \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \lambda \cdot \mathrm{e}^{-\lambda} \cdot \mathrm{e}^{\lambda} = \lambda$$

## 12.2 נוסחת הזנב

נראה כעת קשר שימושי בין התוחלת למידת ההסתברות.

**משפט 2.12** יהא $X$ משתנה מקרי בדיד אשר מקבל ערכים שלמים ואי־שליליים בלבד, אז:

$$E(X) = \sum_{k=1}^{\infty} P(X \geq k)$$

**הערות:**

1. באופן פורמלי, נאמר שמשתנה מקרי $X$ הוא בדיד ו**אי־שלילי** אם התומך $A$ של $X$ מקיים $A \subseteq [0,\infty)$. באופן שקול אפשר להגדיר $P(X \geq 0) = 1$.

2. המשפט נכון גם במקרה בו התומך לא בהכרח מוכל בשלמים (אך עדיין אי־שלילי).

3. לפעמים נוח יותר לחשב את ההסתברות של אי־שוויון חזק ואז נחשב: $\sum_{k=1}^{\infty} P(X \geq k) = \sum_{k=0}^{\infty} P(X > k)$.

**הוכחה:** נרשום את התוחלת לפי ההגדרה ונסדר[9] מחדש את הסכום:

$$E(X) = \sum_{k=1}^{\infty} k \cdot p_X(k) = p_X(1) + p_X(2) + p_X(2) + p_X(3) + p_X(3) + p_X(3) + \cdots =$$

$$= \underbrace{p_X(1) + p_X(2) + p_X(3) + \cdots}_{P(X\geq 1)} + \underbrace{p_X(2) + p_X(3) + \cdots}_{P(X\geq 2)} + \cdots = \sum_{m=1}^{\infty} P(X \geq m)$$

■

**דוגמה:** מטילים מטבע הוגן אינסוף פעמים. נסמן ב־$X$ את מספר ההטלות עד שמקבלים בפעם הראשונה עץ ואז מייד פלי. ראשית ברור כי $P(X > 0) = P(X > 1) = 1$. כעת לכל $k \geq 2$, לא נקבל את הרצף עץ ואז פלי אם יצא $j$ פעמים פלי ואז $k-j$ פעמים עץ. ההסתברות לכל מקרה כזה היא $\left(\frac{1}{2}\right)^j \cdot \left(\frac{1}{2}\right)^{k-j}$ ויש $k+1$ מקרים כאלה, לכן $P(X > k) = \frac{k+1}{2^k}$. כעת לפי נוסחת הזנב:

$$E(X) = \sum_{k=1}^{\infty} P(X \geq k) = \sum_{k=0}^{\infty} P(X > k) = \sum_{k=0}^{\infty} \frac{k+1}{2^k} \underset{(*)}{=} \frac{1}{\left(1-\frac{1}{2}\right)^2} = 4$$

$(*)$ נבחין כי: $\frac{1}{(1-t)^2} = \left(\frac{t}{1-t}\right)' = \left(\sum_{k=0}^{\infty} t^{k+1}\right)' = \sum_{k=0}^{\infty} (k+1)\, t^k$ ונציב $t = \frac{1}{2}$.

**הערה:** ניזכר שחישבנו כבר את התוחלת הזאת לפי ההגדרה, החישוב הזה קצר יותר.

[9] הטור אי־שלילי ולכן ניתן לשנות סדר סכימה.

### 12.3 תוחלת של טרנספורמציה

המשפט הבא עוזר לחשב תוחלת של טרנספורמציה של משתנה מקרי בדיד.

**משפט 3.12** יהא $X$ משתנה מקרי בדיד ותהא $h:\mathbb{R}\to\mathbb{R}$, אז התוחלת של $Y=h(X)$ היא:

$$E(Y)=\sum_{x\in\mathbb{R}}h(x)\cdot p_X(x)$$

**הערה:** מכלילים לוקטור אקראי בדיד.

**הוכחה:** נוכיח עבור $E^+(Y)$. לפי משפט קודם על טרנספורמציה נקבל:

$$E^+(Y)=\sum_{y>0}y\cdot p_Y(y)=\sum_{y>0}y\cdot\left(\sum_{x\in h^{-1}(y)}p_X(x)\right)\underset{(*)}{=}\sum_{x\in\mathbb{R},\ h(x)>0}h(x)\cdot p_X(x)$$

$(*)$ הטור אי־שלילי, לכן מותר לשנות את סדר הסכימה.

באופן דומה עבור $E^-(Y)$ וסיימנו.

■

**דוגמאות:**

1. לכל משתנה מקרי בדיד $X$ מתקיים $E(|X|)=\sum_{x\in\mathbb{R}}|x|\cdot p_X(x)$.

2. מציעים לכם את המשחק הבא: אתם משלמים $n$ שקלים, כעת מטילים מטבע הוגן שוב ושוב עד שיוצא עץ, אתם מרוויחים $2^{k-1}$ שקלים כאשר $k$ הוא מספר ההטלות הכולל (כלומר עד שיצא עץ). כמה $n$ צריך להיות שווה על מנת שיהיה כדאי לשחק במשחק?

נסמן ב־$X$ את מספר ההטלה הראשונה בה יצא עץ ואז $Y = 2^{X-1}$ מייצג את הרווח. אם התוחלת מייצגת את הממוצע אז הגיוני לדרוש $n < E(Y)$, נחשב:

$$E(Y) = \sum_{x\in\mathbb{R}} h(x)\cdot p_X(x) = \sum_{k=1}^{\infty} 2^{k-1}\cdot\left(\frac{1}{2}\right)^k = \sum_{k=1}^{\infty}\frac{1}{2} = \infty$$

נסיק כי ה"רווח הממוצע" הוא אינסוף, לכן על פניו נראה שכל ערך של $n$ צפוי להשתלם. עם זאת, עבור ערכי $n$ גדולים, ככל הנראה נפסיד אם נשחק משחק אחד. אם כך מהי המשמעות שהתוחלת הוא אינסוף? המשמעות היא שאם נשחק במשחק שוב ושוב הרווח הממוצע צפוי לגדול ככל שנשחק יותר. לכן עבור סכום מסויים, נאמר $n = 1000$, עבור מספיק משחקים יהיה משתלם לשחק את המשחק.

### 12.4 לינאריות וכפליות של התוחלת

תכונות בסיסיות נוספות של התוחלת הן:

**טענה 4.12** יהיו $X, Y$ בדידים, אז:

1. **לינאריות**: לכל $a \in \mathbb{R}$ מתקיים $E(a\cdot X + Y) = a\cdot E(X) + E(Y)$.
2. **כפליות**: אם $X, Y$ בלתי תלויים אז $E(X\cdot Y) = E(X)\cdot E(Y)$.

**הוכחה:**

1. שימוש כפול במשפט על תוחלת של טרנספורמציה מניב:

$$E(a\cdot X+Y) = \sum_{(x,y)\in\mathbb{R}^2}(ax+y)\,p_{X,Y}(x,y) =$$
$$= a\cdot\sum_{(x,y)\in\mathbb{R}^2} x\cdot p_{X,Y}(x,y) + \sum_{(x,y)\in\mathbb{R}^2} y\cdot p_{X,Y}(x,y) = a\cdot E(X) + E(Y)$$

2. אם $X, Y$ בלתי תלויים אז:

$$E(X\cdot Y) = \sum_{(x,y)\in\mathbb{R}^2} xy\cdot p_{X,Y}(x,y) = \sum_{x\in\mathbb{R}}\left(\sum_{y\in\mathbb{R}} xy\cdot p_X(x)\cdot p_Y(y)\right) =$$
$$= \sum_{x\in\mathbb{R}} x\cdot p_X(x)\cdot\left(\sum_{y\in\mathbb{R}} y\cdot p_Y(y)\right) = \sum_{x\in\mathbb{R}} x\cdot p_X(x)\cdot E(Y) = E(X)\cdot E(Y)$$

■

**דוגמה:** בסדרה סופית של $n$ ניסויי ברנולי נסמן ב־$U_k$ את ההצלחה בניסוי ה־$k$־י, ברור ש־$E(U_k)=p$. נסמן ב־$X$ את מספר ההצלחות, אז כידוע $X\sim \mathrm{Bin}(n,p)$. בנוסף לפי הגדרת האינדיקטורים נקבל $X=\sum_{k=1}^{n}U_k$. מלינאריות נקבל:

$$E(X)=E\left(\sum_{k=1}^{n}U_k\right)=\sum_{k=1}^{n}E(U_k)=\sum_{k=1}^{n}p=np$$

**הערה:** נבחין שהחישוב הזה קצר יותר מהחישוב של התוחלת של משתנה בינומי עשינו לפי ההגדרה. בנוסף לא היינו צריכים את העובדה שהניסויים בלתי־תלויים. עם זאת, כאשר הניסויים לא בלתי־תלויים אז $X$ כבר לא מפולג בינומית.

### 12.5 אי־שוויון מרקוב

אי־שוויון מרקוב הוא אי־שוויון בסיסי וחשוב אשר עוזר לחסום הסתברות בעזרת תוחלת. כמו כן הוא משמש להוכחת אי־שוויונות חשובים בהמשך.

**משפט 5.12** (**אי־שוויון מרקוב**) יהא $X$ משתנה מקרי בדיד ואי־שלילי, אז:

$$\forall x>0,\quad P(X\geq x)\leq\frac{E(X)}{x}$$

**הערה:** ההסתברות $P(X\geq x)$ נקראת **הסתברות זנבית**.

**הוכחה:** לכל $x_0>0$ מתקיים:

$$E(X)=\sum_{x>0}x\cdot p_X(x)\underset{(*)}{\geq}\sum_{x>x_0}x\cdot p_X(x)\geq\sum_{x>x_0}x_0\cdot p_X(x)=x_0\cdot\sum_{x>x_0}p_X(x)=x_0\cdot P(X\geq x_0)$$

$(*)$ הטור אי־שלילי.

נחלק ב־$x_0$ וסיימנו.

■

**דוגמה:** בהגרלה של כרטיסים להופעה משתתפים 200 אנשים והסיכוי לזכות הוא $p = 10^{-2}$ באופן בלתי־תלוי. נמצא טווח ערכים בו נוכל לומר שיש סיכוי של לפחות $90\%$ שמספר הזוכים הוא בטווח הזה. נסמן ב־$X$ את מספר הזוכים, אז $X \sim \text{Bin}(200, 10^{-2})$. מחפשים $N \in \mathbb{N}$ עבורו מתקיים $P(X \geq N) \leq 0.1$. לפי אי־שוויון מרקוב $P(X \geq N) \leq \frac{E(X)}{N} = \frac{200 \cdot 10^{-2}}{N} = \frac{2}{N}$. נדרוש $\frac{2}{N} \leq 0.1$ ונקבל $20 \leq N$. לכן יש סיכוי של לפחות $90\%$ שמספר הזוכים הוא בין 0 ל־19.

ממרקוב ומשפט על טרנספורמציה נקבל שלכל $X$ בדיד מתקיים $P(|X| \geq x) \leq \frac{E(|X|)}{x}$ לכל $x > 0$. למעשה זהו מקרה פרטי של טענה כללית יותר:

**מסקנה 6.12** יהא $X$ משתנה מקרי בדיד ותהא $h : [0, \infty) \to [0, \infty)$ עולה עבורה $h(x) > 0$ לכל $x > 0$, אז:

$$P(|X| \geq x) \leq \frac{E(h(|X|))}{h(x)}$$

**הוכחה:** מהמונוטוניות של $X$ נסיק שאם $|X| \geq x$ אז $h(|X|) \geq h(x)$ לכן המאורע $\{|X| \geq x\}$ מוכל במאורע $\{h(|X|) \geq h(x)\}$, לפיכך:

$$P(|X| \geq x) \leq P(h(|X|) \geq h(x))$$

כעת, המשתנה $h(|X|)$ הוא אי־שלילי ולכן ממרקוב $P(h(|X|) \geq h(x)) \leq \frac{E(h(|X|))}{h(x)}$. סה"כ נקבל:

$$P(|X| \geq x) \leq P(h(|X|) \geq h(x)) \leq \frac{E(h(|X|))}{h(x)}$$

■

### 12.6 תוחלת מותנית

לפעמים יש משתנים שונים אשר תלויים אחד בשני ורוצים לחשב את התוחלת של אחד כתלות באחר או לסירוגין את התוחלת של אחד מהם אבל קשה לחשב לפי ההגדרה. נראה כעת כלים להתמודד עם בעיות אילו.

**דוגמה:** שני שחקנים מטילים מטבע. לראשון יש הסתברות $\alpha$ לעץ ולשני $\beta$. השחקנים מטילים את המטבע במקביל עד שלראשון יוצא עץ. מהי תוחלת מספר העצים של השחקן השני? נענה בקרוב על השאלה הזאת.

**הגדרה 7.12** יהיו $X, Y$ משתנים מקריים בדידים ויהא $x \in \mathbb{R}$ עבורו $p_X(x) > 0$. **התוחלת המותנית** של $Y$ בהינתן $X = x$ היא:

$$E\left(Y \mid X=x\right)=\sum_{y\in\mathbb{R}} y\cdot p_{Y|X}\left(y \mid x\right)$$

**הערה:** הביטוי $E\left(Y \mid X=x\right)$ הוא פונקציה של $x$. למעשה התוחלת המותנית היא משתנה מקרי, כלומר אם נסמן $Z=E\left(Y \mid X\right)$ אז $Z\left(z\right)=E\left(Y \mid X=z\right)$.

**דוגמה:** מטילים קוביה הוגנת עד שיוצא $3$ ואז מטילים שוב כמספר הפעמים בשלב הקודם. נחשב את התוחלת המותנית של סכום תוצאות ההטלה בפעם השניה כתלות ב־$k$ המסמן את מספר ההטלות בפעם הראשונה. נסמן ב־$X$ את מספר ההטלות בפעם הראשונה וב־$Y$ את סכום ההטלות בפעם השניה. ברור כי $X\sim\mathrm{Geom}\left(\frac{1}{6}\right)$, נצפה שהתוחלת המותנית של $Y$ בהינתן $X=k$ תהיה שווה למספר ההטלות בפעם הראשונה כפול התוחלת של כל הטלה, כלומר $E\left(Y \mid X=k\right)=\frac{7}{2}k$. עם זאת, חישוב לפי ההגדרה הוא לא פשוט כלל. ראשית לכל $1\leq k\in\mathbb{N}$ צריך לחשב את $p_{Y|X}\left(m \mid k\right)$, כלומר את ההסתברות שהסכום של $k$ הטלות הוא בדיוק $m$ ואז להציב:

$$E\left(Y \mid X=k\right)=\sum_{y\in\mathbb{R}} y\cdot p_{Y|X}\left(y \mid k\right)=\sum_{m=k}^{6k} m\cdot P\left(Y=m \mid X=k\right)=\cdots=\frac{7}{2}k$$

שתי תכונות בסיסיות הן:

**טענה 8.12** יהיו $X,Y$ משתנים מקריים.

1. אם $X,Y$ בלתי־תלויים אז $E\left(Y \mid X\right)=E\left(Y\right)$.
2. אם $h:\mathbb{R}\to\mathbb{R}$ רציפה למעט קבוצה סופית של נקודות אז $E\left(h\left(X\right)Y \mid X\right)=h\left(X\right)\cdot E\left(Y \mid X\right)$.

**הוכחה:**

1. נחשב לפי ההגדרה, לכל $x$ עבורו $p_X\left(x\right)>0$ נקבל:

$$\begin{aligned}E\left(Y \mid X=x\right)&=\sum_{y\in\mathbb{R}} y\cdot p_{Y|X}\left(y \mid x\right)=\sum_{y\in\mathbb{R}} y\cdot\frac{P\left(Y=y,X=x\right)}{P\left(X=x\right)}=\\&=\sum_{y\in\mathbb{R}} y\cdot\frac{P\left(Y=y\right)\cdot P\left(X=x\right)}{P\left(X=x\right)}=\sum_{y\in\mathbb{R}} y\cdot p_Y\left(y\right)=E\left(Y\right)\end{aligned}$$

2. אם $h(y)=0$ שני האגפים שווים לאפס וסיימנו. אחרת, נסמן $Z=h(X)\cdot Y$, ונקבל:

$$p_{Z|X}(z\mid x)=\frac{P(Z=z,X=x)}{P(X=x)}=$$
$$=\frac{P(h(X)\cdot Y=z,X=x)}{P(X=x)}=\frac{P\left(Y=\frac{z}{h(x)},X=x\right)}{P(X=x)}=p_{Y|X}\left(\frac{z}{h(x)}\middle|x\right)$$

מכאן נקבל:

$$E(h(X)Y\mid X=x)=E(Z\mid X=x)=\sum_{z\in\mathbb{R}}z\cdot p_{Z|X}(z\mid x)=\sum_{z\in\mathbb{R}}z\cdot p_{Y|X}\left(\frac{z}{h(x)}\middle|x\right)\underset{(*)}{=}$$
$$=\sum_{y\in\mathbb{R}}h(x)\cdot y\cdot p_{X|Y}(y\mid x)=h(X)\cdot\sum_{y\in\mathbb{R}}y\cdot p_{X|Y}(y\mid x)=h(X)\cdot E(Y\mid X)$$

$(*)$ נבצע החלפת משתנים $y=\frac{z}{h(x)}$.

■

**דוגמה:** ביחס לדוגמה קודמת, נסמן ב־$Z$ את ממוצע ההטלות בפעם השניה כתלות ב־$X$. נצפה שממוצע ההטלות יהיה התוחלת. אכן, ניקח $f(t)=\frac{1}{t}$ ונקבל כי $Z=f(X)\cdot Y$, מכאן:

$$E(Z\mid X)=f(X)\cdot E(Y\mid X)=\frac{1}{X}\cdot\frac{7}{2}X=\frac{7}{2}$$

### 12.7 נוסחת ההחלקה

כעת נראה איך אפשר לחשב תוחלת של משתנה מקרי בעזרת הגדרת משתנה עזר וחישוב תוחלת מותנית.

**משפט 9.12** (**נוסחת ההחלקה**) יהיו $X,Y$ משתנים מקריים בדידים, אז $E(Y)=E(E(Y\mid X))$.

**הערה:** מסקנה מהמשפט היא **נוסחת וואלד**: יהיו $\{X_1,X_2,...\}$ משתנים מקריים $i.i.d$ ויהא $N$ משתנה מקרי המקבל ערכים טבעיים ובלתי תלוי בסדרה $\{X_1,X_2,...\}$ אז:

$$E\left(\sum_{k=1}^{N}X_k\right)=E(N)\cdot E(X_1)$$

**הוכחה:** כזכור $E(Y\mid X)$ היא טרנספורמציה על $X$, נסמן $g(x)=E(Y\mid X=x)=\sum_{y\in\mathbb{R}}y\cdot p_{Y|X}(y\mid x)$ ואז

לפי משפט על תוחלת של טרנספורמציה:

$$E\left(E\left(Y\mid X\right)\right)=\sum_{x\in\mathbb{R}}g\left(x\right)\cdot p_X\left(x\right)=\sum_{x\in\mathbb{R}}\left(\sum_{y\in\mathbb{R}}y\cdot p_{Y|X}\left(y\mid x\right)\right)\cdot p_X\left(x\right)=$$
$$=\sum_{y,x\in\mathbb{R}}y\cdot\frac{p_{X,Y}\left(x,y\right)}{p_X\left(x\right)}\cdot p_X\left(x\right)=\sum_{y,x\in\mathbb{R}}y\cdot p_{X,Y}\left(x,y\right)=$$
$$=\sum_{y\in\mathbb{R}}y\cdot\left(\sum_{x\in\mathbb{R}}p_{X,Y}\left(x,y\right)\right)=\sum_{y\in\mathbb{R}}y\cdot p_Y\left(y\right)=E\left(Y\right)$$

■

**דוגמאות:**

1. מטילים קוביה הוגנת עד שיוצא 3 ואז מטילים שוב כמספר הפעמים בשלב הקודם. נחשב את התוחלת של סכום תוצאות ההטלה בפעם השניה. נסמן ב־$X$ את מספר ההטלות בפעם הראשונה וב־$Y$ את סכום ההטלות בפעם השניה. ראינו כי $E\left(Y\mid X=k\right)=\frac{7}{2}k$, נחשב את התוחלת של $Y$:

$$E\left(Y\right)=E\left(E\left(Y\mid X\right)\right)=E\left(\frac{7}{2}\cdot X\right)=\frac{7}{2}\cdot E\left(X\right)=\frac{7}{2}\cdot 6=21$$

2. שני שחקנים מטילים מטבע. לראשון יש הסתברות $\alpha$ לעץ ולשני $\beta$. השחקנים מטילים את המטבע במקביל עד שלראשון יוצא עץ. נחשב את תוחלת ההטלות של השחקן השני. נסמן ב־$X$ את מספר ההטלות עד שיצא לשחקן הראשון עץ וב־$Y$ את מספר הפעמים שיצא לשחקן השני עץ. ראשית נבחין כי $X\sim\mathrm{Geom}\left(\alpha\right)$ ו־$Y\mid X\sim\mathrm{Bin}\left(X,\beta\right)$ לפי נוסחת ההחלקה:

$$E\left(Y\right)=E\left(E\left(Y\mid X\right)\right)=E\left(\beta\cdot X\right)=\beta\cdot E\left(X\right)=\frac{\beta}{\alpha}$$

### 12.8 מומנטים

נגדיר כעת מושג אשר יעזור לחקור תכונות של משתנה מקרי.

**הגדרה 10.12** יהא $X$ משתנה מקרי ויהא $1\leq k\in\mathbb{N}$. **המומנט ה־$k$־י** של $X$ (אם הוא מוגדר) הוא $E\left(X^k\right)$.

**הערות:**

1. נאמר כי $X \in L^k(P)$ אם $E\left(|X|^k\right)$ סופי.

2. ראינו כי $P(|X| \geq x) \leq \frac{E(h(|X|))}{h(x)}$ לכל $h$ עולה, בפרט עבור $h(x) = x^k$ כאשר $1 \leq k \in \mathbb{N}$. אם כך נקבל:

$$P(|X| \geq x) \leq \frac{E\left(|X|^k\right)}{|x|^k}$$

נסיק שככל שמומנטים גבוהים יותר קיימים, כך ההסתברות הזנבית דועכת מהר יותר. למעשה המומנטים מתארים את "פיזור המסה" ביחס לתוחלת, כלומר ככל שקיימים מומנטים מסדר גבוה יותר כך המסה (כלומר ההסתברות) מרוכזת יותר סביב התוחלת.

### 12.8.1 פונקציה יוצרת מומנטים

חישוב מומנטים לפי ההגדרה יכול להיות ארוך ומייגע, נראה כעת כלי אשר יקל על החישוב.

**הגדרה 11.12** יהא $X$ משתנה מקרי. **הפונקציה היוצרת מומנטים** של $X$ היא: $M_X(s) = E\left(\mathrm{e}^{sX}\right)$.

**הערות:**

1. ייתכנו נקודות $s$ עבורן $M_X(s) = \infty$.

2. זוהי בעצם התמרת לפלס של משתנה מקרי.

3. ההגדרה היא כללית ונכונה גם עבור משתנים מקריים לא בדידים.

**דוגמאות:**

1. עבור $X \sim \mathrm{Pois}(\lambda)$ נקבל:

$$M_X(s) = E\left(\mathrm{e}^{sX}\right) = \sum_{k=0}^{\infty} \mathrm{e}^{sk} \cdot \mathrm{e}^{-\lambda} \cdot \frac{\lambda^k}{k!} = \mathrm{e}^{-\lambda} \cdot \sum_{k=0}^{\infty} \frac{(\lambda \mathrm{e}^s)^k}{k!} = \mathrm{e}^{-\lambda} \cdot \mathrm{e}^{\mathrm{e}^s \lambda} = \mathrm{e}^{\lambda \mathrm{e}^s - \lambda}$$

2. עבור $X \sim \text{Bin}(n,p)$ נקבל:

$$M_X(s) = E\left(e^{sX}\right) = \sum_{x\in\mathbb{R}} e^{sx}\cdot p_X(x) = \sum_{k=0}^{n} e^{sk}\cdot p_X(k) = \sum_{k=0}^{n} e^{sk}\cdot \binom{n}{k}\cdot p^k\cdot(1-p)^{n-k} =$$
$$= \sum_{k=0}^{n}\binom{n}{k}\cdot\left(e^s\cdot p\right)^k\cdot(1-p)^{n-k} = \left(e^s\cdot p+1-p\right)^n$$

3. נגדיר משתנה $X$ עם פונקציית צפיפות $p_X(k) = \frac{6}{\pi^2k^2}$ לכל $1\le k\in\mathbb{N}$. לפי ההגדרה:

$$M_X(s) = E\left(e^{sX}\right) = \sum_{k=1}^{\infty} e^{stk}p_X(k) = \sum_{k=1}^{\infty}\frac{6e^{stk}}{\pi^2k^2}$$

כעת נפריד לפי ערכי $s$:

**1.** עבור $s=0$ נקבל $M_X(s) = \frac{6}{\pi^2}\sum\limits_{k=1}^{\infty}\frac{1}{k^2} = \frac{6}{\pi^2}\cdot\frac{\pi^2}{6} = 1$.

**2.** עבור $s>0$ האיבר $\frac{6e^{stk}}{\pi^2k^2}$ לא שואף לאפס ולכן הטור מתבדר, כלומר $M_X(s)$ לא מוגדר.

**3.** עבור $s<0$ שימוש במבחן השוואה מראה שהטור $\frac{6e^{stk}}{\pi^2k^2}$ לא שואף לאפס ולכן הטור $\sum\limits_{k=1}^{\infty}\frac{6e^{stk}}{\pi^2k^2}$ מתכנס ולכן $M_X(s)$ מוגדר. פיתוח של הביטוי מניב את הנוסחה הבאה:

$$M_X(s) = \frac{6}{\pi^2}\sum_{k=1}^{\infty}\frac{e^{stk}}{k^2} = -\frac{6}{\pi^2}\int_0^s\frac{\ln(1-t)}{t}dt$$

הפונקציה $-\int\limits_0^s\frac{\ln(1-t)}{t}dt$ נקראת **דילוגריתם** ומסומנת $\text{L}i_2(s)$.

לסיכום עבור המשתמה המקרי הנ"ל הפונקציה יוצרת מומנטים $M_X(s)$ מוגדרת לכל $s\le 0$ והיא:

$$M_X(s) = \begin{cases} 1 & , \quad s=0 \\ -\frac{6}{\pi^2}\text{L}i_2(s) & , \quad s<0 \end{cases}$$

נצטט כעת טענה על תכונות הפונקציה.

**טענה 12.12** יהא $X$ משתנה מקרי.

1. $M_X(s)$ תמיד מוגדרת (סופית) בקטע המכיל את $s=0$.

2. לכל $a,b\in\mathbb{R}$ מתקיים $M_{a\cdot X+b}(s)=\mathrm{e}^{s\cdot b}\cdot M_X(a\cdot s)$.

3. $M_X(s)$ גזירה מכל סדר ב־$s=0$ ומתקיים $M_X^{(k)}(0)=E\left(X^k\right)$.

### 12.8.2 אי־שוויון צ'רנוף

מסקנה חשובה אשר נובעת מפונקציה יוצרת מוננטים היא **אי־שוויון צ'רנוף** (Chernoff bounds):

**משפט 13.12** יהא $X$ משתנה מקרי עם פונקציה יוצרת מומנטים $M_X(s)$ אז:

1. לכל $s>0$ עבורו $M_X(s)$ קיימת מתקיים $P(X\geq a)\leq \mathrm{e}^{-as}M_X(s)$.

2. לכל $s<0$ עבורו $M_X(s)$ קיימת מתקיים $P(X\leq a)\leq \mathrm{e}^{-as}M_X(s)$.

**הערות:**

1. כאשר $M_X(s)$ לא מוגדרת חסם צ'רנוף לא רלוונטי. למשל בדוגמה של משתנה $X$ עם פונקציית צפיפות $p_X(k)=\frac{6}{\pi^2k^2}$ לכל $1\leq k\in\mathbb{N}$ ראינו ש־$M_X(s)$ לא מוגדרת לכל $s>0$.

2. כיוון שהחסמים נכונים לכל $s$ בתחום הרלוונטי נקבל שהביטוי משמאל לא תלוי ב־$s$, מכאן נסיק:

$$P(X\geq a)\leq \inf_{s>0}\left\{\mathrm{e}^{-as}M_X(s)\right\}$$
$$P(X\leq a)\leq \inf_{s<0}\left\{\mathrm{e}^{-as}M_X(s)\right\}$$

**הוכחה:** מתכונות מידת ההסתברות ומונוטוניות האקספוננט נקבל:

$$P(X\geq a)=P\left(\mathrm{e}^{sX}\geq \mathrm{e}^{sa}\right)$$

כעת המשתנה $\mathrm{e}^{sX}$ הוא אי־שלילי לכן לפי מרקוב נקבל שלכל $s>0$ מתקיים:

$$P(X\geq a)=P\left(\mathrm{e}^{sX}\geq \mathrm{e}^{sa}\right)\leq \frac{E\left(\mathrm{e}^{sX}\right)}{\mathrm{e}^{sa}}=\mathrm{e}^{-as}M_X(s)$$

באופן אנלוגי עבור $s<0$.

■

**דוגמה:** ניזכר בדוגמה:

"בהגרלה של כרטיסים להופעה משתתפים 200 אנשים והסיכוי לזכות הוא $p = 10^{-2}$ באופן בלתי־תלוי"

בעזרת מרקוב ראינו שיש סיכוי של לפחות 90% שמספר הזוכים הוא בין 0 ל־19, נבדוק מה צ'רנוף נותן. רוצים $N$ עבורו $P(X \geq N) \leq 0.1$, לכל $s > 0$ נקבל מצ'רנוף:

$$P(X \geq N) \leq \mathrm{e}^{-sN} M_X(s) = \mathrm{e}^{-sN} \left(\mathrm{e}^{s} \cdot 10^{-2} + 1 - 10^{-2}\right)^{200}$$

כעת צריך לחקור את אגף ימין ולהבין עבור אילו ערכי $N$ זה קטן מ־0.1. ישירות זה קצת מייגע ולכן נראה טריק קטן (אשר נקרא לפעמים צורה סטנדרטית של חסם צ'רנוף עבור משתנה בינומי) שהוא שימושי באופן כללי עבור משתנה בינומי בהקשר של חסם צ'רנוף. נסמן $N = E(X)(1+\delta) = 2(1+\delta)$ ונקבל:

$$P(X \geq N) \leq \left(\frac{\mathrm{e}^{\delta}}{(1+\delta)^{1+\delta}}\right)^{2}$$

עבור $N = 6$ נקבל $\delta = 2$ ואז:

$$P(X \geq 6) \leq \left(\frac{\mathrm{e}^{2}}{(1+2)^{1+2}}\right)^{2} \cong 0.07 < 0.1$$

לכן יש סיכוי של לפחות 90% שמספר הזוכים הוא בין 0 ל־5.

### 12.8.3 מומנטים מסדר שני של פילוגים ידועים

נחשב את המומנטים מהסדר השני של הפילוגים שראינו:

- אם $X \sim \mathrm{U}\{x_1, ..., x_n\}$ אז:

$$E\left(X^2\right) = \sum_{x \in \mathbb{R}} x^2 \cdot p_X(x) = \sum_{k=1}^{n} x_k^2 \cdot \frac{1}{n}$$

במקרה בו $X \sim \mathrm{U}\{1, ..., n\}$ נקבל:

$$E\left(X^2\right) = \sum_{k=1}^{n} k^2 \cdot \frac{1}{n} = \frac{1}{n} \cdot \sum_{k=1}^{n} k^2 = \frac{n(n+1)(2n+1)}{6n} = \frac{2n^2+3n+1}{6}$$

- אם $X \sim \mathrm{Bern}(p)$ אז:

$$E\left(X^2\right) = \sum_{x \in \mathbb{R}} x^2 \cdot p_X(x) = 0^2 \cdot (1-p) + 1^2 \cdot p = p$$

- אם $X \sim \text{Bin}(n,p)$ אז:

  - לפי ההגדרה:

$$E\left(X^2\right) = \sum_{k=0}^{n} k^2 \cdot p_X(k) = \sum_{k=0}^{n} k^2 \cdot \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k} =$$

$$= \sum_{k=0}^{n} k^2 \cdot \binom{n}{k} \cdot \left(\frac{p}{1-p}\right)^k \cdot (1-p)^n = p \cdot (1-p)^{n-1} \cdot \sum_{k=1}^{n} k^2 \cdot \binom{n}{k} \cdot \left(\frac{p}{1-p}\right)^{k-1} \underset{(*)}{=}$$

$$= p \cdot (1-p)^{n-1} \cdot \left(1 + \frac{p}{1-p}\right)^{n-2} \cdot \left(\frac{p}{1-p} \cdot n^2 + n\right) = p\left(n^2 p - np + n\right) = np\left(np - p + 1\right)$$

$(*)$ נבחין כי:

$$\sum_{k=0}^{n} k^2 \binom{n}{k} \cdot t^{k-1} = \left(\sum_{k=0}^{n} k \binom{n}{k} \cdot t^k\right)' = \left(t \sum_{k=0}^{n} k \binom{n}{k} \cdot t^{k-1}\right)' = \left(t\left(\sum_{k=0}^{n} k \binom{n}{k} \cdot t^k\right)'\right)' =$$

$$= \left(t\left((t+1)^n\right)'\right)' = \left(t \cdot n (t+1)^{n-1}\right)' = n(t+1)^{n-1} + t \cdot n \cdot (n-1)(t+1)^{n-2} =$$

$$= (t+1)^{n-2} \cdot \left(tn^2 + n\right)$$

ולכן נציב $t = \frac{p}{1-p}$.

  - בעזרת פונקציה יוצרת מומנטים:

ראינו כי $M_X(s) = \left(e^s \cdot p + 1 - p\right)^n$ ולכן:

$$E\left(X^2\right) = M_X^{(2)}(0) = \left(\left(e^s \cdot p + 1 - p\right)^n\right)''|_{s=0} = \left(n \cdot p \cdot e^s \cdot \left(e^s \cdot p + 1 - p\right)^{n-1}\right)'|_{s=0} =$$

$$= \left(n \cdot p \cdot e^s \cdot \left(e^s \cdot p + 1 - p\right)^{n-1} + n \cdot (n-1) \cdot p^2 \cdot e^{2s} \cdot \left(e^s \cdot p + 1 - p\right)^{n-2}\right)|_{s=0} =$$

$$= n \cdot p + n \cdot (n-1) \cdot p^2 = np\left(np - p + 1\right)$$

- אם $X \sim \text{NB}(r,p)$ אז:

$$M_X(s) = E\left(e^{sX}\right) = \sum_{k=0}^{\infty} e^{sk} \cdot \binom{k+r-1}{r-1} p^r \cdot (1-p)^k =$$

$$= p^r \cdot \sum_{k=0}^{\infty} \binom{k+r-1}{r-1} \left(e^s \cdot (1-p)\right)^k \underset{(*)}{=} \left(\frac{p}{1 - e^s \cdot (1-p)}\right)^r$$

לפיכך:

$$E\left(X^2\right)=M_X^{(2)}(0)=p^r\cdot\left(\left(1-\mathrm{e}^s\cdot(1-p)\right)^{-r}\right)''\,|_{s=0}=\cdots=r\cdot\frac{(1-p)\cdot(2-p)}{p^2}$$

(*) כזכור: $\sum_{l=0}^{\infty}\binom{m+l-1}{l}x^l=\sum_{k=0}^{\infty}D(m,l)\,x^l=\left(\frac{1}{1-x}\right)^m$. כמו כן השוויון תקף כאשר $s<\ln\frac{1}{1-p}$.

- אם $X\sim\mathrm{Geom}(p)$ אז:

$$M_X(s)=E\left(\mathrm{e}^{sX}\right)=\sum_{k=1}^{\infty}\mathrm{e}^{sk}\cdot p\cdot(1-p)^{k-1}=\mathrm{e}^s\cdot p\cdot\sum_{k=1}^{\infty}\mathrm{e}^{s(k-1)}\cdot(1-p)^{k-1}=$$
$$=\mathrm{e}^s\cdot p\cdot\sum_{k=0}^{\infty}\left(\mathrm{e}^s\cdot(1-p)\right)^k=\frac{\mathrm{e}^s\cdot p}{1-\mathrm{e}^s\cdot(1-p)}$$

לפיכך:

$$\begin{aligned}E\left(X^2\right)&=M_X^{(2)}(0)=p\cdot\left(\frac{\mathrm{e}^s}{1-\mathrm{e}^s\cdot(1-p)}\right)''\,|_{s=0}=\\&=p\cdot\left(\frac{\mathrm{e}^s\cdot(1-\mathrm{e}^s\cdot(1-p))+\mathrm{e}^s\cdot\mathrm{e}^s\cdot(1-p)}{\left(1-\mathrm{e}^s\cdot(1-p)\right)^2}\right)'\,|_{s=0}=\\&=p\cdot\left(\frac{\mathrm{e}^s}{\left(1-\mathrm{e}^s\cdot(1-p)\right)^2}\right)'\,|_{s=0}=\\&=p\cdot\frac{\mathrm{e}^s\cdot\left(1-\mathrm{e}^s\cdot(1-p)\right)^2+\mathrm{e}^s\cdot2\cdot\left(1-\mathrm{e}^s\cdot(1-p)\right)\cdot\mathrm{e}^s\cdot(1-p)}{\left(1-\mathrm{e}^s\cdot(1-p)\right)^4}\,|_{s=0}=\\&=p\cdot\frac{p^2+2\cdot p\cdot(1-p)}{p^4}=\frac{p+2\cdot(1-p)}{p^2}=\frac{2-p}{p^2}\end{aligned}$$

- אם $X\sim\mathrm{HG}(n,N,D)$, במקרה זה החישוב לפי ההגדרה עדיף מאשר חישוב פונקציה יוצרת מומנטים:

$$E\left(X^2\right)=\sum_{k=1}^{n}k^2\cdot\frac{\binom{D}{k}\cdot\binom{N-D}{n-k}}{\binom{N}{n}}=\cdots=n\cdot\frac{D}{N}\cdot\left(\frac{(n-1)\cdot(D-1)}{N-1}+1\right)$$

- אם $X \sim \text{Pois}(\lambda)$ ראינו כי $M_X(s) = e^{\lambda e^s - \lambda}$, לפיכך:

$$E\left(X^2\right) = M_X^{(2)}(0) = \left(e^{\lambda e^s - \lambda}\right)'' |_{s=0} = \left(e^{\lambda e^s - \lambda} \cdot \lambda e^s\right)' |_{s=0} =$$
$$= \left(\left(e^{\lambda e^s - \lambda} \cdot \lambda e^s\right) \cdot \lambda e^s + e^{\lambda e^s - \lambda} \cdot \lambda e^s\right) |_{s=0} = \lambda^2 + \lambda$$

## 13 השונות

רוצים לדעת איך ערכי $X$ מפוזרים ביחס לתוחלת, כלומר מהו ממוצע המרחקים בין $X$ ל־$E(X)$. אם כך הגיוני לחשב את התוחלת של $|X - E(X)|$, עם זאת משיקולי גזירות ושיקולים נוספים ניקח את ההפרש בריבוע.

**הגדרה 1.13** יהא $X \in L^2(P)$, **השונות** של $X$ היא:

$$var(X) = E\left((X - E(X))^2\right)$$

**סטיית התקן** של $X$ היא

$$\sigma_X = \sqrt{var(X)}$$

**הערות:**

1. לפי ההגדרה, השונות היא תמיד אי־שלילית.

2. סטיית התקן מנסה לנרמל את העיוות ולמדוד את "ממוצע המרחקים האמיתי" בין ערכי $X$ לתוחלת. עם זאת, סטיית התקן לא מתקנת לחלוטין את העיוות שנוצר מהעלאת המרחק בריבוע, זאת כיוון שהריבוע נותן משקל גדול יותר לסטיות גדולות מאשר לסטיות קטנות ופעולת השורש לא מבטלת את האפקט הזה.

3. אם $X \in L^2(P)$ אז ישירות מההגדרת השונות ותכונות התוחלת נקבל:

$$var(X) = E\left((X - E(X))^2\right) = E\left(X^2 - 2 \cdot X \cdot E(X) + (E(X))^2\right) =$$
$$= E\left(X^2\right) - 2E(X) \cdot E(X) + (E(X))^2 = E\left(X^2\right) - (E(X))^2$$

לכן על מנת לחשב את השונות יש לחשב את התוחלת והמומנט השני.

**דוגמה:** נחשב את השונות של הערכים בהטלת קוביה הוגנת. נסמן ב־$X$ את הערכים ונחשב לפי ההגדרה:

$$var\left(X\right)=E\left(\left(X-E\left(X\right)\right)^2\right)=E\left(\left(X-\frac{7}{2}\right)^2\right)=E\left(X^2-7\cdot X+\frac{49}{4}\right)=$$
$$=E\left(X^2\right)-7\cdot E\left(X\right)+E\left(\frac{49}{4}\right)=\frac{1^2+\cdots+6^2}{6}-7\cdot\frac{7}{2}+\frac{49}{4}=\frac{35}{12}$$

### 13.1 השונות של הפילוגים הידועים

נחשב את השונות של הפילוגים שראינו:

- אם $X\sim\mathrm{U}\left\{x_1,...,x_n\right\}$ אז:

$$var\left(X\right)=E\left(X^2\right)-\left(E\left(X\right)\right)^2=\frac{1}{n}\cdot\sum_{k=1}^{n}x_k^2-\left(\frac{1}{n}\cdot\sum_{k=1}^{n}x_k\right)^2$$

במקרה בו $X\sim\mathrm{U}\left\{1,...,n\right\}$ נקבל:

$$var\left(X\right)=E\left(X^2\right)-\left(E\left(X\right)\right)^2=\frac{n\left(n+1\right)\left(2n+1\right)}{6n}-\left(\frac{n+1}{2}\right)^2=\frac{n^2-1}{12}$$

- אם $X\sim\mathrm{Bern}\left(p\right)$ אז:

$$var\left(X\right)=E\left(X^2\right)-\left(E\left(X\right)\right)^2=p-p^2$$

- אם $X\sim\mathrm{Bin}\left(n,p\right)$ אז:

$$var\left(X\right)=np\left(np-p+1\right)-\left(np\right)^2=np\left(1-p\right)$$

- אם $X\sim\mathrm{NB}\left(r,p\right)$ אז:

$$var\left(X\right)=r\cdot\frac{\left(1-p\right)\cdot\left(2-p\right)}{p^2}-\left(r\cdot\frac{1-p}{p}\right)^2=r\cdot\frac{1-p}{p^2}$$

- אם $X \sim \text{Geom}(p)$ אז:

$$var(X) = \frac{2-p}{p^2} - \left(\frac{1}{p}\right)^2 = \frac{1-p}{p^2}$$

- אם $X \sim \text{HG}(n, N, D)$, במקרה זה החישוב לפי ההגדרה עדיף מאשר חישוב פונקציה יוצרת מומנטים:

$$var(X) = n \cdot \frac{D}{N} \cdot \left(\frac{(n-1)\cdot(D-1)}{N-1} + 1\right) - \left(n \cdot \frac{D}{N}\right)^2 = n \cdot \frac{D \cdot (N-D) \cdot (N-n)}{N^2 \cdot (N-1)}$$

- אם $X \sim \text{Pois}(\lambda)$ אז:

$$var(X) = \lambda^2 + \lambda - (\lambda)^2 = \lambda$$

### 13.2 תכונות בסיסיות

ננסח ונוכיח מספר תכונות בסיסיות של השונות

**טענה 2.13** יהא $X \in L^2(P)$, אז:

1. לכל $a \in \mathbb{R}$ מתקיים $var(aX) = a^2 \cdot var(X)$.
2. לכל $b \in \mathbb{R}$ מתקיים $var(X+b) = var(X)$.
3. $X$ משתנה מקרי קבוע אם ורק אם $var(X) = 0$.
4. אם $Y \in L^2(P)$ ובלתי־תלוי ב־$X$ אז $var(X+Y) = var(X) + var(Y)$.

**הוכחה:** התכונות נובעות ישירות מההגדרה ותכונות התוחלת, נחשב:

1. לכל $a \in \mathbb{R}$ נקבל:

$$var(aX) = E\left(a^2 \cdot X^2\right) - (E(a \cdot X))^2 = a^2 \cdot \left(E\left(X^2\right) - (E(X))^2\right) = a^2 \cdot var(X)$$

2. לכל $b \in \mathbb{R}$ נקבל:

$$var(X+b) = E\left((X+b-E(X+b))^2\right) =$$
$$= E\left((X+b-E(X)+b)^2\right) = E\left(X^2\right) - (E(X))^2 = var(X)$$

3. $\Leftarrow$: אם $X = c$ משתנה מקרי קבוע אז בבירור $var(X) = E\left((c-E(c))^2\right) = E\left((c-c)^2\right) = 0$.
$\Rightarrow$: אם $var(X) = 0$ אז $E\left((X-E(X))^2\right) = 0$. נניח שלא, נסמן $Y = (X-E(X))^2$ ואז יש $x_0 \neq 0$ עבורו $P_Y(x_0) > 0$. נבחין כי $Y$ אי־שלילי לכן $x_0 > 0$ וכן התוחלת של $Y$ אי־שלילית. כעת נקבל $0 = E\left((X-E(X))^2\right) = E(Y) \geq x_0 \cdot p_Y(x_0) \neq 0$ וזאת סתירה. מכאן, $(X-E(X))^2$ הוא משתנה קבוע השווה לאפס, כלומר $X$ הוא משתנה קבוע השווה ל־$E(X)$.

4. נחשב:

$$var(X+Y) = E\left((X+Y)^2\right) - (E(X+Y))^2 = E\left(X^2 + 2\cdot XY + Y^2\right) - (E(X)+E(Y))^2 =$$
$$= E\left(X^2\right) + 2\cdot E(XY) + E\left(Y^2\right) - (E(X))^2 - 2\cdot E(X)\cdot E(Y) - (E(Y))^2$$
$$= E\left(X^2\right) - (E(X))^2 + E\left(Y^2\right) - (E(Y))^2 = var(X) + var(Y)$$

■

**דוגמאות:**

1. מחלקים 16 אנשים ל־8 זוגות. כל זוג מבצע משימה זהה באופן בלתי־תלוי עם הסתברות של $\frac{1}{5}$ להצלחה. נחשב את השונות של מספר האנשים שהצליחו במשימה. נסמן ב־$X$ את מספר הזוגות שהצליחו. ברור כי $X \sim \text{Bin}\left(8, \frac{1}{5}\right)$, לכן $E(X) = 8\cdot\frac{1}{5} = \frac{8}{5},\ var(X) = 8\cdot\frac{1}{5}\cdot\frac{4}{5} = \frac{32}{25}$. רוצים את:

$$var(2\cdot X) = 2^2\cdot var(X) = 4\cdot\frac{32}{25} = \frac{128}{25}$$

2. נתונים 20 כדורים: 5 אדומים, 5 לבנים, 5 צהובים ו־5 שחורים. מוציאים (עם החזרות) כדורים עד שמוציאים כדור בצבע שונה מהכדור הראשון שיצא. נחשב את השונות של מספר הכדורים שהוצאנו. נסמן ב־$X$ את מספר הכדורים שהוצאנו. נבחין כי $X$ מפולג גיאומטרית עם הזזה של 1 ופרמטר הצלחה של $\frac{3}{4}$, לכן אם נגדיר $Y = X - 1$ נקבל כי $Y \sim \text{Geom}\left(\frac{3}{4}\right)$. לפיכך:

$$var\left(X\right) = var\left(Y+1\right) = Var\left(Y\right) = \frac{1-\frac{3}{4}}{\left(\frac{3}{4}\right)^2} = \frac{4}{9}$$

### 13.3 אי־שוויון צ'בישב

בדומה למרקוב, נקבל קשר בין הסתברות של מרחק בין $X$ לתוחלת לחסם הקשור לשונות. הקירוב כאן בד"כ טוב יותר ממרקוב.

**משפט 3.13** (**אי־שוויון צ'בישב**) יהא $X \in L^2\left(P\right)$, אז לכל $\delta > 0$ מתקיים:

$$P\left(\left|X - E\left(X\right)\right| \geq \delta\right) \leq \frac{var\left(X\right)}{\delta^2}$$

**הערה:** לפעמים רושמים באופן שקול $P\left(\left|X - E\left(X\right)\right| \geq a \cdot \sigma_X\right) \leq \frac{1}{a^2}$ לכל $a > 0$.

**הוכחה:** נפעיל את המסקנה ממרקוב עבור $Y = X - E\left(X\right)$ והפונקציה $h\left(t\right) = t^2$ ונקבל:

$$P\left(\left|X - E\left(X\right)\right| \geq \delta\right) = P\left(\left|Y\right| \geq \delta\right) \leq \frac{E\left(\left|Y\right|^2\right)}{\delta^2} = \frac{E\left(\left(X - E\left(X\right)\right)^2\right)}{\delta^2} = \frac{var\left(X\right)}{\delta^2}$$

■

**דוגמאות:**

1. נניח כי $X$ מתאר את מספר המוצרים המיוצרים במפעל ביום. נבדוק מה ניתן לומר על ההסתברות שמיוצרים בין 20 ל־80 מוצרים ביום אם ידוע כי $E(X)=50$ ו־$var(X)=15$. מצ'בישב נקבל:

$$P(|X-50|\geq 31)\leq \frac{15}{(31)^2}$$

לכן:

$$P(20\leq X\leq 80)=1-P(|X-50|\geq 31)\geq 1-\frac{15}{(31)^2}\simeq 0.98$$

לכל יש סיכוי של לפחות $98\%$ שהמפעל ייצר בין 20 ל־80 מוצרים ביום.

2. בהגרלה של כרטיסים להופעה משתתפים 200 אנשים והסיכוי לזכות הוא $p=10^{-2}$ באופן בלתי־תלוי. נמצא טווח ערכים בו נוכל לומר שיש סיכוי של $90\%$ לפחות שמספר הזוכים הוא בטווח הזה. נסמן ב־$X$ את מספר הזוכים, אז $X\sim \text{Bin}(200,10^{-2})$ וכן $E(X)=2,\ var(X)=2\cdot(1-10^{-2})=1.98$ . מחפשים $N\in\mathbb{N}$ עבורו מתקיים $P(|X-2|\geq N)\leq 0.1$. מצ'בישב נקבל:

$$P(|X-2|\geq N)\leq \frac{1.98}{N^2}$$

נדרוש $\frac{1.98}{N^2}\leq 0.1$ ונקבל $19.8\leq N^2$ כלומר $5\leq N$. נסיק שיש סיכוי של לפחות $90\%$ שמספר הזוכים הוא בין 0 ל־6.

**הערה:** כזכור, חישוב דומה עם מרקוב עבור אותם הפרמטרים נתן טווח של בין 0 ל־19.

### 13.4 שונות משותפת

רוצים להבין את הקשר בין משתנים מקריים שונים, כלומר איך הם משפיעים אחד על השני.

**הגדרה 4.13** יהיו $X,Y\in L^2(P)$, **השונות המשותפת** (**קוריאנס**) בין $X$ ל־$Y$ היא:

$$\sigma_{X,Y}=cov(X,Y)=E((X-E(X))\cdot(Y-E(Y)))$$

**הערות:**

1. הקוריאנס תמיד מוגדר, אפשר להוכיח זאת בעזרת אי־שוויון הממוצעים.

2. הקוריאנס מודד בין היתר את הקשר הבא: אם כאשר $X$ גדל גם $Y$ גדל אז נצפה לקוריאנס חיובי. עם זאת, אם כאשר $X$ גדל $Y$ דווקא קטן לצפה לקבל קוריאנס שלילי.

3. בדומה לשונות, נקבל נוסחה נוחה לחישוב ישירות מההגדרה:

$$\begin{aligned} cov\left(X,Y\right) &= E\left(\left(X-E\left(X\right)\right)\cdot\left(Y-E\left(Y\right)\right)\right) = \\ &= E\left(XY-E\left(Y\right)\cdot X-E\left(X\right)\cdot Y+E\left(X\right)\cdot E\left(Y\right)\right) = \\ &= E\left(XY\right)-E\left(Y\right)\cdot E\left(X\right)-E\left(X\right)\cdot E\left(Y\right)+E\left(X\right)\cdot E\left(Y\right) = \\ &= E\left(XY\right)-E\left(Y\right)\cdot E\left(X\right) \end{aligned}$$

**דוגמאות:**

1. מטילים מטבע הוגן $n$ פעמים. נסמן ב־$X$ את מספר הפעמים שיצא עץ וב־$Y$ פלי, נצפה לקבל $cov\left(X,Y\right)<0$.
ראשית ברור כי $X,Y\sim\text{Bin}\left(n,\frac{1}{2}\right)$, לכן $E\left(X\right)=E\left(Y\right)=\frac{n}{2}$. כמו כן $X+Y=n$ לכן:

$$E\left(XY\right)=E\left(X\cdot\left(n-X\right)\right)=n\cdot E\left(X\right)-E\left(X^2\right)=\frac{n^2}{2}-\frac{n}{2}\cdot\left(\frac{n}{2}+\frac{1}{2}\right)=\frac{n}{4}\cdot\left(n-1\right)$$

כעת נחשב את הקוריאנס:

$$cov\left(X,Y\right)=E\left(XY\right)-E\left(Y\right)\cdot E\left(X\right)=\frac{n}{4}\cdot\left(n-1\right)-\left(\frac{n}{2}\right)^2=-\frac{n}{4}<0$$

2. נניח $Y \sim \text{Pois}(\lambda)$ מקבל ערכים טבעיים. מבצעים $Y$ ניסויי ברנולי ונסמן ב־$X$ את מספר ההצלחות. נצפה לקבל $cov(X,Y) > 0$. ראשית נבחין כי $X \mid Y \sim \text{Bin}(Y,p)$ ולכן מנוסחת ההחלקה:

$$E(X) = E(E(X \mid Y)) = E(p \cdot Y) = p \cdot E(Y) = \lambda \cdot p$$
$$E(XY) = E(E(XY \mid Y)) = E(Y \cdot E(X \mid Y)) = E(Y \cdot Y \cdot p) = p \cdot E\left(Y^2\right) = p \cdot \left(\lambda^2 + \lambda\right)$$

כעת נחשב את הקוואריאנס:

$$cov(X,Y) = E(XY) - E(Y) \cdot E(X) = p \cdot \left(\lambda^2 + \lambda\right) - (\lambda \cdot p)^2 = \lambda \cdot p > 0$$

**הערה:** ראינו כאן למעשה טענה כללית אשר מכונה לפעמים גם **פיצול פואסון**, אם $Y \sim \text{Pois}(\lambda)$ ו־$X \mid Y \sim \text{Bin}(Y,p)$ אז $X \sim \text{Pois}(\lambda \cdot p)$.

נוכיח כעת מספר תכונות בסיסיות של הקוואריאנס.

**טענה 5.13** יהיו $X, Y, Z \in L^2(P)$ משתנים מקריים.

1. חילופיות: $cov(X,Y) = cov(Y,X)$.
2. בילינאריות: לכל $a \in \mathbb{R}$ מתקיים:

$$\begin{cases} cov(a \cdot X + Y, Z) = a \cdot cov(X,Z) + cov(Y,Z) \\ cov(X, a \cdot Y + Z) = a \cdot cov(X,Y) + cov(X,Z) \end{cases}$$

3. קבוע: לכל $a \in \mathbb{R}$ מתקיים:

$$\begin{cases} cov(X,a) = 0 \\ cov(X+a, Y) = cov(X,Y) \end{cases}$$

4. אי־תלות: אם $X, Y$ בלתי־תלויים אז $cov(X,Y) = 0$.
5. סכום: $var(X+Y) = var(X) + var(Y) + 2 \cdot cov(X,Y)$.
באופן כללי: $var\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} var(X_k) + 2 \cdot \sum_{1 \le k < m \le n} cov(X_k, X_m)$.

**הערה:** הכיוון ההפוך של 4 לא נכון, כלומר אם $cov\left(X,Y\right)=0$ אז לא בהכרח מקיים ש־$X,Y$ בלתי־תלויים.
למשל עבור $X\sim\mathrm{U}\left\{-1,0,1\right\}$ ו־$Y=X^2$ נקבל $cov\left(X,Y\right)=0$ אך $Y,X$ תלויים.

**הוכחה:** התכונות נובעות ישירות מההגדרה ותכונות התוחלת והשונות.

1. חילופיות:

$$cov\left(X,Y\right)=E\left(\left(X-E\left(X\right)\right)\cdot\left(Y-E\left(Y\right)\right)\right)=E\left(\left(Y-E\left(Y\right)\right)\cdot\left(X-E\left(X\right)\right)\right)=cov\left(Y,X\right)$$

2. בילינאריות:

$$\begin{aligned}cov\left(a\cdot X+Y,Z\right)&=E\left(\left(a\cdot X+Y-E\left(a\cdot X+Y\right)\right)\cdot\left(Z-E\left(Z\right)\right)\right)=\\&=E\left(\left(a\cdot X+Y-a\cdot E\left(X\right)-E\left(Y\right)\right)\cdot\left(Z-E\left(Z\right)\right)\right)=\cdots=\\&=a\cdot\left(E\left(X\cdot Z\right)-E\left(Z\right)\cdot E\left(X\right)\right)+E\left(Y\cdot Z\right)-E\left(Y\right)\cdot E\left(Z\right)=\\&=a\cdot cov\left(X,Z\right)+cov\left(Y,Z\right)\end{aligned}$$

3. לכל $a\in\mathbb{R}$ נקבל:

$$\begin{aligned}cov\left(X,a\right)&=E\left(X\cdot a\right)-E\left(X\right)\cdot E\left(a\right)=a\cdot E\left(X\right)-E\left(X\right)\cdot a=0\\cov\left(X+a,Y\right)&=cov\left(X,Y\right)+cov\left(a,Y\right)=cov\left(X,Y\right)\end{aligned}$$

4. אם $X,Y$ בלתי־תלויים אז:

$$cov\left(X,Y\right)=E\left(X\cdot Y\right)-E\left(X\right)\cdot E\left(Y\right)=E\left(X\right)\cdot E\left(Y\right)-E\left(X\right)\cdot E\left(Y\right)=0$$

5. סכום:

$$\begin{aligned}var\left(X+Y\right)&=cov\left(X+Y,X+Y\right)=\\&=cov\left(X,X\right)+cov\left(Y,Y\right)+2\cdot cov\left(X,Y\right)=var\left(X\right)+var\left(Y\right)+2\cdot cov\left(X,Y\right)\end{aligned}$$

■

**דוגמאות:**

1. מטילים קוביה $n$ פעמים ומסמנים ב־$X$ את מספר הפעמים שיצא 3. מטילים שוב את הקוביה $X$ פעמים ומסמנים ב־$Y$ את מספר הפעמים שיצא 3. נחשב את השונות של סך כל הפעמים שיצא 3, כלומר את $var(X+Y)$. ראשית ברור כי $X \sim \text{Bin}\left(n, \frac{1}{6}\right)$ ו־$Y \mid X \sim \text{Bin}\left(X, \frac{1}{6}\right)$, לכן:

$$
\begin{aligned}
var(X) &= n \cdot \frac{1}{6} \cdot \frac{5}{6} = \frac{5n}{36} \\
E(Y) &= E(E(Y \mid X)) = E\left(\frac{1}{6} \cdot X\right) = \frac{1}{6} \cdot E(X) = \frac{n}{36} \\
E\left(Y^2\right) &= E\left(E\left(Y^2 \mid X\right)\right) \underset{(*)}{=} E\left(\frac{1}{36} \cdot X^2 - \frac{1}{36} \cdot X + \frac{1}{6} \cdot X\right) = \\
&= \frac{1}{36} \cdot E\left(X^2\right) + \frac{5}{36} \cdot E(X) = \frac{1}{36} \cdot \frac{n}{6}\left(\frac{n}{6} + \frac{5}{6}\right) + \frac{5}{36} \cdot \frac{n}{6} = \frac{n^2 + 35n}{6^4} \\
var(Y) &= E\left(Y^2\right) - (E(Y))^2 = \frac{n^2 + 35n}{6^4} - \left(\frac{n}{36}\right)^2 = \frac{35n}{6^4}
\end{aligned}
$$

$(*)$ שימוש בזהות $E\left(Y^2 \mid X\right) = var(Y \mid X) + (E(Y \mid X))^2$.

$$
\begin{aligned}
E(X \cdot Y) &= E(E(X \cdot Y \mid X)) = E(X \cdot E(Y \mid X)) = E\left(X \cdot \frac{1}{6} \cdot X\right) = \frac{1}{6} \cdot E\left(X^2\right) = \frac{n^2 + 5n}{6^3} \\
cov(X, Y) &= E(X \cdot Y) - E(X) \cdot E(Y) = \frac{n^2 + 5n}{6^3} - \frac{n}{6} \cdot \frac{n}{36} = \frac{5n}{6^3}
\end{aligned}
$$

כעת ניתן לחשב את השונות המבוקשת:

$$
var(X+Y) = var(X) + var(Y) + 2 \cdot cov(X, Y) = \frac{5n}{36} + \frac{35n}{6^4} + 2 \cdot \frac{5n}{6^3} = \frac{311n}{6^4}
$$

2. מטילים מטבע $n$ פעמים. נסמן ב־$X$ את מספר הפעמים בהם יצא עץ ואז מיד פלי. נחשב את השונות של $X$. נגדיר אינדיקטורים $X_k$ המציינים שבהטלה ה־$k$־ית יצא עץ ואז מיד פלי. ברור כי $1 \le k \le n-1$ וכן $X = \sum_{k=1}^{n-1} X_k$. ראשית לכל $k$ נקבל $var(X_k) = E(X^2) - (E(X))^2 = \frac{1}{4} - \left(\frac{1}{4}\right)^2 = \frac{3}{16}$. כעת, אם $m, k$ לא

עוקבים אז מאי־תלות נקבל $cov\left(X_m,X_k\right)=0$. עבור ערכים עוקבים נקבל:

$$cov\left(X_m,X_{m+1}\right)=E\left(X_m\cdot X_{m+1}\right)-E\left(X_m\right)\cdot E\left(X_{m+1}\right)\underset{(*)}{=}0-\left(\frac{1}{4}\right)^2$$

$(*)$ אם $X_m=X_{m+1}=1$ אז ההטלה ה־$m+1$ היא גם עץ וגם פלי, זה לא אפשרי. לכן המכפלה בהכרח שווה לאפס.

מכאן:

$$var\left(X\right)=\sum_{k=1}^{n-1}var\left(X_k\right)+2\cdot\sum_{m=1}^{n-2}cov\left(X_m,X_{m+1}\right)=\sum_{k=1}^{n-1}\frac{3}{16}+2\cdot\sum_{m=1}^{n-2}\left(-\frac{1}{16}\right)=\frac{n+1}{16}$$

### 13.5 שונות מותנית והחלקה לשונות

בדומה לתוחלת מותנית נגדיר כעת שונות מותנית.

**הגדרה 6.13** יהא $(X,Y)$ וקטור אקראי בדיד כך ש־$E\left(X^2\right),E\left(Y^2\right)$ סופיים. **השונות המותנית** של $Y$ בהינתן $X=x$ היא:

$$var\left(Y\mid X=x\right)=\sum_{y\in\mathbb{R}}\left(y-E\left(Y\mid X=x\right)\right)^2\cdot P_{Y|X}\left(y\mid x\right)$$

**דוגמה:** נניח ש־$X,Y$ מתארים ערך של קוביה הוגנת ונסמן $Z=X+Y$. נחשב את השונות של $X\mid Z=7$.
ראשית נבחין שהמשתנה $X\mid Z=7$ יכול לקבל כל ערך בין 1 ל־6 באופן אחיד, כלומר $X\mid Z=7\sim\mathrm{U}\left\{1,...,6\right\}$. לפיכך:

$$var\left(X\mid Z=7\right)=\sum_{x=1}^{6}\left(x-E\left(X\mid Z=7\right)\right)^2\cdot P_{X|Z}\left(x\mid 7\right)=\sum_{x=1}^{6}\left(x-\frac{21}{6}\right)^2\cdot\frac{1}{6}=\cdots=\frac{35}{12}$$

למעשה ברגע שראינו שהמשתנה מפולג באופן אחיד אפשר היה להשתמש בתוחלת והשונות של פילוג אחיד.
כלומר לפי הנוסחה נקבל:

$$var\left(X\mid Z=7\right)=\frac{6^2-1}{12}=\frac{35}{12}$$

ננסח ונוכיח תכונות בסיסיות.

**טענה 7.13** יהא $(X,Y)$ וקטור אקראי בדיד כך ש־$E\left(X^2\right),E\left(Y^2\right)$ סופיים, אז:

1. $var\left(Y \mid X\right) = E\left(Y^2 \mid X\right) - \left(E\left(Y \mid X\right)\right)^2$.

2. **החלקה לשונות**: $var\left(Y\right) = E\left(var\left(Y \mid X\right)\right) + var\left(E\left(Y \mid X\right)\right)$.

**הוכחה:**

1. מחישוב ישיר ושימור בהגדרות נקבל:

$$\begin{aligned}
var\left(Y \mid X\right) &= \sum_{y\in\mathbb{R}} \left(y - E\left(Y \mid X\right)\right)^2 \cdot P_{Y|X}\left(y \mid x\right) = \\
&= \sum_{y\in\mathbb{R}} \left(y^2 - 2yE\left(Y \mid X\right) + \left(E\left(Y \mid X\right)\right)^2\right) \cdot P_{Y|X}\left(y \mid x\right) = \\
&= \sum_{y\in\mathbb{R}} y^2 \cdot P_{Y|X}\left(y \mid x\right) - 2E\left(Y \mid X\right) \cdot \sum_{y\in\mathbb{R}} y \cdot P_{Y|X}\left(y \mid x\right) + \left(E\left(Y \mid X\right)\right)^2 \cdot \sum_{y\in\mathbb{R}} P_{Y|X}\left(y \mid x\right) = \\
&= E\left(Y^2 \mid X\right) - 2E\left(Y \mid X\right) \cdot E\left(Y \mid X\right) + \left(E\left(Y \mid X\right)\right)^2 \cdot 1 = E\left(Y^2 \mid X\right) - \left(E\left(Y \mid X\right)\right)^2
\end{aligned}$$

2. נפתח את השונות של $Y$ ע"י שימוש בנוסחת ההחלקה:

$$\begin{aligned}
var\left(Y\right) &= E\left(Y^2\right) - \left(E\left(Y\right)\right)^2 = E\left(E\left(Y^2 \mid X\right)\right) - \left(E\left(E\left(Y \mid X\right)\right)\right)^2 = \\
&= E\left(E\left(Y^2 \mid X\right)\right) - \left(E\left(E\left(Y \mid X\right)\right)\right)^2 + E\left(\left(E\left(Y \mid X\right)\right)^2\right) - E\left(\left(E\left(Y \mid X\right)\right)^2\right) = \\
&= E\left(E\left(Y^2 \mid X\right) - \left(E\left(Y \mid X\right)\right)^2\right) + E\left(\left(E\left(Y \mid X\right)\right)^2\right) - \left(E\left(E\left(Y \mid X\right)\right)\right)^2 = \\
&= E\left(var\left(Y \mid X\right)\right) + var\left(E\left(Y \mid X\right)\right)
\end{aligned}$$

■

**דוגמה:** נניח כי $N \sim \text{Pois}(\lambda)$ ו־$X \mid N \sim \text{Bin}(N,p)$. נחשב את $var(X)$. ראשית מחישובים קודמים:

$$var(X \mid N) = Np(1-p), \;\; E(X \mid N) = Np$$

מכאן:

$$var(X) = E(var(X \mid N)) + var(E(X \mid N)) = E(Np(1-p)) + var(Np) =$$
$$= p(1-p)E(N) + p^2 var(N) = p(1-p)\lambda + p^2\lambda = \lambda p$$

**הערה:** ראינו שלפי פיצול פואסון אם $N \sim \text{Pois}(\lambda)$ ו־$X \mid N \sim \text{Bin}(N,p)$ אז $X \sim \text{Pois}(\lambda \cdot p)$. לכן השונות של $X$ היא השונות של משתנה פואסוני.

### 13.6 מקדם המתאם

הקוריאנס מודד את הקשר בין משתנים שונים אך רגיש ליחידות.

**דוגמה:** אם $X_!, X_2$ נמדדים במטרים אז $Y_1 = 100 \cdot X_1, \;\; Y_2 = 100 \cdot X_2,$ נמדדים בסנטימטרים. נבחין כי:

$$cov(Y_1, Y_2) = cov(100 \cdot X_1, 100 \cdot X_2) = 10^4 \cdot cov(X_1, X_2)$$

כלומר הקוריאנס בין $Y_1, Y_2$ יהיה גדול (בערכו המוחלט) ב־$10^4$ מהקוריאנס של $X_1, X_2$.

זה לא הגיוני שהמדד של השונות ישנה את ערכו אם מחליפים יחידות, לכן רוצים לנרמל אותו.

**הגדרה 8.13** יהיו $X, Y \in L^2(P)$ לא קבועים, **מקדם המתאם** (**הקורולציה**) בין $X$ ל־$Y$ הוא $\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \cdot \sigma_Y}$.

ראשית נוכיח את התכונות הבסיסיות ואז נראה דוגמאות.

**טענה 9.13** יהיו $X, Y \in L^2(P)$ לא קבועים.

1. לכל $a \in \mathbb{R}$ מתקיים $\rho_{X+a,Y} = \rho_{X,Y}$.
2. לכל $0 \neq a \in \mathbb{R}$ מתקיים $\rho_{a \cdot X,Y} = \text{sgn}(a) \cdot \rho_{X,Y}$.
3. $|cov(X,Y)| \leq \sigma_X \cdot \sigma_Y$, בפרט $|\rho_{X,Y}| \leq 1$.

**הערות:**

1. אי־השוויון $|cov(X,Y)| \leq \sigma_X \cdot \sigma_Y$ הוא למעשה **אי־שוויון קושי־שוורץ** במרחב $L^2(P)$.

2. מתקיים $|\rho_{X,Y}| = 1$ אם ורק אם יש $b \in \mathbb{R}$, $0 \neq a \in \mathbb{R}$ עבורם $X = a \cdot Y + b$.

3. באופן אינטואיטיבי, ככל ש־$|\rho_{X,Y}|$ קרוב יותר ל־1 כך הקשר בין $X$ ל־$Y$ הוא "הדוק" יותר. כמו כן ככל ש־$|\rho_{X,Y}|$ קרוב יותר ל־0 נסיק שאין קשר/תלות בין $X$ ל־$Y$.

**הוכחה:**

1. ישירות מההגדרה:

$$\rho_{X+a,Y} = \frac{cov(X+a,Y)}{\sigma_{X+a} \cdot \sigma_Y} = \frac{cov(X,Y)}{\sigma_X \cdot \sigma_Y} = \rho_{X,Y}$$

2. ישירות מההגדרה:

$$\rho_{a \cdot X,Y} = \frac{cov(a \cdot X,Y)}{\sigma_{a \cdot X} \cdot \sigma_Y} = \frac{a \cdot cov(X,Y)}{|a| \cdot \sigma_X \cdot \sigma_Y} = \operatorname{sgn}(a) \cdot \rho_{X,Y}$$

3. לכל $t \in \mathbb{R}$ מתקיים:

$$\begin{aligned} 0 &\leq var(t \cdot X + Y) = cov(t \cdot X + Y, t \cdot X + Y) = \\ &= t^2 cov(X,X) + 2t \cdot cov(X,Y) + cov(Y,Y) = \\ &= t^2 \cdot var(X) + 2t \cdot cov(X,Y) + var(Y) = t^2 \cdot \sigma_X^2 + 2t \cdot cov(X,Y) + \sigma_Y^2 \end{aligned}$$

קיבלנו פולינום ריבועי אי־שלילי במשתנה $t$, לכן הדיסקרימיננטה שלו היא אי־חיובית, כלומר:

$$(2 \cdot cov(X,Y))^2 - 4 \cdot \sigma_X^2 \cdot \sigma_Y^2 \leq 0$$

או באופן שקול $|cov(X,Y)| \leq \sigma_X \cdot \sigma_Y$ כנדרש.

■

**דוגמאות:**

1. נניח כי $N \sim \text{Pois}(\lambda)$ מקבל ערכים טבעיים. מבצעים $N$ ניסויי ברנולי ומסמנים ב־$X$ את מספר ההצלחות. נחשב את $\rho_{X,N}$:

$$\begin{cases} var(X) &= \lambda \cdot p \\ var(N) &= \lambda \\ cov(X,N) &= \lambda \cdot p \end{cases} \Rightarrow \rho_{X,N} = \frac{\lambda \cdot p}{\sqrt{\lambda} \cdot \sqrt{\lambda \cdot p}} = \sqrt{p}$$

2. נניח כי $X, Y$ בלתי־תלויים עם $\sigma_X^2 = 1,\ \sigma_Y^2 = \alpha^2$, כאשר $X$ מתאר אות משודר ו־$Y$ רעש המתווסף לאות. נסמן ב־$Z = X + Y$ את האות הנקלט. נחשב את מקדם המתאם בין האות המשודר לנקלט כתלות ב־$\alpha$:

$$\rho_{X,Z} = \frac{cov(X,Z)}{\sigma_X \cdot \sigma_Z} = \frac{cov(X, X+Y)}{1 \cdot \sqrt{var(X+Y)}} = \frac{cov(X,X) + cov(X,Y)}{\sqrt{var(X) + var(Y)}} = \frac{1+0}{\sqrt{1+\alpha^2}} = \frac{1}{\sqrt{1+\alpha^2}}$$

נסיק שככל שיש פחות רעש (כלומר $\alpha \to 0$) מתקיים $\rho_{X,Z} \to 1$ ולכן יש התאמה טובה יותר בין האות המשודר לנקלט. לעומת זאת, ככל שיש יותר רעש (כלומר $|\alpha| \to \infty$ ) מתקיים $\rho_{X,Z} \to 0$ ולכן יש התאמה פחות טובה בין האות המשודר לנקלט.

חלק III

# משתנה מקרי כללי

ניזכר ב**למת הרציפות** שראינו בתחילת הקורס אשר תעזור לנו בהמשך להוכיח תכונות של משתנים מקריים רציפים.

**טענה 10.13** (**למת הרציפות**) יהא $(\Omega, \mathcal{F}, P)$ מרחב הסתברות, ותהא $\{A_n\}_{n=1}^{\infty} \subseteq \mathcal{F}$.

1. אם הסדרה עולה, כלומר $A_1 \subseteq A_2 \subseteq \cdots$, אז מתקיים $P\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$.
2. אם הסדרה יורדת, כלומר $A_1 \supseteq A_2 \supseteq \cdots$, אז מתקיים $P\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n)$.
3. מתקיים $P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n)$, זה נכון גם כאשר הסדרה סופית.

## 14 משתנה מקרי רציף ורציף בהחלט

**הגדרה 1.14** יהא $X$ משתנה מקרי. נאמר ש־$X$ **רציף** אם $P(X = x) = 0$ לכל $x \in \mathbb{R}$.

**הערות:**

1. משתנה לא חייב להיות רציף או בדיד, נראה בהמשך גם משתנה מעורב.
2. השם רציף מרמז שיש כאן פונקציה רציפה, מהי? בהמשך נראה שההגדרה של משתנה רציף שקולה לכך שפונקציה המוגדרת מהמשתנה היא רציפה. הפונקציה המדוברת נקראת פונקציית התפלגות, נכיר אותה בקרוב.

**דוגמאות:**

1. נניח כי $X \sim \text{Bern}\left(\frac{1}{2}\right)$ אז $P(X = 1) = \frac{1}{2}$ ולכן $X$ לא רציף.
2. נניח כי $X$ מתאר בחירה אקראית ואחידה של ערך ממשי בקטע $[0, 1]$, ראינו שבמקרה זה $P(X = x) = 0$ לכל $x$ ממשי ולכן $X$ רציף. ההתפלגות הזאת נקראת התפלגות אחידה, מסמנים $X \sim \text{U}[0, 1]$.

ברוב המקרים נעבוד עם משתנים מקריים רציפים בעלי תכונה חשובה נוספת:

**הגדרה 2.14** יהא $X$ משתנה מקרי. נאמר ש־$X$ **רציף בהחלט** אם יש פונקציה אי־שלילית $f_X(x)$ שהיא אינטגרבילית רימן במובן הרחב ב־$\mathbb{R}$ כך שלכל קטע $[a,b]$ מתקיים $P(X\in[a,b])=\int_a^b f_X(x)\,dx$.

**הערות:**

1. הפונקציה $f_X$ נקראת **פונקציית הצפיפות** של $X$. מתכונות של אינטגרל רימן ברור שהפונקציה לא נקבעת ביחידות. כמו כן, $f_X$ לא חייבת להיות רציפה.

2. מההגדרה נסיק $\int_{-\infty}^{\infty} f_X(x)\,dx = P(X\in\mathbb{R}) = 1$.

3. משתנה רציף בהחלט הוא בהכרח רציף. אכן אם $X$ רציף בהחלט אז לכל $x\in\mathbb{R}$ נקבל:

$$P(X=x)=P(X\in[x,x])=\int_x^x f_X(t)\,dt=0$$

לכן $X$ רציף לפי ההגדרה. עם זאת, נראה בקרוב שמשתנה רציף הוא לא בהכרח רציף בהחלט.

## 15 פילוגים רציפים מרכזיים

### פילוג אחיד

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **אחיד** בקטע לא טריוויאלי $[a,b]$ ונסמן $X\sim\mathbf{U}[a,b]$ אם $X$ מתאר בחירה אקראית של מספר ממשי בקטע $[a,b]$. זהו משתנה רציף בהחלט, פונקציית הצפיפות היא:

$$f_X(x)=\begin{cases}\frac{1}{b-a} & , \quad x\in[a,b]\\ 0 & , \quad x\notin[a,b]\end{cases}$$

הגרף של $f_X$, למשל עבור $[0,1]$ הוא:

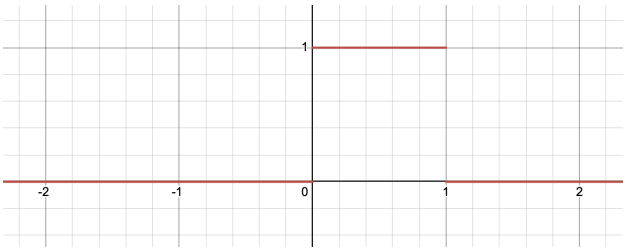

**פילוג מעריכי (אקספוננציאלי)**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **מעריכי** עם פרמטר $\lambda > 0$ ונסמן $X \sim \mathbf{Exp}(\lambda)$ אם $X$ רציף בהחלט עם פונקציית צפיפות $f_X(x) = \begin{cases} \lambda \cdot \mathrm{e}^{-\lambda x} & , \quad x > 0 \\ 0 & , \quad x \leq 0 \end{cases}$. הגרף של $f_X$, למשל עבור $\lambda = 1$ הוא:

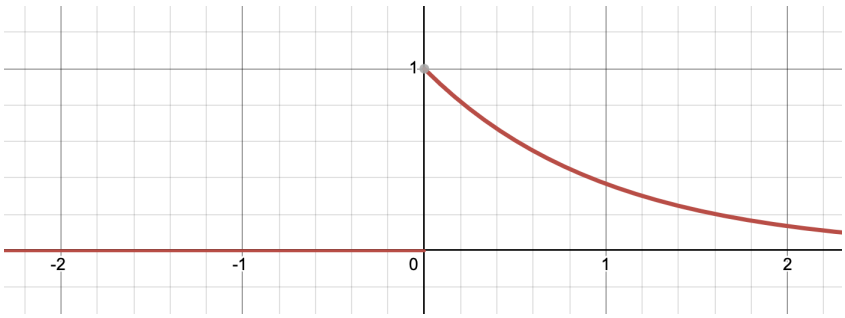


**הערות:**

1. זהו למעשה הכללה של הפילוג הגיאומטרי הבדיד.

2. כזכור לפילוג הגיאומטרי יש את תכונת חוסר הזיכרון. הפילוג המעריכי הוא הכללה רציפה ולכן גם לו יש את תכונת חוסר הזיכרון. באופן מדוייק:

**טענה:** יהא $X$ משתנה מקרי רציף ואי־שלילי אז:

ל־$X$ יש את תכונת חוסר הזיכרון: $\forall s,t \geq 0, \quad P(X > s+t \mid X > s) = P(X > t)$

$$\Updownarrow$$

קיים $\lambda > 0$ כך שמתקיים $X \sim \mathrm{Exp}(\lambda)$

ההוכחה דומה למקרה הבדיד. בנוסף אפשר בצורה נוחה להוכיח עם פונקציית ההתפלגות שנראה בהמשך.

**פילוג גמא**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **גמא** עם פרמטרים $\lambda > 0$ ו־$1 \leq k \in \mathbb{N}$ ונסמן $X \sim \Gamma(k, \lambda)$ אם $X$ רציף בהחלט עם פונקציית צפיפות $f_X(x) = \begin{cases} \frac{\lambda^k}{(k-1)!} \cdot x^{k-1} \cdot \mathrm{e}^{-\lambda x} & , \quad x > 0 \\ 0 & , \quad x \leq 0 \end{cases}$. הגרף של $f_X$, למשל עבור $\lambda = 2, \ k = 2$ הוא:

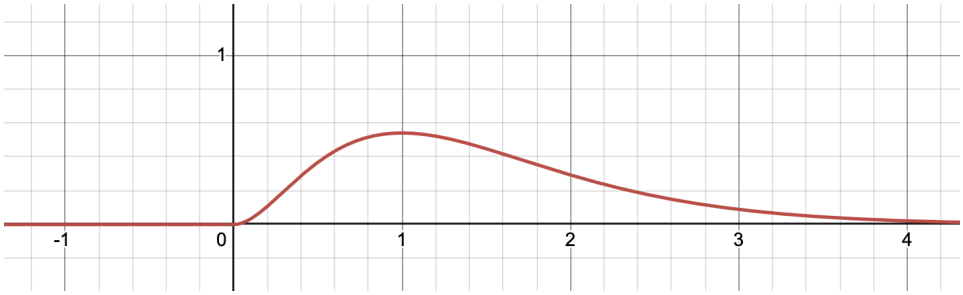


**הערות:**

1. עבור $k=1$ נקבל $\Gamma(1,\lambda)=\mathrm{Exp}(\lambda)$, כלומר פילוג גמא הוא הכללה של הפילוג המעריכי.

2. מכלילים את פילוג גמא לכל $k$ ממשי חיובי, לא נטפל במקרה זה.

**פילוג גאוסי (נורמלי)**

נאמר שמשתנה מקרי $X$ הוא בעל פילוג **נורמלי** עם פרמטרים $\sigma>0$, $\mu\in\mathbb{R}$ ונסמן $X\sim\mathbf{N}(\mu,\sigma^2)$ אם $X$ רציף בהחלט עם פונקציית צפיפות $f_X(x)=\frac{1}{\sqrt{2\pi}\cdot\sigma}\cdot e^{-\frac{1}{2}\cdot\left(\frac{x-\mu}{\sigma}\right)^2}$. הגרף של $f_X$, למשל עבור $\mu=0,\ \sigma=1$ הוא:

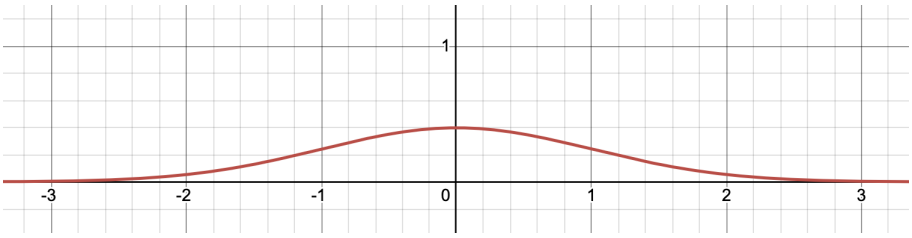


**הערות:**

1. לפונקציה $f_X$ קוראים גם **גאוסיאן**.

2. האינטגרל של הגאוסיאן הוא לא אלמנטרי, לכן חישוב ההסתברויות נעשה על־ידי קירובים. נהוג להגדיר $\Phi(z)=\int\limits_{-\infty}^{z} f_X(x)\,dx$ ולחשב את ההסתברויות המבוקשות בעזרת טבלת ערכים של $\Phi$.

3. ההתפלגות הנורמלית היא התפלגות חשובה ומרכזית בהסתברות. בהמשך נראה ממשפט הגבול המרכזי שסדרת משתנים $i.i.d$ "מתכנסת" למשתנה המפולג נורמלית. למשל דגימות של גובה בקבוצה "גדולה מספיק" או ציונים בקבוצת סטודנטים "גדולה מספיק".

## 16 פונקציית ההתפלגות

עד כה ראינו:

- אם $X$ משתנה מקרי בדיד אז פונקציית ההסתברות $p_X$ מאפיינת את $X$.
- אם $X$ משתנה מקרי רציף בהחלט אז פונקציית הצפיפות $f_X$ מאפיינת את $X$.

נרצה פונקציה המאפיינת את $X$ ללא תלות בסוג המשתנה.

**הגדרה 1.16** יהא $X$ משתנה מקרי. **פונקציית ההתפלגות** (המצטברת) של $X$ היא:

$$\begin{cases} F_X : \mathbb{R} \longrightarrow [0,1] \\ F_X(x) = P(X \leq x) \end{cases}$$

**הערות:**

1. $F_X$ מוגדרת לכל משתנה מקרי.
2. אם למשתנים מקריים $X, Y$ מתקיים $F_X \equiv F_Y$ אז $X, Y$ בעלי פילוג זהה.
3. מוכיחים כי:

$$X \text{ משתנה מקרי בדיד} \iff F_X \text{ היא פונקציית מדרגות עולה חלש}$$

נראה זאת מייד בכל הפילוגים הבדידים.

4. נראה בקרוב כי:

$$X \text{ משתנה מקרי רציף} \iff F_X \text{ רציפה}$$

### 16.1 פונקציית ההתפלגות של פילוגים ידועים

נחשב לפי ההגדרה את פונקציית ההתפלגות של הפילוגים שראינו:

**$X \sim Bern(p)$:**

נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \leq x) = 0$ |
| $0 \leq x < 1$ | $F_X(x) = P(X \leq x) = P(X = 0) = 1 - p$ |
| $1 \leq x$ | $F_X(x) = P(X \leq x) = P(X = 0) + P(X = 1) = 1$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ 1 - p & , \quad 0 \leq x < 1 \\ 1 & , \quad 1 \leq x \end{cases}$$

למשל עבור $p = \frac{1}{2}$ נקבל:

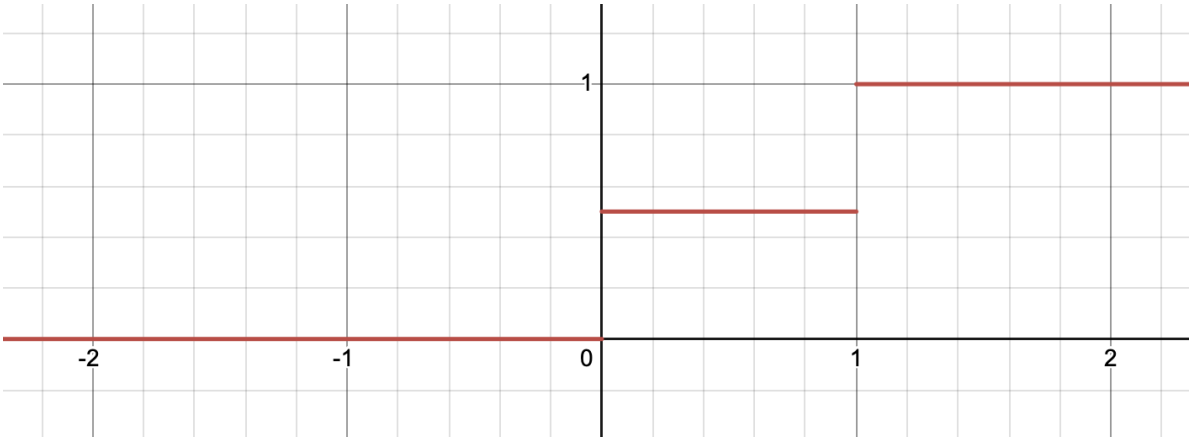

**$X \sim Bin(n,p)$:**

ניקח $n=2,\ p=\frac{1}{2}$ ונקבל כי:

$$p_X(k)=P(X=k)=\binom{2}{k}\cdot\left(\frac{1}{2}\right)^2=\binom{2}{k}\cdot\frac{1}{4}$$

כאשר $k\in\{0,1,2\}$. נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x<0$ | $F_X(x)=P(X\le x)=0$ |
| $0\le x<1$ | $F_X(x)=P(X\le x)=P(X=0)=\frac{1}{4}$ |
| $1\le x<2$ | $F_X(x)=P(X\le x)=\sum_{k=0}^{1}P(X=k)=\sum_{k=0}^{1}\binom{2}{k}\cdot\frac{1}{4}=\frac{1}{4}+\frac{1}{2}=\frac{3}{4}$ |
| $2\le x$ | $F_X(x)=P(X\le x)=\sum_{k=0}^{2}P(X=k)=1$ |

סה"כ נקבל:

$$F_X(x)=\begin{cases}0 & , \quad x<0\\ \frac{1}{4} & , \quad 0\le x<1\\ \frac{3}{4} & , \quad 1\le x<2\\ 1 & , \quad 2\le x\end{cases}$$

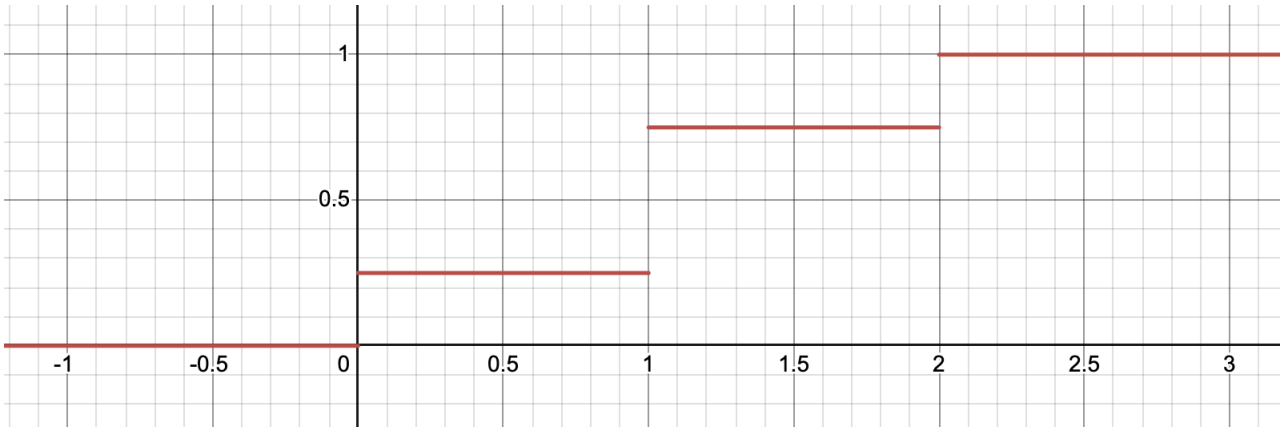

### $X \sim NB(r,p)$:

ניקח $r=2,\ p=\frac{1}{2}$ ונקבל כי:

$$p_X(k)=P(X=k)=\binom{k+1}{1}\cdot\left(\frac{1}{2}\right)^{k+2}=(k+1)\cdot\left(\frac{1}{2}\right)^{k+2}$$

לכל $0\le k\in\mathbb{N}$. נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x<0$ | $F_X(x)=P(X\le x)=0$ |
| $0\le x<1$ | $F_X(x)=P(X\le x)=P(X=0)=(0+1)\left(\frac{1}{2}\right)^{2+0}=\frac{1}{4}$ |
| $1\le x<2$ | $F_X(x)=P(X\le x)=\sum\limits_{k=0}^{1}P(X=k)=\sum\limits_{k=0}^{1}(k+1)\left(\frac{1}{2}\right)^{2+k}=\frac{1}{4}+\frac{1}{4}=\frac{1}{2}$ |
| $\vdots$ | $\vdots$ |
| $n\le x<n+1$ | $F_X(x)=P(X\le x)=\sum\limits_{k=0}^{n}P(X=k)=\sum\limits_{k=0}^{n}(k+1)\left(\frac{1}{2}\right)^{2+k}$ |
| $\vdots$ | $\vdots$ |

סה"כ נקבל:

$$F_X(x)=\begin{cases}0 & , \quad x<0\\ \frac{1}{4} & , \quad 0\le x<1\\ \frac{1}{2} & , \quad 1\le x<2\\ \vdots & \quad \vdots\\ \sum\limits_{k=0}^{n}(k+1)\left(\frac{1}{2}\right)^{2+k} & , \quad n\le x<n+1\\ \vdots & \quad \vdots\end{cases}$$

### $X \sim Geom(p)$:

ניקח $p = \frac{1}{2}$ ונקבל:

$$p_X(k) = P(X = k) = \left(\frac{1}{2}\right)^k$$

כאשר $1 \leq k \in \mathbb{N}$. נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 1$ | $F_X(x) = P(X \leq x) = 0$ |
| $1 \leq x < 2$ | $F_X(x) = P(X \leq x) = P(X = 1) = \left(\frac{1}{2}\right)^1 = \frac{1}{2}$ |
| $2 \leq x < 3$ | $F_X(x) = P(X \leq x) = \sum_{k=1}^{2} P(X = k) = \sum_{k=1}^{2} \left(\frac{1}{2}\right)^k = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}$ |
| $\vdots$ | $\vdots$ |
| $n \leq x < n+1$ | $F_X(x) = P(X \leq x) = \sum_{k=1}^{n} P(X = k) = \sum_{k=1}^{n} \left(\frac{1}{2}\right)^k = \frac{1}{2} \cdot \frac{1-\left(\frac{1}{2}\right)^n}{1-\frac{1}{2}} = 1 - \left(\frac{1}{2}\right)^n$ |
| $\vdots$ | $\vdots$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 1 \\ \frac{1}{2} & , \quad 1 \leq x < 2 \\ \vdots & \quad \vdots \\ 1 - \left(\frac{1}{2}\right)^n & , \quad n \leq x < n+1 \\ \vdots & \quad \vdots \end{cases}$$

### $X \sim HG(n, N, D)$:

ניקח $n = 3,\ N = 4,\ D = 2$, במקרה זה נקבל:

$$p_X(k) = P(X = k) = \frac{\binom{2}{k} \cdot \binom{2}{3-k}}{\binom{4}{3}} = \frac{1}{4} \cdot \binom{2}{k} \cdot \binom{2}{3-k}$$

כאשר $k \in \{1, 2\}$. נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 1$ | $F_X(x) = P(X \le x) = 0$ |
| $1 \le x < 2$ | $F_X(x) = P(X \le x) = P(X = 1) = \frac{1}{4} \cdot \binom{2}{1} \cdot \binom{2}{3-1} = \frac{1}{2}$ |
| $2 \le x$ | $F_X(x) = P(X \le x) = P(X = 1) + P(X = 2) = 1$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 1 \\ \frac{1}{2} & , \quad 1 \le x < 2 \\ 1 & , \quad 2 \le x \end{cases}$$

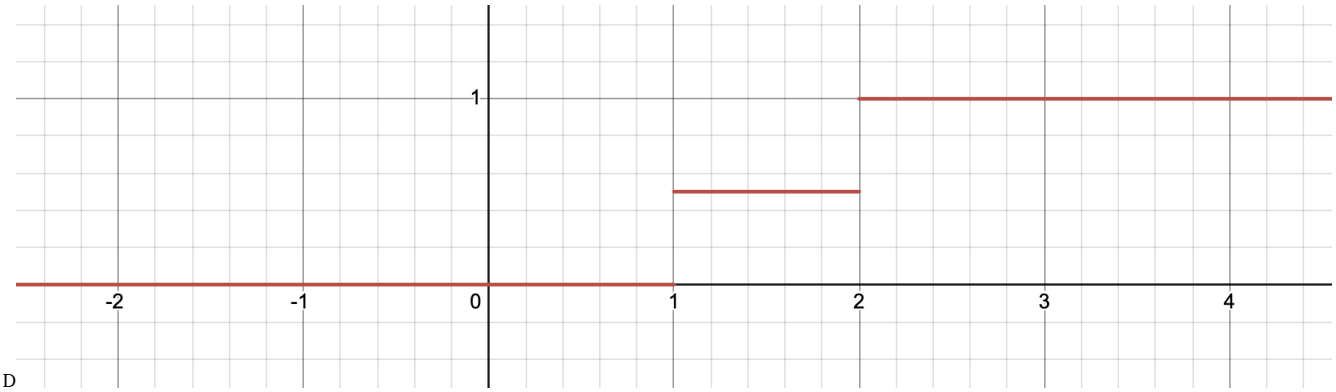


D

### $X \sim \text{Pois}(\lambda)$:

ניקח $\lambda = 2$, במקרה זה נקבל:

$$p_X(k) = P(X = k) = \mathrm{e}^{-2}\frac{2^k}{k!}$$

כאשר $0 \le k \in \mathbb{N}$. נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \le x) = 0$ |
| $0 \le x < 1$ | $F_X(x) = P(X \le x) = P(X = 0) = \mathrm{e}^{-2}$ |
| $1 \le x < 2$ | $F_X(x) = P(X \le x) = \sum_{k=0}^{1} P(X = k) = \sum_{k=0}^{1} \mathrm{e}^{-2}\frac{2^k}{k!}$ |
| $\vdots$ | $\vdots$ |
| $n \le x < n+1$ | $F_X(x) = P(X \le x) = \sum_{k=0}^{n} P(X = k) = \sum_{k=0}^{n} \mathrm{e}^{-2}\frac{2^k}{k!}$ |
| $\vdots$ | $\vdots$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ \sum_{k=0}^{n} \mathrm{e}^{-2}\frac{2^k}{k!} & , \quad n \le x < n+1 \end{cases}$$

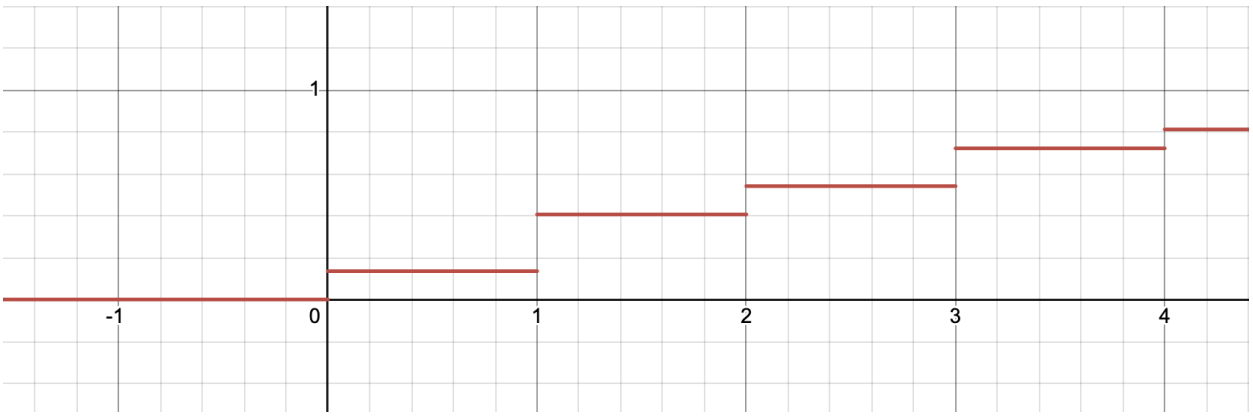

### $\mathbf{X \sim U[a,b]}$:

ניקח $a=0,\ b=2$, במקרה זה נקבל:

$$f_X(x)=\begin{cases}\frac{1}{2-0} & , \quad x\in[0,2]\\ 0 & , \quad x\notin[0,2]\end{cases}=\begin{cases}\frac{1}{2} & , \quad x\in[0,2]\\ 0 & , \quad x\notin[0,2]\end{cases}$$

נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x<0$ | $F_X(x)=P(X\le x)=\int\limits_{-\infty}^{x} f_X(t)\,dt=\int\limits_{-\infty}^{x} 0\,dt=0$ |
| $0\le x\le 2$ | $F_X(x)=P(X\le x)=\int\limits_{-\infty}^{x} f_X(t)\,dt=\int\limits_{0}^{x} \frac{1}{2}\,dt=\frac{x}{2}$ |
| $2<x$ | $F_X(x)=P(X\le x)=\int\limits_{-\infty}^{x} f_X(t)\,dt=\int\limits_{0}^{2} \frac{1}{2}\,dt=1$ |

סה"כ נקבל:

$$F_X(x)=\begin{cases}0 & , \quad x<0\\ \frac{x}{2} & , \quad 0\le x\le 2\\ 1 & , \quad 2<x\end{cases}$$

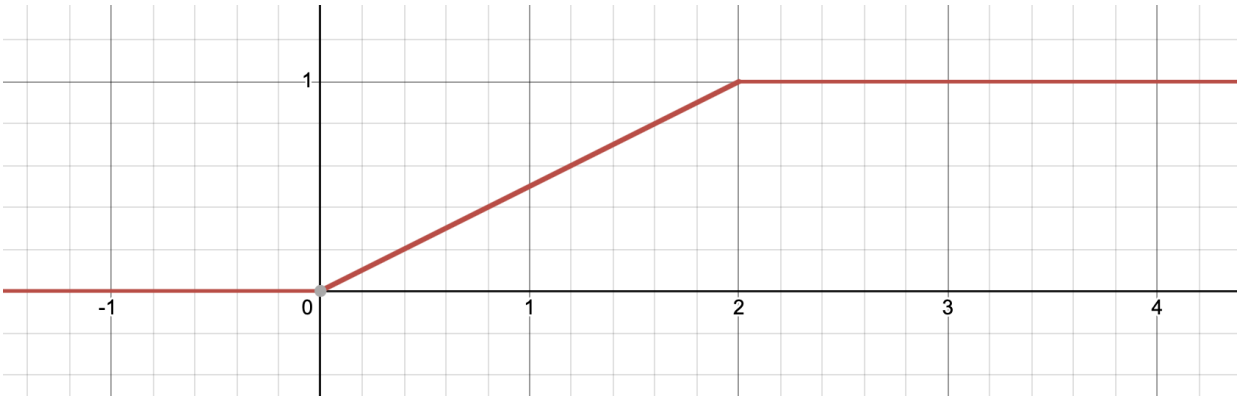

**$X \sim \mathbf{Exp}(\lambda)$:**

ניקח $\lambda = 2$, במקרה זה נקבל:

$$f_X(x) = \begin{cases} 2 \cdot e^{-2x} & , \quad x > 0 \\ 0 & , \quad x \le 0 \end{cases}$$

נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X(t)\,dt = \int_{-\infty}^{x} 0\,dt = 0$ |
| $0 \le x$ | $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X(t)\,dt = \int_{0}^{x} 2 \cdot e^{-2t}\,dt = 1 - e^{-2x}$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ 1 - e^{-2x} & , \quad 0 \le x \end{cases}$$

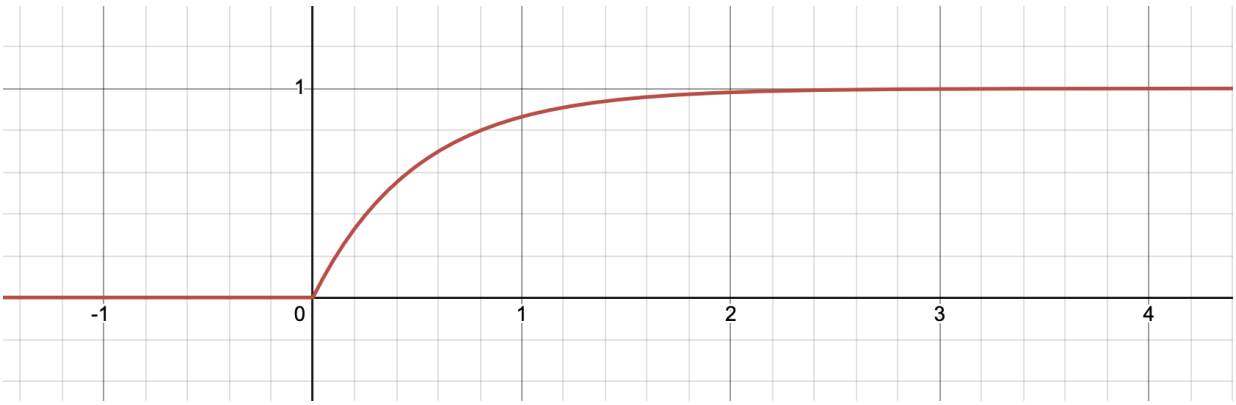

**$X \sim \Gamma(k, \lambda)$:**

ניקח $\lambda = 2$. $k = 4$, במקרה זה נקבל:

$$f_X(x) = \begin{cases} \frac{2^4}{6} \cdot x^3 \cdot e^{-2x} & , \quad x > 0 \\ 0 & , \quad x \le 0 \end{cases} = \begin{cases} \frac{8}{3} \cdot x^3 \cdot e^{-2x} & , \quad x > 0 \\ 0 & , \quad x \le 0 \end{cases}$$

נחשב לפי ההגדרה על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X(t)\,dt = \int_{-\infty}^{x} 0\,dt = 0$ |
| $0 \le x$ | $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X(t)\,dt = \int_{0}^{x} \frac{8}{3} \cdot t^3 \cdot e^{-2t}\,dt = 1 - \left(\frac{4}{3}x^3 + 2x^2 + 2x + 1\right) \cdot e^{-2x}$ |

סה"כ נקבל:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ 1 - \left(\frac{4}{3}x^3 + 2x^2 + 2x + 1\right) \cdot e^{-2x} & , \quad 0 \le x \end{cases}$$

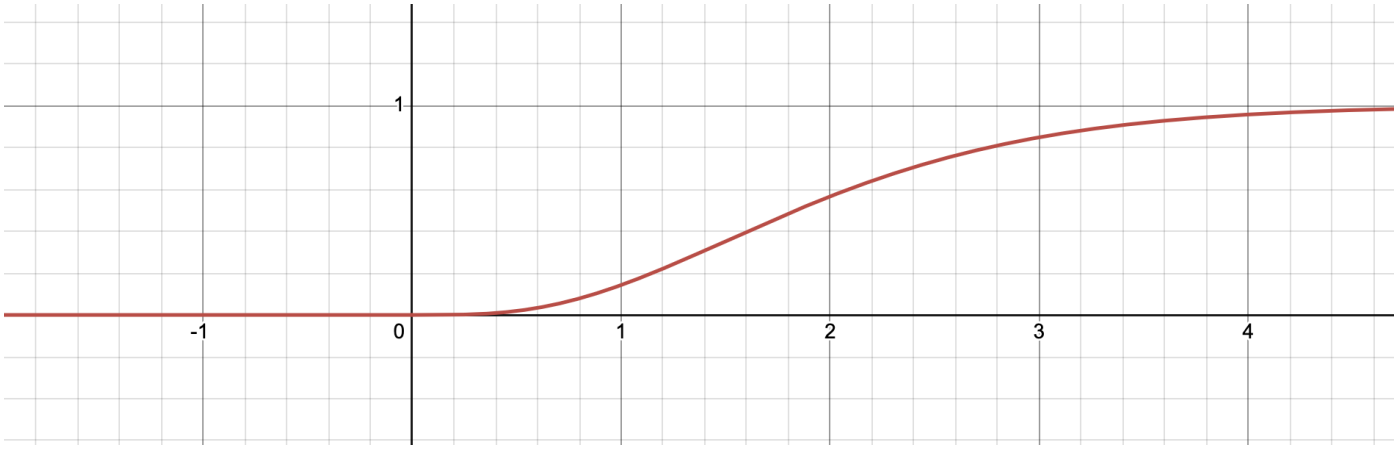

**$X \sim N(\mu, \sigma^2)$:**

ניקח $\sigma = 1$. $\mu = 0$, במקרה זה נקבל:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\cdot x^2}$$

לפי ההגדרה:

$$F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X(t)\,dx = \frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^{x} e^{-\frac{1}{2}\cdot t^2}\,dt$$

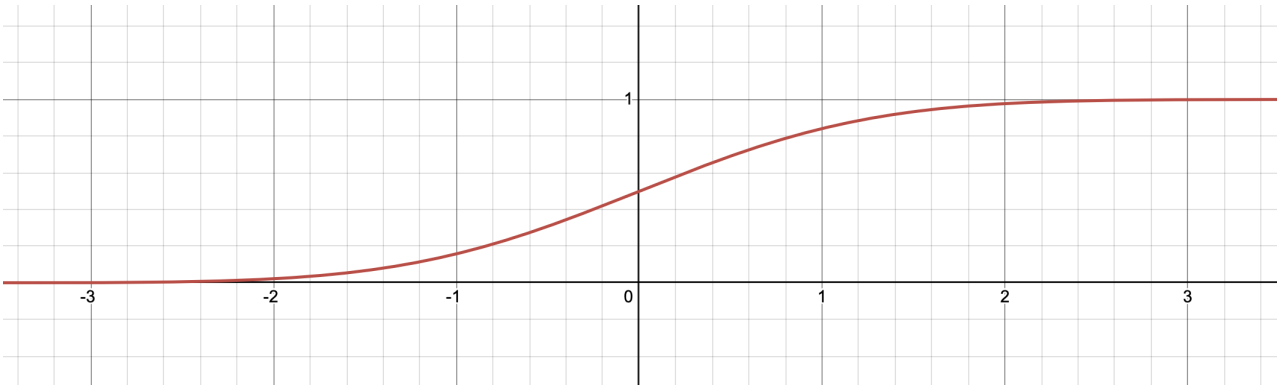


**הערה:** כפי שכבר הערנו, האינטגרל של הגאוסיאן הוא לא אלמנטרי, לכן חישוב ההסתברויות נעשה על־ידי קירובים. נהוג לסמן $\Phi(x) = F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt$ ולחשב את ההסתברויות המבוקשות בעזרת טבלת ערכים של $\Phi$. באופן כללי מגדירים **פונקציית שגיאה** על־ידי:

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_{0}^{x} e^{-t^2}\,dt = \sum_{n=0}^{\infty} \frac{(-1)^n}{(2n+1)\cdot n!} x^{2n+1} \quad \Rightarrow \quad \Phi(x) = \frac{1}{2} + \frac{1}{2}\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)$$

ומשתמשים בערכים ותכונות שלה על מנת לחשב הסתברויות.

### 16.2 תכונות של פונקציית התפלגות

נראה כעת תכונות בסיסיות ושימושיות של פונקציית ההתפלגות. אפשר להתרשם מהתכונות בפילוגים הידועים שראינו בפרק הקודם.

**טענה 2.16** יהא $X$ משתנה מקרי, אז:

1. $F_X$ מונוטונית עולה (חלש).
2. $F_X$ רציפה מימין בכל נקודה.
3. מתקיים: $\lim_{x\to\infty} F_X(x) = 1$, $\lim_{x\to-\infty} F_X(x) = 0$.
4. לכל $x \in \mathbb{R}$ נסמן $F_X(x-) = \lim_{t\to x^-} F_X(t)$ ואז:
   (א) $P(X < x) = F_X(x-)$.
   (ב) $P(X = x) = F_X(x) - F_X(x-)$.

**הוכחה:**

1. לכל $x_1 < x_2$ ברור שהמאורע $\{X \le x_1\}$ מוכל במאורע $\{X \le x_2\}$, לכן מתכונות מידת ההסתברות נקבל:

$$F_X(x_1) = P(X \le x_1) \le P(X \le x_2) = F_X(x_2)$$

2. לפי אפיון היינה לרציפות חד־צדדית, מספיק להוכיח שלכל סדרה יורדת $\{t_n\}$ השואפת ל־$x$ מתקיים $\lim_{n\to\infty} F_X(t_n) = F_X(x)$. לשם כך נבחין כי $A_n = \{X \le t_n\}$ היא סדרה יורדת של מאורעות, לכן מתכונות מידת ההסתברות נקבל:

$$\lim_{n\to\infty} F_X(t_n) = \lim_{n\to\infty} P(X \le t_n) = P\left(\bigcap_{n=1}^{\infty} \{X \le t_n\}\right) = P(X \le x) = F_X(x)$$

3. נוכיח את אחד הגבולות, למשל את $\lim_{x\to\infty} F_X(x) = 1$. שוב לפי היינה מספיק להוכיח שלכל סדרה עולה $\{t_n\}$ השואפת לאינסוף מתקיים $\lim_{n\to\infty} F_X(t_n) = 1$, אכן:

$$\lim_{n\to\infty} F_X(t_n) = \lim_{n\to\infty} P(X \le t_n) = P\left(\bigcup_{n=1}^{\infty} \{X \le t_n\}\right) = P(\Omega) = 1$$

4. (א) באופן דומה לפי אפיון היינה מספיק להוכיח שלכל סדרה עולה $\{t_n\}$ השואפת ל־$x$ ושונה מ־$x$ מתקיים $\lim_{n\to\infty} F_X(t_n) = P(X < x)$, אכן:

$$\lim_{n\to\infty} F_X(t_n) = \lim_{n\to\infty} P(X \le t_n) = P\left(\bigcup_{n=1}^{\infty} \{X \le t_n\}\right) = P(X < x)$$

(ב) נבחין כי:

$$F_X(x) = P(X \le x) = P(X < x) + P(X = x) = F_X(x-) + P(X = x)$$

לכן $P(X = x) = F_X(x) - F_X(x-)$ כנדרש.

■

מהתכונות נסיק אפיון של משתנה רציף.

**מסקנה 3.16** יהא $X$ משתנה מקרי, אז: $X$ רציף $\iff$ $F_X$ רציפה.

**הוכחה:** נוכיח כל כיוון בנפרד:

$\Leftarrow$: אם $X$ רציף אז לכל $x$ מתקיים $P(X = x) = 0$. ראינו כי $F_X$ רציפה מימין בכל נקודה, נראה רציפות משמאל. לפי סעיף קודם $P(X = x) = F_X(x) - F_X(x-)$ ולכן:

$$\lim_{t\to x^-} F_X(t) = F_X(x-) = F_X(x) - P(X = x) = F_X(x)$$

$\Rightarrow$: יהא $x \in \mathbb{R}$, אם $F_X$ רציפה ב־$x$ אז בפרט היא רציפה משמאל כלומר $F_X(x) = \lim_{t\to x^-} F_X(t) = F_X(x-)$ לכן:

$$P(X = x) = F_X(x) - F_X(x-) = 0$$

כנדרש.

■

### 16.3 דוגמה למשתנה מעורב

נדגים כעת שימוש בתכונות וכן נדגים מצב בו מקבלים **משתנה מעורב**.

**דוגמה:** ידוע שרמזור הוא אדום במשך 30 שניות ואז ירוק במשך 10 שניות. נסמן ב־$X$ את זמן ההמתנה ברמזור. נחשב את פונקציית ההתפלגות של $X$. נסמן ב־$Y$ את זמן ההגעה לרמזור מתוך מחזור של 40 שניות. סביר להניח כי $Y \sim \mathrm{U}[0,40]$, לכן עבור $g(t) = \begin{cases} 30-t & , \quad t \in [0,30] \\ 0 & , \quad t \notin [0,30] \end{cases}$ נקבל $X = g(Y)$.

נבחין כי $F_Y(y) = \begin{cases} 0 & , \quad y < 0 \\ \frac{y}{40} & , \quad 0 \le y < 40 \\ 1 & , \quad 40 \le y \end{cases}$, כעת נחשב את $F_X$ על־ידי הפרדה לתחומים:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \le x) = 0$ |
| $0 \le x < 30$ | $F_X(x) = P(X \le x) = P(g(Y) \le x) = P(Y \ge 30 - x) = \frac{x+10}{40}$ |
| $30 \le x$ | $F_X(x) = P(X \le x) = 1$ |

לכן:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ \frac{x+10}{40} & , \quad 0 \le x < 30 \\ 1 & , \quad 30 \le x \end{cases}$$

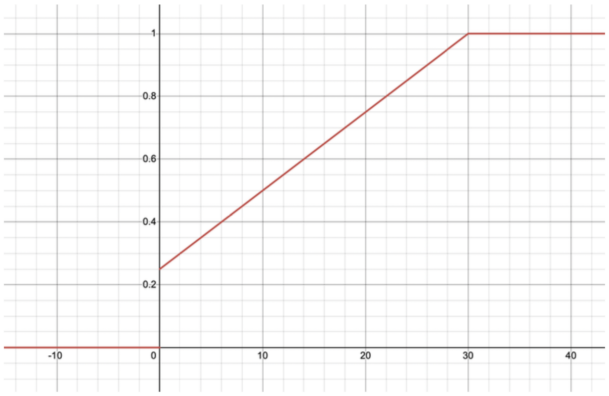


נבחין כי $F_X$ לא רציפה ולכן $X$ לא רציף. מצד שני $F_X$ היא לא פונקציית מדרגות ולכן המשתנה לא בדיד. זהו כאמור **משתנה מעורב**. בנוסף, ניתן לחשב הסתברויות כגון ההסתברות שלא נחכה ברמזור:

$$P(X=0) = F_X(0) - F_X(0-) = \frac{1}{4} - 0 = \frac{1}{4}$$

### 16.4 אפיון משתנה רציף בהחלט

אפיון שימושי של משתנה מקרי רציף בהחלט הוא:

**מסקנה 4.16** יהא $X$ משתנה מקרי אז:

$X$ רציף בהחלט עם פונקציית צפיפות $f_X$

$$\Updownarrow$$

קיימת $g(t)$ אינטגרבילית רימן במובן המוכלל ב־$\mathbb{R}$ המקיימת $F_x(x) = \int_{-\infty}^{x} g(t)\,dt$ (ואז $f_X = g$)

**הערות:**

1. $f_X$ בד"כ לא רציפה ולכן $F_X$ היא לא פונקציה קדומה שלה.
2. מההגדרות וניוטון־לייבניץ נסיק שאם $F_X$ גזירה פרט למספר זניח של נקודות ו־$F_X'$ אינטגרבילית רימן במובן המוכלל ב־$\mathbb{R}$ אז $X$ רציף בהחלט וכן $F_X' = f_X$.
3. מהאפיון נוכל להראות שמשתנה רציף הוא לא בהכרח רציף בהחלט, נדגים זאת אחרי ההוכחה.

**הוכחה:** נוכיח כל כיוון בנפרד:

$\Downarrow$: אם $X$ רציף בהחלט אז לפי ההגדרה $F_x(x) = \int_{-\infty}^{x} f_X(t)\,dt$ ולכן $g = f_X$.

$\Uparrow$: נניח שקיימת $g$ כנ"ל, לכל קטע $[a,b]$ מתקיים:

$$P(X \in [a,b]) = P(X \le b) - P(X < a) = F_x(b) - F_x(a-) =$$
$$= \int_{-\infty}^{b} g(t)\,dt - \lim_{t\to a^-} \int_{-\infty}^{t} g(t)\,dt \underset{(*)}{=} \int_{-\infty}^{b} g(t)\,dt - \int_{-\infty}^{a} g(t)\,dt = \int_{a}^{b} g(t)\,dt$$

$(*)$ מרציפות האינטגרל הלא מסויים.

לכן לפי ההגדרה $g$ היא פונקציית הצפיפות של $X$, כלומר $X$ רציף בהחלט ומתקיים $f_X = g$.

■

**דוגמה:** יהא $X$ המרחק בין נקודה אקראית בעיגול היחידה הסגור במישור $\mathbb{R}^2$ סביב $(0,0)$ לראשית הצירים. ברור כי התומך של $X$ הוא $[0,1]$. הבחירה היא אחידה ולכן לכל $x \in [0,1]$ ההסתברות $P(X \leq x)$ היא היחס בין השטח של עיגול ברדיוס $x$ לשטח עיגול היחידה, לפיכך:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \leq x) = 0$ |
| $0 \leq x < 1$ | $F_X(x) = P(X \leq x) = \frac{\pi x^2}{\pi \cdot 1^2} = x^2$ |
| $1 \leq x$ | $F_X(x) = P(X \leq x) = 1$ |

$$\Rightarrow F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ x^2 & , \quad 0 \leq x < 1 \\ 1 & , \quad 1 \leq x \end{cases}$$

הגרף של $F_X$ הוא:

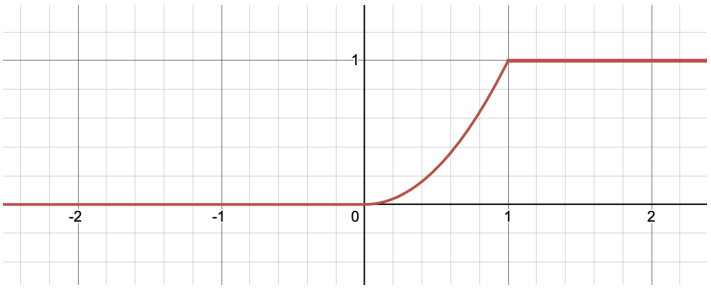


ברור כי $F_X$ גזירה ברציפות בכל נקודה למעט $x = 1$ ולכן:

| | |
|---|---|
| $x < 0$ | $f_X(x) = F_X'(x) = \frac{d}{dx}(0) = 0$ |
| $0 \leq x < 1$ | $f_X(x) = F_X'(x) = \frac{d}{dx}(x^2)$ |
| $1 \leq x$ | $f_X(x) = F_X'(x) = \frac{d}{dx}(1) = 0$ |

$$\Rightarrow f_X(x) = \begin{cases} 0 & , \quad x < 0 \\ 2x & , \quad 0 \leq x < 1 \\ 0 & , \quad 1 \leq x \end{cases}$$

הגרף של $f_X$ הוא:

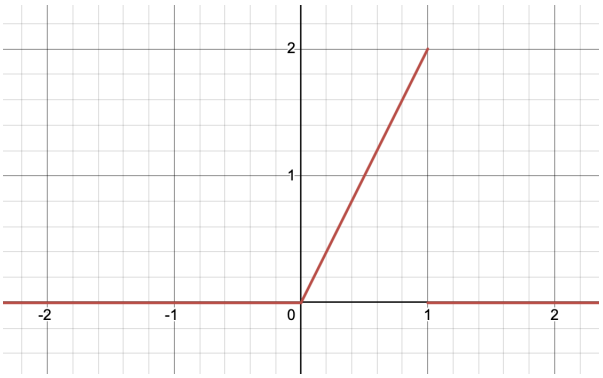


נציין שיכולנו לחשב ישירות את פונקציית הצפיפות, הרי לכל $x \in [0,1]$ הצפיפות של $x$ היא היקף מעגל ברדיוס $x$ (שזה "מספר הנקודות" שמרחקן מהראשית הוא $x$) חלקי שטח עיגול ברדיוס 1 (שזה "מספר הנקודות" הכולל), כלומר $f_X(x) = \frac{2\pi x}{\pi 1^2} = 2x$.

### 16.5 דוגמה למשתנה רציף שאינו רציף בהחלט

ההבדל בין משתנה רציף לרציף בהחלט הוא מאוד עדין ולא ממש בא לידי ביטוי בד"כ. עם זאת, לשם חידוד ההבדל נראה כעת דוגמה למשתנה רציף שהוא לא רציף בהחלט.

**דוגמה:** ראשית נכיר את **פונקציית קנטור**. זוהי פונקציה המסומנת על־ידי $c(x)$, מוגדרת בקטע $[0,1]$, רציפה שם, עולה חלש שהגרף שלה הוא:

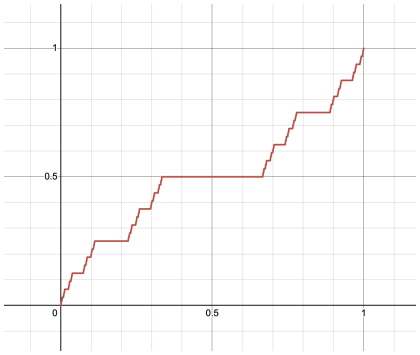


הפונקציה גזירה כמעט בכל מקום והנגזרת שלה מתאפסת כמעט בכל מקום. לא נגדיר פורמלית את הפונקציית קנטור אז זאת פונקציה חשובה באנליזה ממשית, היא דוגמה נגדית לאינטואיציה שפונקציה רציפה, עולה וגזירה חייבת לקיים שהנגזרת שלה אי־שלילית בכל התחום וחיובית בחלק מהתחום. נגדיר משתנה מקרי $X$ להיות משתנה מקרי המתאים לפונקציית ההתפלגות:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ c(x) & , \quad 0 \le x < 1 \\ 1 & , \quad 1 \le x \end{cases}$$

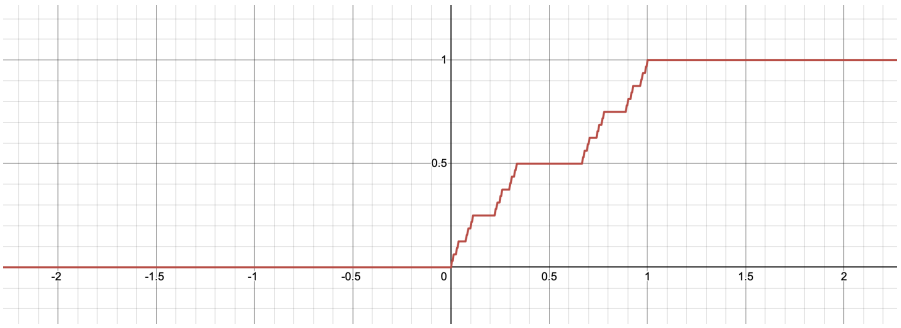


המשתנה $X$ רציף לפי האפיון כי $F_X$ רציפה. נבחין כי $F_X$ גזירה כמעט בכל מקום, לכן אם $X$ היה רציף בהחלט אז כמעט בכל מקום היה מתקיים $F'_X = f_X$. אבל $F'_X \equiv 0$ כמעט בכל מקום, כלומר פונקציית הצפיפות היא זהותית אפס וזה כמובן לא אפשרי.

## 17 וקטור אקראי רציף בהחלט

נגדיר כעת וקטור אקראי רציף בהחלט.

**הגדרה 1.17** יהא $\overline{X}=(X_1,...,X_n)$ וקטור אקראי. נאמר כי $\overline{X}$ הוא **וקטור אקראי רציף בהחלט** אם יש $f_{\overline{X}}(\overline{x})$ אי שלילית, אינטגרבילית רימן ב־$\mathbb{R}^n$ במובן המוכלל כך שלכל $A\subseteq\mathbb{R}^n$ בעלת נפח ($n$־מימדי) מתקיים:

$$P\left(\overline{X}\in A\right)=\int\underset{A}{\cdots}\int f_{\overline{X}}(\overline{x})\,dx_1\cdots dx_n$$

**הערה:** הפונקציה $f_{\overline{X}}(\overline{x})$ נקראת **פונקציית הצפיפות (המשותפת)** של $\overline{X}$.

**דוגמאות:**

1. **פילוג אחיד**

תהא $A\subseteq\mathbb{R}^n$ בעלת נפח חיובי. אם $\overline{X}$ מוגרל באופן אחיד מ־$A$ אז נאמר כי $\overline{X}$ בעל **פילוג אחיד** ב־$A$ ונסמן $\overline{X}\sim\mathrm{U}(A)$. נבחין שלכל $B\subseteq\mathbb{R}^n$ מתקיים שההסתברות $P\left(\overline{X}\in B\right)$ היא הנפח היחסי של $B$ בתוך $A$ ביחס ל־$A$, כלומר:

$$P\left(\overline{X}\in B\right)=\frac{\int\underset{B\cap A}{\cdots}\int\frac{1}{|A|}\,dx_1\cdots dx_n}{\int\underset{A}{\cdots}\int\frac{1}{|A|}\,dx_1\cdots dx_n}=\frac{|A\cap B|}{|A|}$$

לכן, פונקציית הצפיפות של $\overline{X}$ היא:

$$f_{\overline{X}}(\overline{x})=\begin{cases}\frac{1}{|A|} & , \quad \overline{x}\in A\\ 0 & , \quad \overline{x}\notin A\end{cases}$$

**דוגמה:** ניקח $A=[0,1]\times[0,1]$ ונקבל $f_{X,Y}(x,y)=\begin{cases}1 & , \quad (x,y)\in A\\ 0 & , \quad (x,y)\notin A\end{cases}$. נחשב את ההסתברות $P(X<Y)$:

$$P(X<Y)=\iint\limits_{\{X<Y\}\cap A}1\;dxdy=\int_0^1\int_0^y 1\;dxdy=\int_0^1 y\;dy=\frac{1}{2}$$

2. **פילוג גאוסי (נורמלי)**

יהא $\overline{X}$ וקטור אקראי. נאמר כי $\overline{X}$ בעל פילוג **גאוסי תקני $n$־מימדי** אם $X_1,...,X_n \sim N(0,1)$ בלתי־תלויים.

נקבל כי $\overline{X}$ רציף בהחלט עם פונקציית צפיפות:

$$f_{\overline{X}}(\overline{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}|\overline{x}|^2} = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\left(x_1^2+\cdots+x_n^2\right)}$$

חישוב ישיר מראה כי:

$$\begin{aligned}\int\cdots\int_{\mathbb{R}^n} f_{\overline{X}}(\overline{x})\,dx_1\cdots dx_n &= \int\cdots\int_{\mathbb{R}^n} \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\left(x_1^2+\cdots+x_n^2\right)} dx_1\cdots dx_n = \\ &= \frac{1}{(2\pi)^{\frac{n}{2}}}\int\cdots\int_{\mathbb{R}^n} e^{-\frac{1}{2}\left(x_1^2+\cdots+x_n^2\right)} dx_1\cdots dx_n = \\ &= \left(\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}x_1^2} dx_1\right)\cdots\left(\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}x_n^2} dx_n\right) = 1\cdots 1 = 1\end{aligned}$$

**הערה:** מוכיחים שכל תת־וקטור של וקטור גאוסי תקני הוא גם וקטור גאוסי תקני במימד המתאים.

## 17.1 פונקציית ההתפלגות

נכליל את ההגדרה לוקטור אקראי רציף.

**הגדרה 2.17** יהא $\overline{X}$ וקטור אקראי. **פונקציית ההתפלגות המשותפת** של $\overline{X}$ היא:

$$\begin{cases} F_{\overline{X}} : \mathbb{R}^n \longrightarrow [0,1] \\ F_{\overline{X}}(x_1,...,x_n) = P(X_1 \le x_1,...,X_n \le x_n) \end{cases}$$

נכליל את התכונות הבסיסיות שראינו במקרה של משתנה מקרי רציף.

**משפט 3.17** יהא $\overline{X}$ וקטור אקראי, אז:

1. $F_{\overline{X}}$ מונוטונית עולה (חלש) בכל משתנה בנפרד.
2. $F_{\overline{X}}$ רציפה מימין בכל משתנה בנפרד בכל נקודה.
3. מתקיים: $\lim\limits_{x_1,...,x_n\to\infty} F_{\overline{X}}(\overline{x}) = 1$. כמו כן, לכל $1 \le k \le n$ מתקיים $\lim\limits_{x_k\to-\infty} F_{\overline{X}}(\overline{x}) = 0$.

4. אם $\overline{X}$ רציף בהחלט אז $F_{\overline{X}}(\overline{x}) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_{\overline{X}}(\overline{t})\, dt_1 \cdots dt_n$.

5. אם $F_{\overline{X}}$ גזירה ברציפות $n$ פעמים (פרט לקבוצה זניחה) אז $f_{\overline{X}}(\overline{x}) = \frac{\partial^n}{\partial x_1 \cdots \partial x_n} F_{\overline{X}}(\overline{x})$.

**דוגמאות:**

1. יהא $(X,Y) \sim \mathrm{U}[0,1]^2$. הפילוג אחיד ולכן לפי ההגדרה פונקציית הצפיפות היא:

$$f_{X,Y}(x,y) = \begin{cases} 1 & , \quad (x,y) \in [0,1]^2 \\ 0 & , \quad (x,y) \notin [0,1]^2 \end{cases}$$

נחשב את פונקציית ההתפלגות על־ידי הפרדה לתחומים:

| | |
|---|---|
| $y<0$ או $x<0$ | $F_{X,Y}(x,y) = P(X \le x, Y \le y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dudv = \int_{-\infty}^{x}\int_{-\infty}^{y} 0\ dudv = 0$ |
| $0 \le x,\ y < 1$ | $F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dudv = \int_{0}^{x}\int_{0}^{y} 1\ dudv = xy$ |
| $0 \le x < 1,\ 1 \le y$ | $F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dudv = \int_{0}^{x}\int_{0}^{1} 1\ dudv = x$ |
| $0 \le y < 1,\ 1 \le x$ | $F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dudv = \int_{0}^{1}\int_{0}^{y} 1\ dudv = y$ |
| $1 \le x, y$ | $F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dudv = \int_{0}^{1}\int_{0}^{1} 1\ dudv = 1$ |

לפיכך פונקציית ההתפלגות היא:

$$F_{X,Y}(x,y) = \begin{cases} 0 & , \quad x<0 \ or\ y<0 \\ xy & , \quad 0 \le x,\ y<1 \\ x & , \quad 0 \le x < 1,\ 1 \le y \\ y & , \quad 0 \le y < 1,\ 1 \le x \\ 1 & , \quad 1 \le x, y \end{cases}$$

ברור כי $F_{X,Y}$ גזירה ברציפות פעמיים בכל המישור למעט קבוצה זניחה, לכן "בכיוון השני" נקבל חזרה:

$$f_{X,Y}(x,y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x,y) = \begin{cases} 1 & , \quad (x,y) \in [0,1)^2 \\ 0 & , \quad (x,y) \notin [0,1)^2 \end{cases}$$

נבחין שיש הבדל בין פונקציית הצפיפות שקיבלנו לפונקציית הצפיפות "המקורית" שרשמנו, עם זאת הפונקציות זהות פרט לקבוצה זניחה. כאמור, פונקציית הצפיפות לא נקבעת ביחידות.

2. נתון וקטור $(X,Y)$ עם פונקציית התפלגות:

$$F_{X,Y}(x,y)=\begin{cases} 0 & , \quad x<0 \ or \ y<0 \\ \frac{1}{3}x^2y^2(x+2y) & , \quad 0\le x,y<1 \\ \frac{1}{3}x^2(x+2) & , \quad 0\le x<1,\ 1\le y \\ \frac{1}{3}y^2(1+2y) & , \quad 0\le y<1,\ 1\le x \\ 1 & , \quad 1\le x,y \end{cases}$$

ברור כי $F_{X,Y}$ גזירה ברציפות פעמיים בכל המישור למעט קבוצה זניחה, לכן:

$$f_{X,Y}(x,y)=\frac{\partial^2}{\partial x\partial y}F_{X,Y}(x,y)=\begin{cases} 2x^2y+4xy^2 & , \quad x,y\in[0,1) \\ 0 & , \quad x,y\notin[0,1) \end{cases}$$

כעת, נניח שרוצים לחשב את $P(Y<2X)$, אז נחשב:

$$P(Y<2X)=\iint\limits_{\{Y<2X\}} f_{X,Y}(x,y)\,dxdy=\int_0^1\int_{\frac{1}{2}y}^1 2x^2y+4xy^2dxdy=\cdots=\frac{53}{60}$$

### 17.2 פילוג שולי

בדומה למקרה הבדיד, פילוג של כל תת וקטור הוא נקרא **פילוג שולי**. גם כאן הפילוגים השוליים החד־מימדיים לא קובעים את הפילוג של הוקטור עצמו. ננסח את המשפט על חישוב פונקציית ההתפלגות והצפיפות של הפילוגים השוליים מפונקציית ההתפלגות והצפיפות של הוקטור.

**טענה 4.17** יהא $(X,Y)$ וקטור אקראי, אז:

1. $F_X(x)=\lim\limits_{y\to\infty}F_{X,Y}(x,y)$, $F_Y(y)=\lim\limits_{x\to\infty}F_{X,Y}(x,y)$.
2. אם $(X,Y)$ רציף בהחלט אז $f_X(x)=\int\limits_{\mathbb{R}}f_{X,Y}(x,y)\,dy$, $f_Y(y)=\int\limits_{\mathbb{R}}f_{X,Y}(x,y)\,dx$.

**הערות:**

1. מכלילים לוקטור באורך $n$ וכן לפילוג שולי של כל תת־וקטור.

2. הסעיף הראשון נכון לוקטור אקראי כללי, לא בהכרח בדיד או רציף.

**הוכחה:**

1. נוכיח למשל עבור $X$. לכל $1 \leq n \in \mathbb{N}$ נסמן $A_n = \{X \leq x, Y \leq n\}$ ונבחין כי $A_n \underset{n\to\infty}{\longrightarrow} \{X \leq x\}$. מכאן:

$$F_X(x) = P\{X \leq x\} = P\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} P(A_n) = \lim_{n\to\infty} F_{X,Y}(x,n) \underset{(*)}{=} \lim_{y\to\infty} F_{X,Y}(x,y)$$

$(*)$ הגדרת הגבול לפי היינה, יש לזכור שהפונקציה מונוטונית בכל רכיב.

2. נוכיח למשל עבור $X$. תהא $A \subseteq \mathbb{R}$ אז בעלת שטח, אז:

$$P(X \in A) = P((X,Y) \in A \times \mathbb{R}) = \iint\limits_{A\times\mathbb{R}} f_{X,Y}(x,y)\,dxdy = \int\limits_{A}\int\limits_{\mathbb{R}} f_{X,Y}(x,y)\,dydx$$

לכן פונקציית הצפיפות של $X$ היא $f_X(x) = \int\limits_{\mathbb{R}} f_{X,Y}(x,y)\,dy$.

■

**דוגמאות:**

1. יהא $(X,Y) \sim \mathrm{U}(\{(x,y) \mid x^2+y^2 \leq 1\})$, אז $f_{X,Y}(x,y) = \begin{cases} \frac{1}{\pi} & , \quad (x,y) \in \{(x,y) \mid x^2+y^2 \leq 1\} \\ 0 & , \quad (x,y) \notin \{(x,y) \mid x^2+y^2 \leq 1\} \end{cases}$.

נחשב את הפילוג השולי של $X$, נפריד לתחומים:

| | |
|---|---|
| $\lvert x\rvert > 1$ | $f_X(x) = \int\limits_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = 0$ |
| $\lvert x\rvert \leq 1$ | $f_X(x) = \int\limits_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy = \int\limits_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi}dy = \frac{2}{\pi}\cdot\sqrt{1-x^2}$ |

סה"כ נקבל $f_X(x) = \begin{cases} \frac{2}{\pi}\cdot\sqrt{1-x^2} & , \quad \lvert x\rvert \leq 1 \\ 0 & , \quad \lvert x\rvert > 1 \end{cases}$

**הערה:** נבחין שלמרות שהוקטור $(X,Y)$ מפולג באחידות, הפילוג השולי הוא לא אחיד.

2. יהא $(X,Y)\sim \mathrm{U}\left[0,1\right]^2$, ראינו כי פונקציית ההתפלגות היא:

$$F_{X,Y}\left(x,y\right)=\begin{cases} 0 & , \quad x,y<0 \\ xy & , \quad 0\le x,\ y<1 \\ x & , \quad 0\le x<1,\ 1\le y \\ y & , \quad 0\le y<1,\ 1\le x \\ 1 & , \quad 1\le x,y \end{cases}$$

נחשב את הפילוג השולי של $X$ בעזרת פונקציית ההתפלגות, נפריד לתחומים:

| | |
|---|---|
| $x<0$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=0$ |
| $0\le x<1$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=\lim\limits_{y\to\infty}x=x$ |
| $1\le x$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=\lim\limits_{y\to\infty}1=1$ |

$$\Rightarrow\ F_X\left(x\right)=\begin{cases} 0 & , \quad x<0 \\ x & , \quad 0\le x<1 \\ 1 & , \quad 1\le x \end{cases}$$

סה"כ נקבל $X\sim \mathrm{U}\left[0,1\right]$. באופן דומה נקבל $Y\sim \mathrm{U}\left[0,1\right]$.

3. יהא $(X,Y)$ עם פונקציית התפלגות:

$$F_{X,Y}\left(x,y\right)=\begin{cases} 0 & , \quad y<0\ \ or\ \ x<0 \\ x & , \quad 0\le x\le y,\ x\le 1 \\ y & , \quad 0\le y\le x,\ y\le 1 \\ 1 & , \quad 1\le x,y \end{cases}$$

נחשב את הפילוג השולי של $X$ בעזרת פונקציית ההתפלגות, נפריד לתחומים:

| | |
|---|---|
| $x<0$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=0$ |
| $0\le x<1$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=\lim\limits_{y\to\infty}x=x$ |
| $1\le x$ | $F_X\left(x\right)=\lim\limits_{y\to\infty}F_{X,Y}\left(x,y\right)=\lim\limits_{y\to\infty}1=1$ |

$$\Rightarrow\ F_X\left(x\right)=\begin{cases} 0 & , \quad x<0 \\ x & , \quad 0\le x<1 \\ 1 & , \quad 1\le x \end{cases}$$

**הערה:** בדוגמה הזאת ובדוגמה הקודמת קיבלנו פילוג שולי חד־מימדי זהה אך פונקציית ההתפלגות המשותפת שונה, כלומר הפילוג של הוקטור שונה.

## 18 פילוג מותנה במקרה הכללי

ההגדרה של פילוג מותנה במקרה הבדיד לא מתאימה למשתנה מקרי רציף כיוון שמניחים $P(X=x)\neq 0$ ובמקרה הרציף זה לא מתקיים באף נקודה. כיוון שפונקציית ההתפלגות מוגדרת לכל משתנה מקרי, נרצה להגדיר פילוג מותנה בעזרת פונקציית ההתפלגות. יהיו $X,Y$ משתנים מקריים ויהא $\varepsilon>0$, נביט בביטוי הבא:

$$\frac{P\left(Y\leq y,X\in(x-\varepsilon,x+\varepsilon]\right)}{P\left(X\in(x-\varepsilon,x+\varepsilon]\right)}=\frac{F_{X,Y}\left(x+\varepsilon,y\right)-F_{X,Y}\left(x-\varepsilon,y\right)}{F_X\left(x+\varepsilon\right)-F_X\left(x-\varepsilon\right)}=(\diamondsuit)$$

נרצה לקחת את הגבול כאשר אפסילון שואף לאפס. נתמקד במקרה הרציף בהחלט בו פונקציית ההתפלגות גזירה (כמעט בכל מקום). במקרה זה נמשיך את החישוב באופן הבא בעזרתו של משפט לגרנז'[10]:

$$(\diamondsuit)=\frac{\frac{F_{X,Y}(x+\varepsilon,y)-F_{X,Y}(x-\varepsilon,y)}{(x+\varepsilon)-(x-\varepsilon)}}{\frac{F_X(x+\varepsilon)-F_X(x-\varepsilon)}{(x+\varepsilon)-(x-\varepsilon)}}=\frac{\frac{F_{X,Y}(x+\varepsilon,y)-F_{X,Y}(x-\varepsilon,y)}{(x+\varepsilon)-(x-\varepsilon)}}{\frac{F_X(x+\varepsilon)-F_X(x-\varepsilon)}{(x+\varepsilon)-(x-\varepsilon)}}=\frac{\frac{\partial}{\partial x}F_{X,Y}\left(x_1,y\right)}{\frac{d}{dx}F_X\left(x_2\right)}=\frac{\frac{\partial}{\partial x}F_{X,Y}\left(x_1,y\right)}{f_X\left(x_2\right)}\underset{\varepsilon\to 0}{\longrightarrow}\frac{\frac{\partial}{\partial x}F_{X,Y}\left(x,y\right)}{f_X\left(x\right)}$$

לכן עבור $f_X(x)\neq 0$ נרצה להגדיר $F_{Y|X}(y\mid x)=\frac{\frac{\partial}{\partial x}F_{X,Y}(x,y)}{f_X(x)}$. באופן פורמלי:

**הגדרה 1.18** יהא $(X,Y)$ וקטור אקראי רציף בהחלט עם פונקציית התפלגות גזירה (כמעט בכל מקום). לכל $x\in\mathbb{R}$ עבורו $f_X(x)\neq 0$, **פונקציית ההתפלגות המותנית** של $Y$ בהינתן $X=x$ היא:

$$F_{Y|X}(y\mid x)=\frac{\frac{\partial}{\partial x}F_{X,Y}\left(x,y\right)}{f_X\left(x\right)}$$

**הערות:**

1. ההגדרה הבדידה נובעת למעשה מאותו החישוב.
2. המוטיבציה מדגימה למעשה את ההגדרה הכללית של התפלגות מותנית של שני משתנים מקריים. עם זאת בקורס נתמקד במקרה הבדיד והרציף בהחלט.

[10] אפשר גם ישירות לפי הגדרת הנגזרת.

3. אם נגזור לפי $y$ את $F_{Y|X}$ נקבל:

$$\frac{\partial}{\partial y}F_{Y|X}\left(y\mid x\right)=\frac{\partial}{\partial y}\frac{\frac{\partial}{\partial x}F_{X,Y}\left(x,y\right)}{f_X\left(x\right)}=\frac{f_{X,Y}\left(x,y\right)}{f_X\left(x\right)}$$

כלומר **פונקציית הצפיפות המותנית** של $Y$ בהינתן $X=x$ היא:

$$f_{Y|X}\left(y\mid x\right)=\frac{f_{X,Y}\left(x,y\right)}{f_X\left(x\right)}$$

לכל $x\in\mathbb{R}$ עבורו $f_X\left(x\right)\neq 0$. כך למעשה מגדירים את פונקציית הצפיפות המותנית של וקטור אקראי רציף בהחלט. נבחין שזה אנלוגי להגדרה הבדידה עם פונקציית ההסתברות.

4. באופן אנלוגי לנוסחת ההסתברות השלמה נקבל:

$$f_Y\left(y\right)=\int\limits_{\{x|f_X(x)>0\}}f_{Y|X}\left(y\mid x\right)\cdot f_X\left(x\right)dx$$

**דוגמאות:**

1. יהא $(X,Y)\sim\mathrm{U}\left(\{(x,y)\mid x^2+y^2\leq 1\}\right)$, ראינו כי:

$$f_{X,Y}\left(x,y\right)=\begin{cases}\frac{1}{\pi} & , \quad (x,y)\in\{(x,y)\mid x^2+y^2\leq 1\}\\ 0 & , \quad (x,y)\notin\{(x,y)\mid x^2+y^2\leq 1\}\end{cases}$$

וכן שהפילוג השולי לפי $X$ היא:

$$f_X\left(x\right)=\begin{cases}\frac{2}{\pi}\cdot\sqrt{1-x^2} & , \quad |x|\leq 1\\ 0 & , \quad |x|>1\end{cases}$$

לכן לכל $x\in(-1,1)$ נקבל:

$$f_{Y|X}\left(y\mid x\right)=\frac{f_{X,Y}\left(x,y\right)}{f_X\left(x\right)}=\begin{cases}\frac{\frac{1}{\pi}}{\frac{2}{\pi}\cdot\sqrt{1-x^2}} & , \quad |y|\leq\sqrt{1-x^2}\\ 0 & , \quad |y|>\sqrt{1-x^2}\end{cases}=\begin{cases}\frac{1}{2\sqrt{1-x^2}} & , \quad |y|\leq\sqrt{1-x^2}\\ 0 & , \quad |y|>\sqrt{1-x^2}\end{cases}$$

נבחין כי $f_{Y|X}$ מפולג באחידות בקטע $\left[-\sqrt{1-x^2},\sqrt{1-x^2}\right]$.

2. יהא $X$ משתנה מקרי אשר מוגרל באחידות בקטע $[0,Y]$ כאשר $Y$ הוא משתנה מקרי בעל פונקציית הצפיפות:

$$f_Y(y)=\begin{cases}4ye^{-2y} & , \quad y>0\\ 0 & , \quad y\le 0\end{cases}$$

נחשב את $f_X$. מהנתון נובע כי $X\mid Y$ מפולג באחידות בקטע $[0,Y]$, לכן לכל $x>0$ נקבל:

$$f_X(x)=\int\limits_{\{y|f_Y(y)>0\}} f_{X|Y}(x\mid y)\cdot f_Y(y)\,dy \underset{(*)}{=} \int\limits_x^{\infty}\frac{1}{y}\cdot 4ye^{-2y}dy=2e^{-2x}$$

$(*)$ כאמור $f_{X|Y}$ מפולג באחידות בקטע $[0,Y]$, האינטגרציה היא על $y$ ולכן רוצים $x<y$.

כלומר $X\sim \mathrm{Exp}(2)$.

## 19 אי־תלות במקרה הרציף

ההגדרה שראינו במקרה הבדיד היא למעשה כללית. עם זאת, כעת יש לנו את פונקציית ההתפלגות. נאפיין אי־תלות בעזרת פונקציית ההתפלגות.

**משפט 1.19** יהיו $X,Y$ משתנים מקריים.

1. $X,Y$ בלתי תלויים $\iff$ $F_{X,Y}(x,y)=F_X(x)\cdot F_Y(y)$.
2. אם $X,Y$ רציפים בהחלט אז:

$X,Y$ בלתי־תלויים $\iff$ $(X,Y)$ רציף בהחלט ומתקיים $f_{X,Y}(x,y)=f_X(x)\cdot f_Y(y)$ לכל $x,y\in\mathbb{R}$

**הערות:**

1. מכלילים למספר רב יותר של משתנים.
2. כזכור פונקציית הצפיפות לא נקבעת ביחידות, המשפט אומר שיש פונקציית צפיפות המקיימת את השוויון הנ"ל.
3. מכלילים את ה**משפט על טרנספורמציה** של משתנים מקריים בלתי תלויים. באופן מדוייק: אם $X,Y$ בלתי תלויים אז לכל $f,g:\mathbb{R}\to\mathbb{R}$ רציפות למקוטעין גם $f(X),g(Y)$ בלתי תלויים.

**הוכחה:**

1. $\Leftarrow$: לכל $x,y\in\mathbb{R}$ נחשב:

$$F_{X,Y}(x,y)=P(X\le x,Y\le y)\underset{(*)}{=}P(X\le x)\cdot P(Y\le y)=F_X(x)\cdot F_Y(y)$$

$(*)$ מניחים כי $X,Y$ בלתי־תלויים.

$\Rightarrow$: מניחים כי $F_{X,Y}(x,y)=F_X(x)\cdot F_Y(y)$ לכל $x,y\in\mathbb{R}$ ולכן מההגדרה:

$$P(X\le x,Y\le y)=F_{X,Y}(x,y)=F_X(x)\cdot F_Y(y)=P(X\le x)\cdot P(Y\le y)$$

כלומר $X,Y$ בלתי־תלויים.

2. $\Leftarrow$: נוכיח במקרה בו $F_{X,Y}$ גזירה ברציפות פעמיים. מניחים כי $X,Y$ בלתי־תלויים ולכן:

$$f_{X,Y}=\frac{\partial^2}{\partial x\partial y}F_{X,Y}=\frac{\partial}{\partial x}\frac{\partial}{\partial y}(F_X\cdot F_Y)=\frac{\partial}{\partial x}\frac{\partial}{\partial y}(F_X\cdot F_Y)=\frac{\partial}{\partial x}(F_X\cdot f_Y)=f_X\cdot f_Y$$

$\Rightarrow$: לכל $x,y\in\mathbb{R}$ נחשב:

$$\begin{aligned}P(X\le x,Y\le y)&=\int_{-\infty}^{x}\int_{-\infty}^{y}f_{X,Y}(u,v)\,dudv=\int_{-\infty}^{x}\int_{-\infty}^{y}f_X(u)f_Y(v)\,dudv=\\&=\int_{-\infty}^{x}f_X(u)\left(\int_{-\infty}^{y}f_Y(v)\,dv\right)du=\int_{-\infty}^{x}f_X(u)\,du\cdot\int_{-\infty}^{y}f_Y(v)\,dv=\\&=P(X\le x)\cdot P(Y\le y)\end{aligned}$$

כלומר $X,Y$ בלתי־תלויים.

■

**דוגמאות:**

1. יהא $(X,Y)$ וקטור עם פונקציית צפיפות $f_{X,Y}(x,y)=\begin{cases} xy^7 & , \quad (x,y)\in[0,4]\times[0,1] \\ 0 & , \quad otherwise \end{cases}$ אז קל לראות שבמלבן $[0,4]\times[0,1]$ פונקציית הצפיפות ניתנת לכתיבה כמכפלה של פונקציה במשתנה $x$ עם פונקציה במשתנה $y$ וכנ"ל מחוץ למלבן. כלומר אם נגדיר:

$$f_X(x)=\begin{cases} \frac{1}{8}x & , \quad x\in[0,4] \\ 0 & , \quad x\notin[0,4] \end{cases} \qquad f_Y(y)=\begin{cases} 8y^7 & , \quad y\in[0,1] \\ 0 & , \quad y\notin[0,1] \end{cases}$$

נקבל כי $f_{X,Y}=f_X\cdot f_Y$ בכל המישור.

**הערה:** הפירוק למכפלה הוא לא שרירותי, חשוב לזכור שהאינטגרל המוכלל בכל $\mathbb{R}$ של פונקציית הצפיפות תמיד שווה ל־1.

2. יהא $(X,Y)$ וקטור עם פונקציית צפיפות $f_{X,Y}(x,y)=\begin{cases} xy & , \quad x\in[0,1]\,,\ y\in[0,x] \\ 0 & , \quad otherwise \end{cases}$. על פניו יש הפרדה בין $x$ ל־$y$ בכלל ההתאמה. עם זאת הרישום מטעה כיוון שתחום הפיצול תלוי בקשר בין המשתנים. במקרה זה המשתנים $X,Y$ תלויים (רואים זאת גיאומטרית בתחום אך כדאי לוודא זאת למשל ע"י הפילוגים השוליים ובדיקת ההגדרה או האפיון).

## 19.1 משפט הקונבולוציה למשתנים מקריים רציפים בהחלט

נגדיר את פעולת הקונבולוציה לפונקציות ממשיות כלליות.

**הגדרה 2.19** תהיינה $f,g:\mathbb{R}\to\mathbb{R}$. הקונבולוציה של $f$ עם $g$ (אם היא מוגדרת) היא:

$$(f*g)(t)=\int_{-\infty}^{\infty} f(x)\cdot g(t-x)\,dx$$

**דוגמה:** ניקח את:

$$f(x)=\begin{cases}2 & , \quad |x|\le 1\\ 0 & , \quad |x|>1\end{cases} \quad , \quad g(x)=\begin{cases}1 & , \quad 0\le x\\ 0 & , \quad x<0\end{cases}$$

ונחשב את $f*g$ :

$$(f*g)(t)=\int_{-\infty}^{\infty} f(x)\cdot g(t-x)\,dx=\int_{-1}^{1} 2\cdot g(t-x)\,dx=2\cdot\int_{t-1}^{t+1} g(u)\,du=(*)$$

נפריד למקרים

| | |
|---|---|
| $t<-1$ | $(*)=2\cdot\int_{t-1}^{t+1} 0\,du=0$ |
| $\lvert t\rvert\le 1$ | $(*)=2\cdot\int_{0}^{t+1} 1\,du=2t+2$ |
| $1<t$ | $(*)=2\cdot\int_{t-1}^{t+1} 1\,du=4$ |

לכן:

$$(f*g)(t)=\begin{cases}0 & , \quad t<-1\\ 2t+2 & , \quad |t|\le 1\\ 4 & , \quad 1<6\end{cases}$$

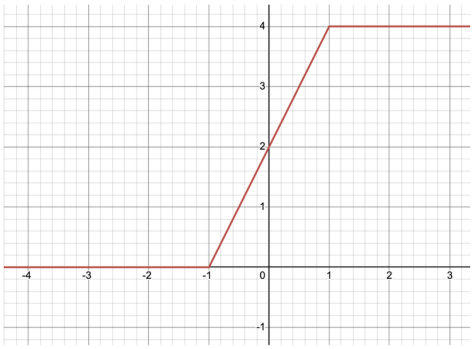


הפירוש הגיאומטרי של הקונבולוציה במקרה זה הוא "מיצוע" של הפונקציה $g$ על־ידי $f$, כלומר בניית פונקציה חדשה מ־$g$ כאשר מחברים את ערכי $g$ "בחלון" ברוחב $4$ אשר מתואר על־ידי $f$.

תכונות בסיסיות כלליות אשר נובעות מההגדרה הן:

**טענה 3.19** תהיינה $f,g,h:\mathbb{R}\to\mathbb{R}$, אם הקונבולוציה מוגדרת אז:

1. חילופיות: $f*g=g*f$.
2. קיבוציות: $(f*g)*h=f*(g*h)$.

נעבור כעת למשפט הקונבולוציה.

**משפט 4.19** (**משפט הקונבולוציה**) יהיו $X,Y$ בלתי־תלויים ורציפים בהחלט, אז $X+Y$ רציף בהחלט ומתקיים:

$$f_{X+Y}(t)=(f_X*f_Y)(t)=\int_{-\infty}^{\infty}f_X(x)\cdot f_Y(t-x)\,dx$$

**הוכחה:** ראשית העובדה שהמשתנה $X+Y$ רציף בהחלט נובעת ממשפט על טרנספורמציה. לגבי השיוויון, נחשב:

$$F_{X+Y}(t)=P(X+Y\le t)=\iint\limits_{\{x+y\le t\}}f_{X,Y}(x,y)\,dxdy=$$

$$=\iint\limits_{\{x+y\le t\}}f_X(x)\cdot f_Y(y)\,dxdy\underset{(*)}{=}\int_{-\infty}^{t}\int_{-\infty}^{\infty}f_X(v)\cdot f_Y(u-v)\,dvdu$$

$(*)$ נבצע החלפת משתנים $u=x+y,\ v=x$.

כעת נגזור לפי $t$ ונקבל:

$$f_{X+Y}(t)=\frac{d}{dt}F_{X+Y}(t)=\frac{d}{dt}\left(\int_{-\infty}^{t}\int_{-\infty}^{\infty}f_X(v)\cdot f_Y(u-v)\,dvdu\right)=$$

$$=\frac{d}{dt}\left(\lim_{M\to\infty}\int_{-M}^{t}\int_{-\infty}^{\infty}f_X(v)\cdot f_Y(u-v)\,dvdu\right)=$$

$$=\lim_{M\to\infty}\left(\frac{d}{dt}\left(\int_{-M}^{t}\int_{-\infty}^{\infty}f_X(v)\cdot f_Y(u-v)\,dvdu\right)\right)\underset{(*)}{=}$$

$$=\int_{-\infty}^{\infty}f_X(v)\cdot f_Y(t-v)\,dv=(f_X*f_Y)(t)$$

$(*)$ גוזרים את האינמטגרל בעזרת כלל השרשרת וחמשפט על גזירות האינטגרת הלא מסויים. אחרי הגזירה הביטוי לא תלוי ב־$M$, כלומר גבול של קבוע שווה לקבוע.

■

מסקנה שימושית ממשפט הקונבולוציה היא התפלגות של סכום משתנים מעריכיים בלתי־תלויים.

**מסקנה 5.19** יהיו $X,Y\sim\mathrm{Exp}\left(\lambda\right)$ בלתי תלויים אז $X+Y\sim\Gamma\left(2,\lambda\right)$.

**הערה:** טענה כללית יותר היא שלכל שני משתנים מקריים $X\sim\Gamma\left(k,\lambda\right),\ Y\sim\Gamma\left(m,\lambda\right)$ בלתי תלויים מתקיים $X+Y\sim\Gamma\left(k+m,\lambda\right)$. מכלילים בצורה אינדוקטיבית לסכום.

**הוכחה:** לפי משפט הקונבולוציה מתקיים $f_{X+Y}=f_X*f_Y$, לכן מספיק להוכיח שפונקציית הצפיפות $f_X*f_Y$ שווה לפונקציית הצפיפות של משתנה עם פילוג $\Gamma\left(2,\lambda\right)$. ראשית נבחין שלכל $t<0$ מתקיים:

$$\left(f_X*f_Y\right)\left(t\right)=\int\limits_{-\infty}^{\infty}f_X\left(x\right)\cdot f_Y\left(t-x\right)dx=\int\limits_{0}^{\infty}\lambda\mathrm{e}^{-\lambda x}\cdot f_Y\left(t-x\right)dx=\int\limits_{-\infty}^{t}\lambda\mathrm{e}^{-\lambda(t-u)}\cdot f_Y\left(u\right)du=0$$

כעת, לכל $0\leq t$ נקבל:

$$\begin{aligned}\left(f_X*f_Y\right)\left(t\right)&=\int\limits_{-\infty}^{\infty}f_X\left(x\right)\cdot f_Y\left(t-x\right)dx=\int\limits_{0}^{\infty}\lambda\mathrm{e}^{-\lambda x}\cdot f_Y\left(t-x\right)dx=\\&=\int\limits_{-\infty}^{t}\lambda\mathrm{e}^{-\lambda(t-u)}\cdot f_Y\left(u\right)du=\int\limits_{0}^{t}\lambda\mathrm{e}^{-\lambda(t-u)}\cdot\lambda\mathrm{e}^{-\lambda u}du=\lambda^2\cdot t\cdot\mathrm{e}^{-\lambda t}.\end{aligned}$$

■

**דוגמה:** נתונות נורות משני סוגים: סוג ראשון עם אורך חיים המפולג מעריכית עם תוחלת של שנה (פרמטר $\lambda=1$) וסוג שני גם עם אורך חיים מפולג מעריכית אך עם תוחלת של שנתיים (פרמטר $\lambda=\frac{1}{2}$). נחשב את ההסתברות ששתי נורות מהסוג הראשון יחזיקו מעמד (אחת אחרי השניה) יותר זמן מאשר נורה אחת מהסוג השני. נסמן את אורך החיים של שתי נורות מהסוג הראשון ב־$X,Y$ וב־$Z$ את אורך החיים של נורה מהסוג השני. רוצים לחשב את $P\left(Z<X+Y\right)$. נתון כי $X,Y\sim\mathrm{Exp}\left(1\right),\ Z\sim\mathrm{Exp}\left(\frac{1}{2}\right)$. המשתנים בלתי תלויים ולכן גם $X+Y,Z$ בלתי־תלויים, מכאן $f_{X+Y,Z}=f_{X+Y}\cdot f_Z$. מטענה קודמת נקבל $X+Y\sim\Gamma\left(2,1\right)$, לכן:

$$\begin{aligned}P\left(Z<X+Y\right)&=\iint\limits_{\{(t,z)|z<t\}}f_{X+Y,Z}\left(t,z\right)dtdz=\iint\limits_{\{(t,z)|z<t\}}f_{X+Y}\left(t\right)\cdot f_Z\left(z\right)dtdz=\\&=\int\limits_{0}^{\infty}\int\limits_{0}^{t}t\cdot\mathrm{e}^{-t}\cdot\frac{1}{2}\cdot\mathrm{e}^{-\frac{1}{2}z}dzdt=\frac{1}{2}\cdot\int\limits_{0}^{\infty}t\cdot\mathrm{e}^{-t}\cdot\left(\int\limits_{0}^{t}\mathrm{e}^{-\frac{1}{2}z}dz\right)dt=\cdots=\frac{8}{9}\end{aligned}$$

## 20 התוחלת והשונות במקרה הרציף בהחלט ובמקרה הכללי

לא נגדיר תוחלת עבור משתנה מקרי כללי, אך נראה בנוסחת הזנב הגדרה שקולה להגדרת התוחלת עבור משתנה מקרי כללי. נכליל את הגדרת התוחלת למקרה הרציף בהחלט:

**הגדרה 1.20** יהא $X$ משתנה מקרי רציף בהחלט. **התוחלת** של $X$ (אם היא מוגדרת) היא:

$$E(X)=\int_{-\infty}^{\infty} x\cdot f_X(x)\,dx$$

**הערות:**

1. גם כאן מגדירים $E^{+}(X)=\int_{0}^{\infty} x\cdot f_x(x)\,dx,\ E^{-}(X)=\int_{-\infty}^{0} -x\cdot f_x(x)\,dx$ ואז התוחלת מוגדרת אם שניהם לא אינסוף.

2. אם התוחלת מוגדרת אז מגדירים את **השונות**, **סטיית התקן** ו**השונות המשותפת** באופן זהה למקרה הבדיד, כלומר:

$$var(X)=E\left((X-E(X))^2\right),\quad \sigma_X=\sqrt{var(X)}$$

$$\sigma_{X,Y}=cov(X,Y)=E\left((X-E(X))\cdot(Y-E(Y))\right)$$

התכונות הבסיסיות שראינו במקרה הבדיד תקפות גם כאן. בפרט המשפט על טרנספורמציה:

**תוחלת של טרנספורמציה**: יהא $X$ משנה רציף בהחלט ותהא $h:\mathbb{R}\to\mathbb{R}$ רציפה למקוטעין, אז:

$$E(h(X))=\int_{-\infty}^{\infty} h(x)\cdot f_X(x)\,dx$$

3. מכלילים למקרה של וקטור אקראי.

**דוגמה:** נתון וקטור $(X,Y)$ עם פונקציית צפיפות $f_{X,Y}(x,y)=\begin{cases}\frac{1}{2y} & , \quad 0<x<y<\frac{1}{x}\\ 0 & , \quad otherwise\end{cases}$. נחשב את:

$$E(X\cdot Y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xy\cdot f_{X,Y}(x,y)\,dxdy=\int_{0}^{1}\int_{x}^{\frac{1}{x}}\frac{xy}{2y}dydx=\cdots=\frac{1}{3}$$

## 20.1 תוחלת ושונות של פילוגים רציפים ידועים

נחשב את התוחלת והשונות של הפילוגים הרציפים בהחלט שראינו:

### פילוג אחיד

אם $X \sim \mathbf{U}[a,b]$ אז כזכור:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & , \quad x \in [a,b] \\ 0 & , \quad x \notin [a,b] \end{cases}$$

נחשב:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx = \int_a^b \frac{x}{b-a}dx = \frac{1}{2} \cdot \frac{b^2-a^2}{b-a} = \frac{b+a}{2}$$

$$E\left(X^2\right) = \int_{-\infty}^{\infty} x^2 \cdot f_X(x)\,dx = \int_a^b \frac{x^2}{b-a}dx = \frac{1}{3} \cdot \frac{b^3-a^3}{b-a} = \frac{b^2+ab+a^2}{3}$$

$$var(X) = E\left(X^2\right) - (E(X))^2 = \frac{b^2+ab+a^2}{3} - \frac{(b+a)^2}{4} = \frac{(b-a)^2}{12}$$

### פילוג מעריכי (אקספוננציאלי)

אם $X \sim \mathbf{Exp}(\lambda)$ אז כזכור:

$$f_X(x) = \begin{cases} \lambda \cdot \mathrm{e}^{-\lambda x} & , \quad x > 0 \\ 0 & , \quad x \leq 0 \end{cases}$$

נחשב:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx = \int_0^{\infty} \lambda x \cdot \mathrm{e}^{-\lambda x}dx = \cdots = \frac{1}{\lambda}$$

$$E\left(X^2\right) = \int_{-\infty}^{\infty} x^2 \cdot f_X(x)\,dx = \int_0^{\infty} \lambda x^2 \cdot \mathrm{e}^{-\lambda x}dx = \cdots = \frac{2}{\lambda^2}$$

$$var(X) = E\left(X^2\right) - (E(X))^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}$$

**פילוג גמא**

אם $X \sim \Gamma(k,\lambda)$ אז כזכור:

$$f_X(x) = \begin{cases} \frac{\lambda^k}{(k-1)!} \cdot x^{k-1} \cdot \mathrm{e}^{-\lambda x} & , \quad x > 0 \\ 0 & , \quad x \le 0 \end{cases}$$

נחשב[11]:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx = \int_{0}^{\infty} \frac{\lambda^k}{(k-1)!} \cdot x^k \cdot \mathrm{e}^{-\lambda x} dx = \cdots = \frac{k}{\lambda}$$

$$E\left(X^2\right) = \int_{-\infty}^{\infty} x^2 \cdot f_X(x)\,dx = \int_{0}^{\infty} \frac{\lambda^k}{(k-1)!} \cdot x^{k+1} \cdot \mathrm{e}^{-\lambda x} dx = \cdots = \frac{k^2+k}{\lambda^2}$$

$$var(X) = E\left(X^2\right) - (E(X))^2 = \frac{k^2+k}{\lambda^2} - \left(\frac{k}{\lambda}\right)^2 = \frac{k}{\lambda^2}$$

**פילוג גאוסי (נורמלי)**

אם $X \sim \mathbf{N}(\mu,\sigma^2)$ אז כזכור:

$$f_X(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \mathrm{e}^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2}$$

נחשב[12]:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx = \int_{-\infty}^{\infty} \frac{x}{\sqrt{2\pi} \cdot \sigma} \cdot \mathrm{e}^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2} dx = \cdots = \mu$$

$$E\left(X^2\right) = \int_{-\infty}^{\infty} x^2 \cdot f_X(x)\,dx = \int_{-\infty}^{\infty} \frac{x^2}{\sqrt{2\pi} \cdot \sigma} \cdot \mathrm{e}^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2} dx = \cdots = \sigma^2 + \mu^2$$

$$var(X) = E\left(X^2\right) - (E(X))^2 = \sigma^2 + \mu^2 - (\mu)^2 = \sigma^2$$

[11] החישוב הוא חישוב ישיר בעזרת שיטות אינטגרציה אך הוא עדיין לא קצר.
[12] גם כאן, החישוב הוא חישוב ישיר בעזרת שיטות אינטגרציה אך הוא עדיין לא קצר.

### 20.2 נוסחת הזנב

נכליל את נוסחת הזנב במקרה הכללי.

**משפט 2.20** (**נוסחת הזנב**) יהא $X$ משנה מקרי אז:

$$\begin{cases} E^{+}(X) = \int\limits_{0}^{\infty} P(X > x)\,dx = \int\limits_{0}^{\infty} 1 - F_X(x)\,dx \\ E^{-}(X) = \int\limits_{-\infty}^{0} P(X < x)\,dx = \int\limits_{-\infty}^{0} F_X(x)\,dx \end{cases}$$

בפרט, אם התוחלת קיימת נקבל:

$$E(X) = \int\limits_{0}^{\infty} P(X > x)\,dx - \int\limits_{-\infty}^{0} P(X < x)\,dx = \int\limits_{0}^{\infty} 1 - F_X(x)\,dx - \int\limits_{-\infty}^{0} F_X(x)\,dx$$

**הערה:** נוסחת הזנב היא למעשה **הגדרה שקולה לתוחלת**. זוהי הגדרה כללית אשר לא תלויה בסוג המשתנה המקרי אלא רק במידת ההסתברות.

**הוכחה:** נסתפק בהוכחת המקרה בו $X$ רציף בהחלט. נחשב:

$$\begin{aligned} E^{+}(X) &= \int\limits_{0}^{\infty} x \cdot f_X(x)\,dx = \int\limits_{0}^{\infty} \left( \int\limits_{0}^{x} 1\,dt \right) \cdot f_X(x)\,dx = \int\limits_{0}^{\infty} \int\limits_{0}^{x} f_X(x)\,dtdx = \\ &= \int\limits_{0}^{\infty} \int\limits_{t}^{\infty} f_X(x)\,dxdt = \int\limits_{0}^{\infty} P(X > t)\,dt = \int\limits_{0}^{\infty} 1 - F_X(t)\,dt \\ E^{-}(X) &= \int\limits_{-\infty}^{0} x \cdot f_X(x)\,dx = \int\limits_{-\infty}^{0} \left( \int\limits_{0}^{x} 1\,dt \right) \cdot f_X(x)\,dx = \int\limits_{-\infty}^{0} \int\limits_{0}^{x} f_X(x)\,dtdx = \\ &= \int\limits_{-\infty}^{0} \int\limits_{-\infty}^{t} f_X(x)\,dxdt = \int\limits_{-\infty}^{0} F_X(t)\,dt = \int\limits_{-\infty}^{0} P(X \le t)\,dt \underset{(*)}{=} \int\limits_{-\infty}^{0} P(X < t)\,dt \end{aligned}$$

$(*)$ האינטגרל לא מושפע משינוי ערך בודד של הפונקציה.

■

**דוגמה:** אמה ותמר קבעו ללכת לקפה ליד הבית של אמה בשעה $17:00$. תמר תגיע לאמה בשעה $17:00$ או קצת מאוחר יותר ואז הן הולכות יחד. במקרה בו תמר לא תגיע לאמה עד השעה $17:30$, אמה תצא לכיוון בית הקפה והן יפגשו שם. נסמן ב־$Y$ את מספר הדקות בהן תמר איחרה ונניח כי $Y \sim \text{Exp}\left(\frac{1}{10}\right)$. נחשב את התוחלת של זמן ההמתנה של אמה. נסמן ב־$X$ את זמן ההמתנה של אמה, אז $X = \min\{Y, 30\}$.
נחשב את פונקציית ההתפלגות של $X$:

| | |
|---|---|
| $x < 0$ | $F_X(x) = P(X \le x) = 0$ |
| $0 \le x < 30$ | $F_X(x) = P(X \le x) = P(Y \le x) = 1 - \mathrm{e}^{-\frac{x}{10}}$ |
| $30 \le x$ | $F_X(x) = P(X \le 30) = 1$ |

לכן:

$$F_X(x) = \begin{cases} 0 & , \quad x < 0 \\ 1 - \mathrm{e}^{-\frac{x}{10}} & , \quad 0 \le x < 30 \\ 1 & , \quad 30 \le x \end{cases}$$

כעת מנוסחת הזנב:

$$E(X) = \int_0^\infty 1 - F_X(x)\,dx - \int_{-\infty}^0 F_X(x)\,dx = \int_0^{30} \mathrm{e}^{-\frac{x}{10}}\,dx = 10\left(1 - \mathrm{e}^{-3}\right) \simeq 9.5$$

כלומר בממוצע אמה תחכה $9.5$ דקות.

### 20.3 תוחלת מותנית ונוסחת ההחלקה במקרה הכללי

נכליל את הגדרת התוחלת המותנית למקרה כללי.

**הגדרה 3.20** יהא $(X, Y)$ וקטור אקראי. **התוחלת המותנית** של $Y$ בהינתן $X = x$ מסומנת על־ידי $E(Y \mid X = x)$ והיא התוחלת של הפילוג $P_{Y|X}(y \mid x)$. אם הוקטור רציף בהחלט נקבל:

$$E(Y \mid X = x) = \int_{-\infty}^{\infty} y \cdot f_{Y|X}(y \mid x)\,dy$$

**הערה:** גם כאן, התוחלת המותנית היא משתנה מקרי.

נכליל את התכונות שראינו במקרה הבדיד

**טענה 4.20** יהיו $X,Y$ משתנים מקריים.

1. אם $X,Y$ בלתי־תלויים אז $E(Y \mid X) = E(Y)$.
2. אם $h:\mathbb{R}\to\mathbb{R}$ רציפה למעט קבוצה סופית של נקודות אז $E(h(X)Y \mid X) = h(X)\cdot E(Y \mid X)$.

ננסח כעת את נוסחת ההחלקה בגרסה הכללית.

**משפט 5.20** (**נוסחת ההחלקה**) יהא $(X,Y)$ וקטור אקראי ונניח כי $Y \in L^2(P)$ אז:

$$E(Y) = E(E(Y \mid X))$$

**הערה:** המשפט נכון גם לשילוב של משתנים מסוגים שונים.

**הוכחה:** נוכיח במקרה הרציף בהחלט. כזכור $E(Y \mid X)$ היא טרנספורמציה על $X$:

$$g(x) = E(Y \mid X = x) = \int_{-\infty}^{\infty} y \cdot f_{Y|X}(y \mid x)\,dy = \int_{-\infty}^{\infty} y \cdot \frac{f_{X,Y}(x,y)}{f_X(x)}dy$$

ואז לפי משפט על תוחלת של טרנספורמציה:

$$\begin{aligned}
E(E(Y \mid X)) &= \int_{-\infty}^{\infty} g(x)\cdot f_X(x)\,dx = \int_{-\infty}^{\infty}\left(\int_{-\infty}^{\infty} y\cdot\frac{f_{X,Y}(x,y)}{f_X(x)}dy\right)\cdot f_X(x)\,dx = \\
&= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} y\cdot\frac{f_{X,Y}(x,y)}{f_X(x)}\cdot f_X(x)\,dydx = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} y\cdot f_{X,Y}(x,y)\,dydx = \\
&= \int_{-\infty}^{\infty} y\cdot\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dxdy = \int_{-\infty}^{\infty} y\cdot f_Y(y)\,dy = E(Y)
\end{aligned}$$

■

**דוגמה:** שוברים מקל באורך 1 המונח על הקטע $[0,1]$ בנקודה אקראית $X$ ואחידה ולאחר מכן שוברים את החלק $[0,X]$ בנקודה אקראית ואחידה $Y$. נחשב את $E(Y)$. מהנתון נובע כי $X \sim \mathrm{U}[0,1]$ וכן $Y \mid X \sim \mathrm{U}[0,X]$, לפיכך:

$$E(Y) = E(E(Y \mid X)) = E\left(\frac{1}{2}\cdot X\right) = \frac{1}{2}\cdot E(X) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4}$$

## 21 וקטור אקראי גאוסי כללי

כזכור אמרנו .שוקטור $\overline{X}$ הוא בעל פילוג גאוסי תקני $n$־מימדי אם $X_1,...,X_n \sim N(0,1)$ בלתי־תלויים, כמו כן פונקציית צפיפות היא:

$$f_{\overline{X}}(\overline{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}} \mathrm{e}^{-\frac{1}{2}|\overline{x}|^2} = \frac{1}{(2\pi)^{\frac{n}{2}}} \mathrm{e}^{-\frac{1}{2}\left(x_1^2+\cdots+x_n^2\right)}$$

**הערה:** נוח לחשוב על $\overline{x}$ כוקטור עמודה ואז מקבלים: $f_{\overline{X}}(\overline{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}} \mathrm{e}^{-\frac{1}{2}\overline{x}^t\overline{x}}$.

מההגדרה ברור שכל תת־וקטור באורך $k$ הוא בעל פילוג גאוסי תקני $k$־מימדי. נביט כעת במקרה פרטי אך נוח ושימושי של משפט על טרנספורמיצה.

**משפט 1.21** יהא $\overline{X}$ הוא בעל פילוג גאוסי תקני $n$־מימדי ותהא $B_{n\times n}$ מטריצה הפיכה, אז $\overline{Y} = B\overline{X}$ הוא וקטור אקראי רציף בהחלט עם פונקציית צפיפות משותפת:

$$f_{\overline{Y}}(\overline{y}) = \frac{1}{|det(B)|} f_{\overline{X}}\left(B^{-1}\overline{Y}\right) = \frac{1}{(2\pi)^{\frac{n}{2}} \cdot |det(B)|} \mathrm{e}^{-\frac{1}{2}\overline{y}^t\left(B^{-1}\right)^t B^{-1}\overline{x}}$$

**הערות:**

1. עבור מטריצה $P_{n\times n}$ הביטוי $\overline{x}^t P\overline{x}$ נקרא **תבנית ריבועית**. עבור $n=2$ ניקח לדוגמה:

$$(x,y)\begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix}\begin{pmatrix} x \\ y \end{pmatrix} = (2x+3y, 3x+5y)\begin{pmatrix} x \\ y \end{pmatrix} = 2x^2+6xy+5y^2$$

2. נזכיר שמטריצה $C$ היא **מוגדרת חיובית** אם כל הערכים העצמיים שלה חיוביים. מוכיחים שזה שקול לעובדה שיש מטריצה $D$ המקיימת $C = D^t D$. לכן אם נסמן $A = \left(B^{-1}\right)^t B^{-1}$ נקבל ש־$A$ מוגדרת חיובית. לפעמים נוח לרשום את פונקציית הצפיפות של $Y$ באופן הבא:

$$f_{\overline{Y}}(\overline{y}) = \frac{\sqrt{det(A)1}}{(2\pi)^{\frac{n}{2}}} \mathrm{e}^{-\frac{1}{2}\overline{y}^t A\overline{x}}$$

כעת אפשר להגדיר וקטור אקראי גאוסי כללי עם פרמטרים $\mu, \Sigma$ בדומה לוקטור גאוסי חד מימדי עם פרמטרים $\mu, \sigma$.

**הגדרה 2.21** יהא $\overline{X}$ וקטור אקראי, נאמר ש־$X$ הוא **וקטור גאוסי** עם תוחלת $\overline{\mu} \in \mathbb{R}^n$ ומטריצה סימטרית ומוגדרת חיובית $\Sigma$ ונסמן $\overline{X} \sim N(\overline{\mu}, \Sigma)$ אם פונקציית הצפיפות היא:

$$f_{\overline{X}}(\overline{x}) = \frac{1}{\sqrt{(2\pi)^n \cdot det(\Sigma)}} e^{-\frac{1}{2}\overline{x-\mu}^t \Sigma^{-1} \overline{x-\mu}}$$

**הערות:**

1. במקרה בו $\overline{\mu} = \overline{0}$ ו־$\Sigma = I$ נקבל פילוג גאוסי תקני $n$־מימדי.
2. אם $\overline{X} \sim N(\overline{\mu}, \Sigma)$ ו־$B$ מטריצה המקיימת $B^2 = \Sigma$ (נהוג לסמן $B = \Sigma^{\frac{1}{2}}$) אז $B^{-1}\left(\overline{X} - \overline{\mu}\right) \sim N\left(\overline{0}, I\right)$.
נסיק שכל וקטור גאוסי $\overline{X} \sim N(\overline{\mu}, \Sigma)$ ניתן לרשום על־ידי $\overline{X} = \Sigma^{\frac{1}{2}} Z + \overline{\mu}$ כאשר $\overline{Z} \sim N\left(\overline{0}, I\right)$.

יש קשר מפתיע בין הקוואריאנס של רכיבי הוקטור למטריצה $\Sigma$.

**הגדרה 3.21** אם $\overline{X}$ ו־$X_1, ..., X_n \in L^2(P)$ אז **מטריצת הקוואריאנס** של $\overline{X}$ היא:

$$\Sigma_{\overline{X}} = \begin{pmatrix} cov(X_1, X_1) & \cdots & cov(X_1, X_n) \\ \vdots & \ddots & \vdots \\ cov(X_n, X_1) & \cdots & cov(X_n, X_n) \end{pmatrix}$$

מתכונות של הקוואריאנס נובע שהמטריצה היא סימטרית. בנוסף חישוב ישיר מראה שהמטריצה אי־שלילית.

**משפט 4.21** אם $\overline{X} \sim N(\overline{\mu}, \Sigma)$ אז $\Sigma$ היא מטריצת הקוואריאנס של $\overline{X}$.

לבסוף נסכם במשפט מספר תכונות חשובות של וקטור גאוסי.

**משפט 5.21** יהא $\overline{X} \sim N(\overline{\mu}, \Sigma)$.

1. לכל מטריצה הפיכה $M_{n\times n}$ ולכל וקטור עמודה $\bar{z}$ מתקיים $M\overline{X} + \bar{z} \sim N(\bar{z} + M\overline{\mu}, M\Sigma M^t)$.
2. אם $\overline{X} \sim N\left(\overline{0}, I\right)$ אז רכיבי הוקטור $\overline{X}$ בלתי־תלויים וכולם מתפלגים $N(0,1)$.
3. לכל $i$ מתקיים $X_i \sim N(\mu_i, \Sigma_{ii})$.
4. $X_1, ..., X_n$ בלתי תלויים $\iff$ $\Sigma$ אלכסונית.
5. לכל $i, j$ המשתנה $X_i \mid X_j$ מתפלג גאוסית.

# 22 משפטי הגבול

## 22.1 סדרת משתנים מקריים ומושג ההתכנסות

ראשית נגדיר סדרה של משתנים מקריים.

**הגדרה 1.22** **סדרת משתנים מקריים** מעל אותו מרחב ההסתברות מסומנת על־ידי $\{X_n\}_{n=1}^{\infty}$. אם בנוסף המשתנים בלתי תלויים ומפולגים זהה אומרים שהסדרה היא i.i.d. **סדרת הסכומים החלקיים** של הסדרה $\{X_n\}_{n=1}^{\infty}$ היא הסדרה $S_n^{\{X_n\}} = \sum_{k=1}^{n} X_k$.

**הערה:** המשפטים שנראה בקרוב יעזרו לנו להבין את ההסתברות של סדרת הסכומים החלקיים. איך זה עוזר? אם נתון תהליך בו יש מספר "גדול מספיק" של שלבים, למשל משחקים מספיק פעמים את אותו המשחק בקזינו או בוחנים הסתברות עבור אוכלוסיה מספיק גדולה, ניתן להשתמש במשפטים שנראה ולקבל הערכה טובה על ההסתברות.

**דוגמאות:**

1. בסדרה אינסופית של ניסויי ברנולי נגדיר $X_n$ להיות הצלחה בניסוי ה־$n$. המשתנים הנ"ל בלתי תלויים ומפולגים $\mathrm{Ber}(p)$, לכן נקבל סדרה $\{X_n\}_{n=1}^{\infty}$ שהיא i.i.d. סדרת הסכומים החלקיים $\left\{S_n^{\{X_n\}}\right\}$ מייצגת את מספר ההצלחות מתוך $n$ ניסויים, לכן $S_n^{\{X_n\}} \sim \mathrm{Bin}(n,p)$.

2. **הילוך מקרי**: חלקיק נמצא על הציר בנקודה $x=0$. בכל שניה הוא קופץ לנקודה אקראית לפי הכלל הבא: אם בזמן $n$ הוא נמצא בנקודה $X_n$ אז בזמן $n+1$ הוא יימצא בנקודה $X_{n+1} = X_n + Z_{n+1}$ כאשר $\{Z_n\}_{n=1}^{\infty}$ היא סדרה של משתנים מקריים, ברור כי $\{X_n\}_{n=1}^{\infty}$ היא סדרת הסכומים החלקיים של $\{Z_n\}_{n=1}^{\infty}$ כלומר $X_n = \sum_{k=1}^{n} Z_k$. נתמקד במקרה בו $\{Z_n\}_{n=1}^{\infty}$ היא i.i.d.

כעת נעבור למושג ההתכנסות. נראה שלושה סוגים שונים של התכנסות.

### 22.1.1 התכנסות בהתפלגות

**הגדרה 2.22** נאמר שסדרה $\{X_n\}_{n=1}^{\infty}$ **מתכנסת בהתפלגות** למשתנה מקרי $X$ ונסמן $X_n \xrightarrow{d} X$ אם מתקיים $\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$ בכל $x$ בו $F_X(x)$ רציפה.

**הערה:** באופן אינטואיטיבי, התכנסות בהתפלגות אומרת שעבור $n$ גדול מספיק ההסתברות ש־$X_n$ שייך לקטע $I$ קרובה להסתברות ש־$X$ שייך לקטע $I$. או במילים אחרות, ההתפלגות של $X_n$ "נראית יותר ויותר" כמו ההתפלגות של $X$ אבל הערכים לא בהכרח מזדהים.

**דוגמאות:**

1. תהא $\{X_n\}_{n=1}^{\infty}$ סדרה קבועה $X_n = X$ לכל $n$. ברור שהיא i.i.d וכן שלכל $n$ מתקיים $F_{X_n}(x) = F_X(x)$, לכן לכל $x$ מתקיים:

$$\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$$

כלומר $X_n \xrightarrow{d} X$.

2. תהא $\{X_n\}_{n=1}^{\infty}$ סדרת משתנים מקריים עם פונקציית התפלגות:

$$F_{X_n}(x) = \begin{cases} 1-\left(1-\frac{1}{n}\right)^{nx} & , \quad x \geq 0 \\ 0 & , \quad x < 0 \end{cases}$$

נוכיח כי הסדרה מתכנסת בהתפלגות למשתנה $X \sim \mathrm{Exp}(1)$. יהא $x \in \mathbb{R}$, נפריד למקרים:

| | |
|---|---|
| $x < 0$ | $\lim_{n\to\infty} F_{X_n}(x) = \lim_{n\to\infty} 0 = 0 = F_X(x)$ |
| $0 \leq x$ | $\lim_{n\to\infty} F_{X_n}(x) = \lim_{n\to\infty} \left(1-\left(1-\frac{1}{n}\right)^{nx}\right) = 1-\mathrm{e}^{-x} = F_X(x)$ |

כלומר $X_n \xrightarrow{d} X$.

### 22.1.2 התכנסות בהסתברות

**הגדרה 3.22** נאמר שסדרה $\{X_n\}_{n=1}^{\infty}$ **מתכנסת בהסתברות** למשתנה מקרי $X$ ונסמן $X_n \xrightarrow{P} X$ אם לכל $\varepsilon > 0$

מתקיים $\lim_{n\to\infty} P\left(|X_n - X| > \varepsilon\right) = 0$.

**הערה:** התכנסות בהסתברות היא התכנסות חזקה יותר מהתכנסות בהתפלגות, כלומר התכנסות בהסתברות גוררת התכנסות בהתפלגות. עם זאת הכיוון ההפוך לא נכון. נראה זאת מייד בדוגמה.

**דוגמאות:**

1. נגדיר סדרה $\{X_n\}_{n=1}^{\infty}$ של אינדיקטורים כאשר $X_n = n$ בהסתברות $\frac{1}{n}$ (אחרת $X_n = 0$). הסדרה מתכנסת בהסתברות למשתנה המקרי הקבוע $X \equiv 0$, כלומר $X_n \xrightarrow{P} 0$. אכן, לכל $\varepsilon > 0$ נקבל:

$$P\left(|X_n - 0| > \varepsilon\right) = P\left(X_n > \varepsilon\right) = 1 - F_{X_n}\left(\varepsilon\right) = \frac{1}{n} \underset{n\to\infty}{\longrightarrow} 0$$

2. תהא $\{X_n\}_{n=1}^{\infty}$ סדרה המקיימת $X_n \sim \mathrm{Exp}\left(n\right)$, נוכיח שהסדרה מתכנסת בהסתברות למשתנה המקרי הקבוע $X \equiv 0$ , כלומר $X_n \xrightarrow{P} 0$. אכן, לכל $\varepsilon > 0$ נקבל:

$$P\left(|X_n - 0| > \varepsilon\right) = P\left(X_n > \varepsilon\right) = \mathrm{e}^{-\varepsilon n} \underset{n\to\infty}{\longrightarrow} 0$$

3. תהא $\{X_n\}_{n=1}^{\infty}$ סדרה של משתנים מקריים רציפים בהחלט עם פונקציית צפיפות:

$$f_{X_n}\left(x\right) = \begin{cases} \frac{n}{2} & , \quad x \in \left[-\frac{1}{n}, \frac{1}{n}\right] \\ 0 & , \quad x \notin \left[-\frac{1}{n}, \frac{1}{n}\right] \end{cases}$$

נוכיח שהסדרה מתכנסת בהסתברות למשתנה המקרי הקבוע $X \equiv 0$. אכן, לכל $\varepsilon > 0$ נקבל:

$$P\left(|X_n - 0| > \varepsilon\right) = P\left(|X_n| > \varepsilon\right) = 1 - P\left(|X_n| \le \varepsilon\right) =$$

$$= 1 - \int_{-\varepsilon}^{\varepsilon} f_{X_n}\left(x\right) dx \underset{(*)}{=} 1 - \int_{-\frac{1}{n}}^{\frac{1}{n}} \frac{n}{2} dx = 1 - \frac{n}{2} \cdot \frac{2}{n} = 0 \underset{n\to\infty}{\longrightarrow} 0$$

$(*)$ עבור $n$ גדול מספיק.

4. תהא $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d כאשר $X_n \sim \mathrm{N}(0,1)$ ויהא $X \sim \mathrm{N}(0,1)$ בלתי תלוי בסדרה. ברור שפונקציית ההתפלגות של כל $X_n$ זהה לזאת של $X$ ולכן $X_n \xrightarrow{d} X$. עם זאת לכל $n$ מתקיים $X_n - X \sim \mathrm{N}(0,2)$ ולכן $\varepsilon > 0$ ובפרט $\varepsilon = 1$ נקבל שלכל $n$:

$$P(|X_n - X| > \varepsilon) \simeq 0.31$$

כלומר $X_n \not\xrightarrow{P} X$.

### 22.1.3 התכנסות כמעט בטוח

**הגדרה 4.22** נאמר שסדרה $\{X_n\}_{n=1}^{\infty}$ **מתכנסת כמעט בטוח** למשתנה מקרי $X$ ונסמן $X_n \xrightarrow{a.s.} X$ אם מתקיים:

$$P\left(\left\{\omega \mid \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1$$

**הערות:**

1. ננסה לחדד את ההבדל בין התכנסות בהסתברות להתכנסות כמעט בטוח. נניח שנתונה סדרה $\{X_n\}_{n=1}^{\infty}$ המייצגת תוצאת הטלה של קוביה הוגנת אינסוף פעמים. סדרת הסכומים החלקיים $Y_n = \frac{1}{n} \cdot \sum_{k=1}^{n} X_k$ מתארת את ממוצע ההטלות עד ההטלה ה־$n$. נראה בקרוב שהסדרה $\{Y_n\}_{n=1}^{\infty}$ שואפת ל־$\frac{7}{2}$ בהסתברות וגם כמעט בטוח. העובדה שיש התכנסות כמעט בטוח ל־$\frac{7}{2}$ אומרת שבהסתברות 1 הממוצע שואף ל־$\frac{7}{2}$, כלומר לאורך זמן, הממוצע יהיה "קרוב כרצוננו" ל־$\frac{7}{2}$. עם זאת, העובדה שיש התכנסות בהסתברות אומרת שההסתברות שהממוצע לא יהיה בסביבת הערך $\frac{7}{2}$ שואפת לאפס אך עדיין יכולה להיות חיובית לאורך זמן.

2. התכנסות כמעט בטוח היא התכנסות חזקה יותר, כלומר התכנסות כמעט בטוח גוררת התכנסות בהסתברות. עם זאת הכיוון ההפוך לא נכון, נראה זאת מייד בדוגמה.

**דוגמאות:**

1. נגדיר סדרה $\{X_n\}_{n=1}^{\infty}$ כאשר $X_n \sim \text{Bern}\left(\frac{1}{2}\right)$ ותהא $Y_n = 2^n \cdot X_1 \cdots X_n$. נוכיח כי $\{Y_n\}_{n=1}^{\infty}$ מתכנסת כמעט בטוח למשתנה המקרי $Y \equiv 0$. יהא $\varepsilon > 0$ קטן מספיק (נדרוש $\varepsilon < 2^n$) ונקבל:

$$P\left(\{|Y_k - 0| < \varepsilon \mid \ \forall k \geq n\}\right) = P\left(\{X_k = 0 \mid \ \exists k \leq n\}\right) =$$
$$= 1 - P\left(\{X_k = 1 \mid \ \forall k \leq n\}\right) = 1 - \left(\frac{1}{2}\right)^n \xrightarrow[n\to\infty]{} 1$$

2. ראינו שהסדרה $\{X_n\}_{n=1}^{\infty}$ של אינדיקטורים כאשר $X_n = n$ בהסתברות $\frac{1}{n}$ מתכנסת בהסתברות למשתנה המקרי הקבוע $X \equiv 0$. נוכיח שהסדרה לא מתכנסת כמעט בטוח למשתנה המקרי הקבוע $X \equiv 0$. אכן לכל $\varepsilon \in (0,1)$ ולכל $k \in \mathbb{N}$ מתקיים:

$$P\left(\{|X_k - 0| < \varepsilon \mid \ \forall n \geq k\}\right) = \lim_{n\to\infty}\left(1 - \frac{1}{k}\right)\cdot\left(1 - \frac{1}{k+1}\right)\cdots\left(1 - \frac{1}{n}\right) =$$
$$= \lim_{n\to\infty}\frac{(k-1)\cdot k\cdots(n-1)}{k\cdot(k+1)\cdots n} = \lim_{n\to\infty}\frac{k-1}{n} = 0 \neq 1$$

### 22.2 החוק החלש של המספרים הגדולים

כזכור התוחלת בדקה ממוצע משוכלל של ערכי המשתנה המקרה. כעת רוצים לבדוק את ממוצע הערכים לאורך זמן, כלומר כתלות במספר הניסויים.

**משפט 5.22** (**WLLN**) תהא $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d כאשר $X_n \in L^2(P)$ לכל $n$. נסמן[13] $E(X_n) = \mu$ ונקבל שממוצע הערכים מתכנס בהסתברות לתוחלת, כלומר $\frac{1}{n}\cdot S_n = \frac{1}{n}\cdot\sum_{k=1}^{n} X_k \xrightarrow{P} \mu$.

**הערות:**

1. לפי ההגדרה נקבל שלכל $\varepsilon > 0$ מתקיים $\lim_{n\to\infty} P\left(\left|\frac{1}{n}\cdot\sum_{k=1}^{n} X_k - \mu\right| > \varepsilon\right) = 0$. באופן שקול אפשר לנסח עם המשלים:

$$P\left(\left|\frac{1}{n}\cdot\sum_{k=1}^{n} X_k - \mu\right| \leq \varepsilon\right) = 1 - P\left(\left|\frac{1}{n}\cdot\sum_{k=1}^{n} X_k - \mu\right| > \varepsilon\right) = \xrightarrow[n\to\infty]{} 1$$

[13] התוחלת לא תלויה ב־$n$ כיוון שהפילוג אחיד.

2. בהוכחה רואים את אי השיוויון השימושי הבא: $P\left(\left|\frac{1}{n}\cdot\sum_{k=1}^{n}X_k-\mu\right|>\varepsilon\right)\leq\frac{\sigma^2}{n\cdot\varepsilon^2}$ כאשר $\sigma^2=var\left(X_n\right)$.

**הוכחה:** ראשית נבחין כי:

$$E\left(S_n\right)=E\left(\sum_{k=1}^{n}X_k\right)=\sum_{k=1}^{n}E\left(X_k\right)=\sum_{k=1}^{n}\mu=n\cdot\mu$$
$$var\left(S_n\right)=var\left(\sum_{k=1}^{n}X_k\right)=\sum_{k=1}^{n}var\left(X_k\right)=\sum_{k=1}^{n}\sigma^2=n\cdot\sigma^2$$

לכן מצ'בישב:

$$P\left(\left|\frac{1}{n}\cdot S_n-\mu\right|>\varepsilon\right)=P\left(\left|\frac{1}{n}\cdot S_n-E\left(\frac{1}{n}\cdot S_n\right)\right|>\varepsilon\right)\leq\frac{var\left(\frac{1}{n}\cdot S_n\right)}{\varepsilon^2}=\frac{\frac{1}{n^2}\cdot var\left(S_n\right)}{\varepsilon^2}=\frac{\sigma^2}{n\cdot\varepsilon^2}$$

סה"כ נקבל:

$$P\left(\left|\frac{1}{n}\cdot S_n-\mu\right|>\varepsilon\right)\leq\frac{\sigma^2}{n\cdot\varepsilon^2}\underset{n\to\infty}{\longrightarrow}0$$

■

**דוגמה:** מטילים קוביה הוגנת 1000 פעמים, נעריך את ההסתברות שממוצע ההטלות יהיה בטווח $[3.4,3.6]$. נסמן ב־$X_n$ את תוצאת כל הטלה ואז $S_n=\sum_{k=1}^{n}X_k$. כזכור:

$$E\left(X_n\right)=\mu=3.5,\quad var\left(X_n\right)=\sigma^2=\tfrac{91}{6}-\tfrac{49}{4}\simeq 2.92$$

רוצים להעריך את $P\left(3.4\leq\frac{S_{1000}}{1000}\leq 3.6\right)$, נחשב:

$$P\left(3.4\leq\frac{S_{1000}}{1000}\leq 3.6\right)=P\left(\left|\frac{S_{1000}}{1000}-3.5\right|\leq 0.1\right)=$$
$$=1-P\left(\left|\frac{S_{1000}}{1000}-3.5\right|>0.1\right)\geq 1-\frac{\sigma^2}{1000\cdot(0.1)^2}\simeq 0.71$$

כלומר ההסתברות היא $71\%$.

### 22.3 החוק החזק של המספרים הגדולים

נראה כעת גרסה חזקה ומדוייקת יותר של החוק החלש. ההוכחה מורכבת יותר ולא נעבור עליה.

**משפט 6.22** (SLLN) תהא $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d כאשר $X_n\in L^1\left(P\right)$ לכל $n$. נסמן $E\left(X_n\right)=\mu$ ונקבל שממוצע הערכים מתכנס כמעט בטוח לתוחלת, כלומר $\frac{1}{n}\cdot S_n=\frac{1}{n}\cdot\sum_{k=1}^{n}X_k\xrightarrow{a.s.}\mu$.

**הערה:** בחוק החלש דורשים $X_n \in L^2(P)$ שזה גורר $X_n \in L^1(P)$, לכן החוק החזק תקף במקרה הקודם וגם נותן התכנסות חזקה יותר.

**דוגמאות:**

1. יהיו $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d מפולגים $\text{Exp}(\lambda)$, לפי החוק החזק נקבל $\frac{1}{n} \cdot S_n = \frac{1}{n} \cdot \sum_{k=1}^{n} X_k \xrightarrow{a.s.} \frac{1}{\lambda}$.

   **הערה:** נבחין שמהנתון ומשפט הקונבולוציה נקבל $S_n \sim \Gamma(n, \lambda)$

2. מטילים קוביה הוגנת אינסוף פעמים. האם אפשר לטעון שאחרי מספיק הטלות בהכרח נקבל את הערך 1? נסמן ב־$\frac{S_n}{n}$ את ממוצע הפעמים שיצא 1 בהטלה, רוצים לטעון שיש $n$ עבורו $\frac{S_n}{n} > 0$ בהסתברות 1. החוק החלש נותן הסתברות השואפת ל־1 אך לא מבטיח שיש שלב בו ההסתברות היא 1 ולכן לא ניתן להסיק שיש $n$ כזה. עם זאת, החוק החזק אומר $\frac{S_n}{n} \xrightarrow{a.s.} \frac{1}{6}$ בהסתברות 1 ולכן יש $n$ כזה.

### 22.4 משפט הגבול המרכזי

ראינו שעבור $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d מתקיים שהסדרה $\frac{S_n}{n}$ שואפת (באופן כזה אחר) לתוחלת $\mu = E(X_n)$, לכן בקירוב $S_n \sim \mu \cdot n$ כלומר[14] $S_n = \mu \cdot n + o(n)$. בדומה לפיתוח טיילור, רוצים להבין את הגורם הבא בקירוב.

**משפט 7.22** (CLT) תהא $\{X_n\}_{n=1}^{\infty}$ סדרה i.i.d כאשר $X_n \in L^2(P)$ לכל $n$ ונסמן $E(X_n) = \mu,\ var(X_n) = \sigma^2$. אז הסדרה $Z_n = \frac{S_n - n \cdot \mu}{\sqrt{n} \cdot \sigma}$ מתכנסת בהתפלגות למשתנה $Z \sim \text{N}(0,1)$, כלומר:

$$Z_n \xrightarrow{d} Z \sim \text{N}(0,1)$$

**הערות:**

1. הפילוג של $Z$ הוא תמיד $\text{N}(0,1)$, בלי תלות בפילוג של המשתנים בסדרה $\{X_n\}_{n=1}^{\infty}$.

2. מסיקים כי $S_n = \mu \cdot n + \sqrt{n}\sigma Z + o(\sqrt{n})$ כאשר $Z \sim \text{N}(0,1)$.

[14] כזכור אומרים כי $f(n) = o(g(n))$ אם $\lim_{n \to \infty} \frac{f(n)}{g(n)} = 0$.

3. באופן מפורש יותר, המשפט אומר:

$$\lim_{n\to\infty} P\left(\frac{S_n - n\cdot\mu}{\sqrt{n}\cdot\sigma} \le z\right) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} \mathrm{e}^{-\frac{t^2}{2}} dt = \Phi(z)$$

למעשה במקרים רבים רוצים לחשב הסתברות של $S_n$ בטווח מסויים, נאמר $P(\alpha_1 \le S_n \le \alpha_2)$. במקרה זה נבצע את החישוב הבא:

$$P(\alpha_1 \le S_n \le \alpha_2) = P\left(\frac{\alpha_1 - n\cdot\mu}{\sqrt{n}\cdot\sigma} \le \frac{S_n - n\cdot\mu}{\sqrt{n}\cdot\sigma} \le \frac{\alpha_2 - n\cdot\mu}{\sqrt{n}\cdot\sigma}\right) = (\diamondsuit)$$

נסמן $Z_n = \frac{S_n - n\cdot\mu}{\sqrt{n}\cdot\sigma}$, $z_2 = \frac{\alpha_2 - n\cdot\mu}{\sqrt{n}\cdot\sigma}$, $z_1 = \frac{\alpha_1 - n\cdot\mu}{\sqrt{n}\cdot\sigma}$ ונקבל:

$$(\diamondsuit) = P(z_1 \le Z_n \le z_2) = P(Z_n \le z_2) - P(Z_n < z_1) \xrightarrow[n\to\infty]{CLT} \Phi(z_2) - \Phi(z_1)$$

כזכור את ערכי $\Phi$ מחשבים בעזרת טבלת ערכים או פונקציית השגיאה שראינו בעבר.

4. כאשר מקרבים משתנה מקרי בדיד בעזרת משתנה מקרי רציף נוצר אי דיוק. יש "טריק" נחמד שעוזר לשפר את הקירוב. ננסח אותו כרגע ונדגים בהמשך:

**תיקון רציפות**: יהיו $X_1, ..., X_n$ משתנים מקריים בדידים i.i.d ונסמן $Y = \sum_{k=1}^{n} X_k$. יהיו $l, m \in \mathbb{Z}$ כך ש־$l < m$ ונניח שרוצים לחשב את ההסתברות של המאורע $A = \{l \le Y \le m\}$. מההגדרה, $Y$ מקבל ערכים שלמים ולכן:

$$P(A) = P\left(l - \frac{1}{2} \le Y \le m + \frac{1}{2}\right)$$

מסתבר שחישוב ההסתברות של $P\left(l - \frac{1}{2} \le Y \le m + \frac{1}{2}\right)$ בעזרת משפט הגבול המרכזי נותן קירוב טוב יותר להסתברות של $P(A)$.

**הערה:** הקירוב טוב במיוחד כאשר $\{X_k\}$ בעלי פילוג ברנולי ואז $Y$ הוא בעל פילוג בינומי.

**דוגמאות:**

1. מטילים שתי קוביות $1000$ פעמים. נחשב את ההסתברות שקיבלנו פעמיים 1 יותר מ־$30$ פעמים. בכל הטלה ההסתברות לקבל $1$ היא $\frac{1}{36}$, לכן אם נסמן ב־$X$ את מספר הפעמים שקיבלנו $1$ אז $X \sim \text{Bin}\left(1000, \frac{1}{36}\right)$ וההסתברות המבוקשת היא:

$$P\left(X > 30\right) = \sum_{k=31}^{1000} \binom{1000}{k} \cdot \left(\frac{1}{36}\right)^k \cdot \left(\frac{35}{36}\right)^{1000-k}$$

לא ממש ניתן לחשב ערך זה, לכן ניעזר במשפט הגבול המרכזי. נרשום את $X$ כסכום של אינדיקטורים בלתי תלויים בעלי פילוג ברנולי. נסמן ב־$U_n$ הצלחה בהטלה ה־$n$־ית (כלומר יצא פעמיים 1) ואז $X = \sum_{k=1}^{1000} U_k$. כעת ממשפט הגבול המרכזי עבור:

$$n = 1000, \quad \mu = E\left(U_n\right) = \frac{1}{36}, \quad \sigma = \sqrt{var\left(U_n\right)} = \sqrt{\frac{1}{36} \cdot \frac{35}{36}}, \quad Z_{1000} = \frac{\sum_{k=1}^{1000} U_k - 1000 \cdot \frac{1}{36}}{\sqrt{1000} \cdot \sqrt{\frac{1}{36} \cdot \frac{35}{36}}}$$

נקבל:

$$\begin{aligned}
P\left(X > 30\right) &= P\left(\sum_{k=1}^{1000} U_k > 30\right) = P\left(\sum_{k=1}^{1000} U_k - 1000 \cdot \frac{1}{36} > 30 - 1000 \cdot \frac{1}{36}\right) = \\
&= P\left(\frac{\sum_{k=1}^{1000} U_k - 1000 \cdot \frac{1}{36}}{\sqrt{1000} \cdot \sqrt{\frac{1}{36} \cdot \frac{35}{36}}} > \frac{30 - 1000 \cdot \frac{1}{36}}{\sqrt{1000} \cdot \sqrt{\frac{1}{36} \cdot \frac{35}{36}}}\right) = P\left(Z_{1000} > \overbrace{\frac{30 - 1000 \cdot \frac{1}{36}}{\sqrt{1000} \cdot \sqrt{\frac{1}{36} \cdot \frac{35}{36}}}}^{z_0}\right) = \\
&= P\left(Z_{1000} > z_0\right) = 1 - P\left(Z_{1000} \leq z_0\right) \overset{CLT}{\simeq} 1 - \Phi\left(z_0\right)
\end{aligned}$$

מתקיים:

$$z_0 = \frac{30 - 1000 \cdot \frac{1}{36}}{\sqrt{1000} \cdot \sqrt{\frac{1}{36} \cdot \frac{35}{36}}} \simeq 0.428$$

לפיכך:

$$P\left(X > 30\right) \simeq 1 - \Phi\left(0.428\right) \simeq 0.33$$

כלומר יש סיכוי של כ־$33\%$ שקיבלנו פעמיים 1 יותר מ־$30$ פעמים ב־$1000$ הטלות.

2. נניח כי $Y \sim \text{Bin}\left(16, \frac{1}{2}\right)$ ורוצים לחשב את $P\left(8 \leq Y \leq 10\right)$. ניתן לרשום את $Y$ כסכום של 16 משתנים $X_k \sim \text{Bern}\left(\frac{1}{2}\right)$ שהם i.i.d, כלומר $Y = \sum_{k=1}^{16} X_k$. מדובר בפילוג ברנולי ולכן $\mu = \frac{1}{2},\ \sigma^2 = \frac{1}{4}$. נרשום:

$$P\left(8 \leq Y \leq 10\right) = P\left(\overbrace{\frac{8 - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{2}}}^{0} \leq \frac{Y - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{2}} \leq \overbrace{\frac{10 - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{2}}}^{1}\right)$$

כעת ממשפט הגבול המרכזי:

$$P\left(8 \leq Y \leq 10\right) \overset{CLT}{\simeq} \Phi\left(1\right) - \Phi\left(0\right) \simeq 0.3413$$

במקרה זה את ההסתברות המבוקשת אפשר לחשב במדוייק ובקלות יחסית:

$$P\left(8 \leq Y \leq 10\right) = \sum_{k=8}^{10} \binom{16}{k} \cdot \left(\frac{1}{2}\right)^k \cdot \left(\frac{1}{2}\right)^{16-k} = \left(\frac{1}{2}\right)^{16} \cdot \sum_{k=6}^{10} \binom{16}{k} = \frac{32318}{2^{16}} \simeq 0.4931$$

נבדוק מה קורה כאשר מבצעים תיקון רציפות:

$$P\left(7.5 \leq Y \leq 10.5\right) = P\left(\overbrace{\frac{7.5 - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{2}}}^{-0.25} \leq \frac{Y - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{4}} \leq \overbrace{\frac{10.5 - 16 \cdot \frac{1}{2}}{\sqrt{16} \cdot \frac{1}{2}}}^{1.25}\right)$$

לכן:

$$P\left(7.5 \leq Y \leq 10.5\right) \overset{CLT}{\simeq} \Phi\left(1.25\right) - \Phi\left(-0.25\right) \simeq 0.4930$$

כלומר תיקון הרציפות שיפר משמעותית את הקירוב.

3. נתון חלקיק המבצע הילוך מקרי על המספרים השלמים $\mathbb{Z}$ באופן הבא: הוא מתחיל ב־$X_0 = 0$ ובכל שניה הוא זז יחידה אחת ימינה או שמאלה בהסתברות שווה. נסמן ב־$U_n$ את הקפיצה ה־$n$־ית ואז $X_n = \sum_{k=1}^{n} U_k$. בבירור:

$$E(U_n) = 0, \quad var(U_n) = 1, \quad E(X_n) = 0$$

לפי החוק החלש נקבל:

$$P\left(-\frac{n}{2} \le X_n \le \frac{n}{2}\right) = 1 - P\left(\left|\frac{X_n}{n} - 0\right| > \frac{1}{2}\right) \underset{n\to\infty}{\longrightarrow} 1$$

כלומר ההסתברות שהחלקיק נמצא בקטע $\left[-\frac{n}{2}, \frac{n}{2}\right]$ שואפת ל־1. אינטואיטיבית, המיקום של החלקיק הוא בערך באפס עם שגיאה מסדר גודל קטן מ־$n$. זה לא אומר שהוא נמצא ליד אפס בהסתברות גבוהה. משפט הגבול המרכזי מאפשר לנו לקחת סביבה הגדלה בקצב של $\sqrt{n}$ ולקבל מידע טוב יותר לגבי ההסתברות על מיקום החלקיק. נסמן $Z_n = \frac{X_n - n\cdot 0}{\sqrt{n}\cdot\sqrt{1}} = \frac{X_n}{\sqrt{n}}$ ונקבל:

$$\begin{aligned} P\left(-\frac{\sqrt{n}}{2} \le X_n \le \frac{\sqrt{n}}{2}\right) &= P\left(-\frac{1}{2} \le \frac{X_n}{\sqrt{n}} \le \frac{1}{2}\right) = \\ &= P\left(\frac{X_n}{\sqrt{n}} \le \frac{1}{2}\right) - P\left(\frac{X_n}{\sqrt{n}} < -\frac{1}{2}\right) \underset{n\to\infty}{\overset{CLT}{\longrightarrow}} \Phi\left(\frac{1}{2}\right) - \Phi\left(-\frac{1}{2}\right) \simeq 0.38 \end{aligned}$$

כלומר יש סיכוי של כ־$38\%$ שהחלקיק נמצא בסביבה $\left[-\frac{\sqrt{n}}{2}, \frac{\sqrt{n}}{2}\right]$. ניתן כעת לבצע "סקיילינג" לסביבות הגדלות בקצב של $\sqrt{n}$ עד כדי קבוע ולקבל הסתברויות מדוייקות יותר לגבי המיקום של החלקיק.

# בהצלחה בבחינה!